Resultados unificados (rascunho para a dissertação)

> **Planilha de apoio:** `resultados_final_20261010_094742.xlsx`. Cada seção abre indicando as abas correspondentes (*Abas da planilha*). Todas as medidas são de associação, sem linguagem causal. Trechos marcados **[provisório]** dependem de confirmação do pesquisador (mapa tópico → aspecto do LDA; segundo anotador). A organização por perguntas está em `00_enquadramento.md`.

1. Dados e amostra

Abas da planilha: `Estat_Corpus`, `Selecao_Teto`, `Rating_Sintetico`, `Descritivo_Teto`, `Resumo_AB`, `Config`.

Este capítulo apresenta a base e o recorte usados em todas as análises seguintes. O estudo parte de 42.013 anúncios do Airbnb no Rio de Janeiro (Inside Airbnb) e 995.072 avaliações textuais. Dos anúncios, 33.140 têm nota oficial e subnotas (limpeza, localização, check-in, comunicação, custo-benefício e precisão); exigindo nota maior que zero e ao menos duas avaliações, restaram **28.890 anúncios elegíveis**.

Para conter o custo computacional, o sentimento foi calculado sobre as **30 avaliações mais recentes de cada anúncio**: 475.858 avaliações (depois de remover 1 avaliação automática e 311 duplicatas), divididas em **1.512.063 sentenças** (1.366.091 textos únicos; 3,18 sentenças por avaliação e 12,4 tokens por sentença). Idiomas das avaliações usadas (detectados por avaliação): português 66,2%, inglês 15,5%, espanhol 14,2%, francês 2,4%, alemão 1,1% e italiano 0,3%; o corpus não foi separado por idioma.

A nota oficial é fortemente comprimida: entre os 22.564 anúncios com índice sintético (seção 7), 22,8% têm nota exatamente 5,0 (média 4,82; desvio-padrão 0,22). Entre os 28.890 elegíveis, 9.373 têm nota 5,0 (32,4%); desses, 5.142 (54,9%) têm índice sintético, porque o índice exige evidência textual em ao menos três aspectos.

2. O que os dados permitem medir

Abas da planilha: `Formula_Ocupacao`, `REF_Investigacao_Coef`.

A seção anterior descreveu o que existe na base; esta delimita o que ela permite concluir, porque isso determina qual é o objeto central do estudo. Os dados trazem a nota e as subnotas oficiais (escala de 1 a 5) e o texto das avaliações, mas **não trazem ocupação nem receita observadas**. Os campos `estimated_occupancy_l365d` e `estimated_revenue_l365d` são estimativas da Inside Airbnb que verificamos ser funções exatas de variáveis do próprio anúncio: `ocupação = min(255, avaliações nos últimos 12 meses × 2 × max(3, estadia mínima))` reproduz o campo em 100,0% dos 42.013 anúncios, e `receita = preço × ocupação` em 100,0% dos 38.356 anúncios com preço; sem avaliação nos últimos 12 meses a ocupação é zero em 100,0% dos 12.979 casos. Na faixa de nota 5,0, a correlação de postos entre a ocupação estimada e as avaliações dos últimos 12 meses é 0,97.

Por isso, daqui em diante esses campos são chamados de **índices de volume recente de avaliações**, e as expressões "desempenho econômico", "ocupação" e "receita" não são usadas para eles sem essa qualificação. Um corolário metodológico: controlar a análise pelo número de avaliações dos últimos 12 meses equivale a controlar o próprio desfecho. Uma versão anterior da análise o fazia e obteve, na faixa de nota 5,0, um coeficiente de R_syn de −1,34 noite por desvio-padrão (p = 0,0001); ele desaparece com

uma forma funcional flexível (−0,09; p = 0,62) e é zero com a fórmula exata, e a análise foi refeita sem esse controle (seção 7). **Consequência anunciada:** o objeto central do estudo são a nota, as subnotas e o texto das avaliações; o volume de avaliações entra apenas como desfecho auxiliar, em três formas: o índice de ocupação, o índice de receita (em log) e o número de avaliações dos últimos 12 meses (em log), este último sem construção algébrica.

3. Como o texto é medido

Abas da planilha: `Config`, `Comparacao_Sentimento_AB`, `Avaliacao_Rotuladas_AB`, `Topicos_BERTopic`, `Topicos_LDA`, `Mapa_Topico_Aspecto`, `Mapa_Revisao`, `Resumo_Log`, `LadoALado_perfil_cobertura`.

Delimitado o objeto, esta seção descreve como o texto vira medida: sentimento por frase, tópicos, aspectos e perfil por anúncio. A medição é feita em quatro passos e cada um é avaliado na seção 4.

Sentimento, com dois modelos. Como a escolha do modelo pode alterar as conclusões, usamos dois, de natureza diferente. O modelo **A** (`cardiffnlp/twitter-xlm-roberta-base-sentiment`) é um modelo multilíngue genérico, treinado em tweets, com três classes (negativo, neutro, positivo); convertemos a saída em estrelas esperadas, 1·P(neg) + 3·P(neu) + 5·P(pos). O modelo **B** (`nlptown/bert-base-multilingual-uncased-sentiment`) é multilíngue e foi treinado em avaliações de produtos e serviços, com cinco classes (1 a 5 estrelas); as estrelas esperadas são a soma de k·P(k). A polaridade discreta de A é a classe mais provável das três; a de B é negativa se a classe mais provável tem 1 ou 2 estrelas, neutra se tem 3 e positiva se tem 4 ou 5. Ambos foram aplicados às mesmas 1.512.063 sentenças (1.366.091 textos únicos). As estrelas médias por texto único são 4,19 em A e 4,06 em B; a proporção de sentenças com quatro estrelas ou mais é 75,1% em A e 70,0% em B, e a distribuição das polaridades (negativa, neutra, positiva) é 6,8%, 14,3% e 78,9% em A, e 10,4%, 8,1% e 81,5% em B: nos dois, a maior parte das frases é positiva, o que reproduz no texto o viés de positividade da plataforma. As análises usam a **ordenação** do sentimento, não o seu nível; por isso importa que as estrelas esperadas ordenem as frases como um leitor humano: a correlação de postos entre o rótulo manual (−1, 0, +1) e as estrelas esperadas é 0,64 em A e 0,63 em B (seção 4.1).

Tópicos. As frases foram agrupadas por **BERTopic** (embeddings multilíngues `paraphrase-multilingual-MiniLM-L12-v2`, UMAP e HDBSCAN, ajustado em uma amostra de 200.000 sentenças e aplicado às demais), que encontrou **185 tópicos**; 29,8% das frases da amostra de ajuste ficaram como ruído, reduzidos a 1,0% dos textos depois da reatribuição ao centroide mais próximo. A coerência C_v média dos tópicos do BERTopic é 0,388. O **LDA** (K = 10, escolhido por C_v máximo numa grade de 5 a 40) tem C_v médio 0,625; esses valores descrevem cada método e não os colocam em disputa. O papel do LDA neste estudo é o de uma checagem (seção 4.5).

Mapa tópico → aspecto. Cada tópico do BERTopic foi mapeado a um de dez aspectos (limpeza, localização, check-in, comunicação, custo-benefício, ruído e conforto, segurança, precisão do anúncio, comodidades e satisfação geral, este último para elogio ou queixa genérica); o código sugeriu o aspecto pela similaridade com termos-semente multilíngues e a decisão foi do pesquisador, tópico a tópico: dos 185 tópicos, 105 mantiveram a sugestão automática, 80 foram alterados pelo pesquisador e 66 reclassificados depois de discussão; 53 tópicos ficaram em satisfação geral. Cada frase herda o aspecto do seu tópico.

Perfil por anúncio. Para cada anúncio e aspecto, o perfil é a média do sentimento das frases do aspecto, exigindo ao menos 2 frases; 28.889 anúncios têm perfil. Participação de cada aspecto nas sentenças e número de anúncios com o aspecto disponível:

Aspecto	Frases do corpus	Anúncios com o aspecto
Satisfação geral	27,1%	26.378
Comunicação	19,2%	25.418
Localização	18,3%	24.101
Comodidades	13,0%	22.272
Limpeza	7,6%	19.095
Precisão do anúncio	5,2%	16.638
Ruído e conforto	2,5%	9.550
Check-in	2,3%	8.919
Segurança	1,3%	5.072
Custo-benefício	1,0%	3.552
Fora do perfil (`geral`)	2,5%	—

4. A medição é confiável?

Abas da planilha: `Avaliacao_Rotuladas_AB`, `Aspecto_Rotuladas`, `Comparacao_Sentimento_AB`, `Diferenca_B_menos_A`, `Config`, `Validacao_Construto`, `LadoALado_validacao_construto`, `Val_Volume_Convergente`, `Val_Confiab_AUC`, `Val_Recortes`, `Checagem_LDA`.

A seção 3 define como o texto é medido; antes de usar essas medidas para dizer algo sobre a nota, é preciso saber o quanto elas merecem confiança. Esta seção busca a resposta em cinco tipos de evidência, da mais direta à mais indireta: frases rotuladas por um pesquisador, concordância entre os dois modelos, uma regra pré-registrada para escolher o modelo principal, concordância com as subnotas oficiais e uma checagem com um método de tópicos diferente. Fecha classificando cada aspecto, e as seções seguintes respeitam essa classificação.

4.1 Evidência direta: frases rotuladas

Abas da planilha: `Avaliacao_Rotuladas_AB`, `Aspecto_Rotuladas`, `Resumo_AB`.

O pesquisador rotulou, sem ver as classificações automáticas, 297 frases: sentimento (negativo, neutro ou positivo) e aspecto principal. A amostra foi estratificada pelo aspecto e pela polaridade previstos pelo modelo A (cerca de um terço de frases de cada polaridade por aspecto) e, portanto, é **rica em frases difíceis**: no corpus, 78,9% das sentenças são positivas segundo A. Por isso há duas leituras de cada métrica: na amostra, e ponderada pela população, em que cada frase pesa o tamanho do seu estrato original (aspecto × polaridade previstos por A); os pesos são os mesmos para A e B, e o tamanho efetivo da amostra ponderada é de apenas 72 frases, de modo que os intervalos são largos.

Medida	A	B
Acurácia na amostra	58,9%	63,3%
F1 macro na amostra	0,57	0,52
Kappa de Cohen na amostra	0,39	0,38
Kappa ponderado linear na amostra	0,48	0,50
Spearman, rótulo humano × estrelas esperadas	0,64	0,63
Acurácia ponderada pela população	87,2%	84,9%
Kappa ponderado pela população	0,55	0,43
Kappa ponderado linear pela população	0,66	0,51

Para os dois modelos o erro mais comum é classificar como neutras frases que o pesquisador considera positivas: quando A prevê "positivo" acerta 94,9%, mas quando prevê "neutro" acerta apenas 26,1%. B classifica mais frases como positivas (151 contra 98 de 297) e acerta menos nas previstas como neutras e negativas:

Polaridade prevista	A: frases	A: acerto	B: frases	B: acerto
negativo	84	61,9%	87	51,7%
neutro	115	26,1%	59	16,9%
positivo	98	94,9%	151	88,1%

A amostra e a população **discordam sobre qual modelo é melhor**, e é preciso descrever as duas. Na amostra, B tem acurácia maior (63,3% contra 58,9%; em português, 61,4% contra 51,8%), porque a amostra foi construída a partir das previsões de A e concentra as frases em que A erra (as que A chama de neutras). Ponderando pela população, A é melhor: a acurácia é 87,2% contra 84,9% e o kappa ponderado linear é 0,66 contra 0,51. Por idioma:

Idioma	Frases	A: acurácia (amostra)	B: acurácia (amostra)	A: acurácia ponderada	B: acurácia ponderada
português	166	51,8%	61,4%	85,0%	82,7%
inglês	63	65,1%	71,4%	91,5%	90,5%
espanhol	45	62,2%	60,0%	84,4%	81,6%
demais idiomas	23	87,0%	60,9%	94,6%	90,4%

O português, idioma de 66% das avaliações, é o de menor acerto na amostra para o modelo A.

Aspecto. A atribuição de aspecto não depende do modelo de sentimento. Acerta 54,5% na amostra (kappa 0,50); ponderando só pela participação de cada aspecto no corpus a estimativa é 52%, e com os estratos aspecto × polaridade, 66% (IC 95% por bootstrap [57%; 75%]), uma estimativa instável (células com poucas frases e pesos muito desiguais): lida na população, a acurácia de aspecto fica **entre 52% e 66%**. O acerto é parecido nas três polaridades previstas (54%, 53% e 57%), mas muito diferente conforme o tópico: 65% nas frases de tópico direto (186) e 38% nas de tópico reatribuído por similaridade (111). A precisão varia muito entre aspectos, com cerca de 27 frases rotuladas por aspecto (intervalos de ±0,18):

Aspecto previsto	Frases rotuladas	Precisão da atribuição
Custo-benefício	27	74%
Localização	27	74%
Precisão do anúncio	27	70%
Limpeza	27	67%
Check-in	27	56%
Segurança	27	48%
Comodidades	27	44%
Comunicação	27	44%
Ruído e conforto	27	44%
Satisfação geral	27	41%
Fora do perfil (`geral`)	27	37%

4.2 Concordância entre os dois modelos

Abas da planilha: `Comparacao_Sentimento_AB`.

Com a evidência direta limitada a 297 frases, o corpus inteiro permite comparar os modelos entre si. Nas 1.512.063 sentenças, a correlação de postos das estrelas esperadas de A e B é 0,61 e o kappa ponderado linear das polaridades é 0,45; por idioma, o kappa é 0,40 em português, 0,54 em inglês e 0,54 em espanhol. No nível anúncio × aspecto, a concordância é maior (0,69 de Spearman; kappa 0,55), porque a média de várias frases reduz o ruído: varia de 0,46 (Precisão do anúncio) a 0,86 (Comodidades). Os dois modelos ordenam as frases e os anúncios de modo semelhante, mas não são intercambiáveis: das 1.192.861 sentenças que A chama de positivas, B concorda em 1.087.384; das 215.635 que A chama de neutras, B chama 128.723 de positivas. Concordância completa:

Nível	Grupo	n	Spearman das estrelas	Pearson das estrelas	Kappa linear das polaridades
sentença	total	1.512.063	0,61	0,66	0,45
sentença	pt	955.831	0,57	0,61	0,40
sentença	en	292.513	0,71	0,78	0,54
sentença	es	195.827	0,69	0,78	0,54
sentença	demais	67.892	0,65	0,75	0,53
anúncio × aspecto	total	160.995	0,69	0,79	0,55
anúncio × aspecto	idioma predominante: pt	122.699	0,66	0,77	0,53
anúncio × aspecto	idioma predominante: en	23.467	0,79	0,87	0,60
anúncio × aspecto	idioma predominante: es	11.874	0,77	0,86	0,60
anúncio × aspecto	idioma predominante: demais	2.955	0,80	0,85	0,57

4.3 Regra pré-registrada e modelo principal

Abas da planilha: `Diferenca_B_menos_A`, `Config`.

Antes de rodar o modelo B, registramos a regra de escolha do modelo principal: **B seria o principal se o intervalo de 95% (bootstrap estratificado) da diferença B − A no kappa ponderado linear populacional de sentimento excluísse zero a favor de B; caso contrário, o principal seria A**, com o outro modelo sempre reportado como robustez. O resultado: a diferença B − A é −0,141 (IC 95% [−0,272; −0,012]), isto é, o intervalo exclui zero, mas **a favor de A**. Pela regra, o modelo principal é **A**. Na acurácia populacional a diferença é −0,023 [−0,078; 0,021], e só em português, no kappa ponderado linear, −0,169 [−0,323; 0,011], intervalo que inclui zero. A seção 4.1 mostra por que a escolha não é óbvia (B é melhor na amostra, A na população); a regra foi fixada antes de ver os resultados justamente para não escolher o resultado mais conveniente. Daqui em diante o modelo principal é A, e os resultados de B aparecem lado a lado nas abas com sufixo `_mB` e nas abas `LadoALado_*`.

4.4 Validade de construto: concordância com as subnotas oficiais

Abas da planilha: `Validacao_Construto`, `LadoALado_validacao_construto`, `Val_Volume_Convergente`, `Val_Confiab_AUC`, `Val_Recortes`.

A evidência indireta mais importante é a concordância com as subnotas que os próprios hóspedes deram. Para cada aspecto com subnota correspondente, correlacionamos, no nível do anúncio, o sentimento do aspecto com a subnota (não há limiar de aprovação; interessam a força e o sinal), e a satisfação geral com a nota global:

Aspecto	Subnota	n	Spearman (A)	Pearson (A)	Spearman (B)	Pearson (B)
Limpeza	cleanliness	19.095	0,45	0,58	0,42	0,52
Localização	location	24.101	0,24	0,31	0,24	0,27
Check-in	checkin	8.919	0,42	0,40	0,43	0,42
Comunicação	communication	25.418	0,30	0,44	0,30	0,43
Custo-benefício	value	3.552	0,24	0,26	0,22	0,23
Precisão do anúncio	accuracy	16.638	0,17	0,22	0,15	0,21
Satisfação geral	rating (nota global)	26.378	0,34	0,52	0,26	0,38

Todos os coeficientes são positivos e significativos nos dois modelos; a concordância é moderada, de 0,17 a 0,45 em A e de 0,15 a 0,43 em B, sem um modelo sistematicamente melhor (B é um pouco maior em check-in e comunicação; A, em limpeza, custo-benefício e, sobretudo, satisfação geral). Ela deve ser lida à luz de que as subnotas também são comprimidas (muitos empates em 5,0), o que atenua as correlações. Cinco verificações de robustez:

- **Por volume de avaliações.** No modelo A, a concordância dos anúncios com até 30 avaliações (em que o sentimento usa todas) difere da dos anúncios com mais de 30 em no máximo 0,11 (Check-in), sem padrão sistemático; em B o resultado é análogo.
- **Convergente e discriminante.** A subnota correspondente é a mais correlacionada com o aspecto em 5 de 7 casos em A e em 3 de 7 em B (nos demais fica em segundo ou terceiro lugar, porque as subnotas são muito correlacionadas entre si, o chamado efeito halo). Controlando a nota global (correlação parcial), resta informação específica em limpeza (0,17), localização (0,22), check-in (0,23) e comunicação (0,15), e quase nenhuma em custo-benefício (0,08) e precisão (0,04).

- **Subnotas saturadas.** A probabilidade de o sentimento ser maior nos anúncios de subnota 5 do que nos de subnota menor (AUC) vai de 0,57 a 0,69 em A e de 0,55 a 0,67 em B.
- **Idioma e tipo de acomodação.** No modelo A, as correlações são positivas em português, inglês e espanhol (de 0,13 a 0,45) e em casa/apartamento inteiro e quarto privado (de 0,17 a 0,46), o que sustenta o uso de modelos multilíngues.
- **Atenuação.** A confiabilidade split-half do sentimento por aspecto (metades das avaliações de cada anúncio, com Spearman-Brown) é baixa: de 0,10 a 0,40 em A e de 0,06 a 0,40 em B. Correlações corrigidas por essa atenuação (de 0,57 a 0,96 em A; em B, até 1,20) são apenas ilustrativas, porque com confiabilidades tão baixas a correção é instável e corrige só o lado do sentimento.

4.5 Checagem com um segundo método de tópicos (LDA)

Abas da planilha: `Checagem_LDA`, `Topicos_LDA`.

Para saber se os resultados por aspecto dependem do método de tópicos, atribuímos cada sentença ao tópico dominante do LDA (10 tópicos) e comparamos. O mapa tópico LDA → aspecto é **[provisório: a confirmar pelo pesquisador]**: só recebe aspecto o tópico cuja leitura das palavras de maior peso, aspecto mais similar aos termos-semente e margem entre o primeiro e o segundo aspecto (≥ 0,05) concordam; senão é "misto" e fica fora do perfil. Apenas 4 dos 10 tópicos receberam aspecto (comodidades, comunicação, satisfação geral e localização), e 55% das sentenças caem em tópicos mistos, de modo que o LDA só permite checar esses quatro aspectos. Entre as sentenças com aspecto nos dois métodos, 68,8% recebem o mesmo aspecto.

Aspecto (LDA)	Spearman do perfil BERTopic × LDA	Spearman com a subnota (LDA)	Spearman com a subnota (BERTopic)	Parcela do R^2 (LDA)	Parcela do R^2 (BERTopic)
Localização	0,61	0,20	0,24	1,6%	0,9%
Comunicação	0,54	0,28	0,30	22,7%	15,5%
Comodidades	0,67	— (sem subnota)	—	62,3%	59,0%
Satisfação geral	0,46	0,19	0,34	13,4%	24,6%

O sinal da validade de construto se mantém nos três aspectos que têm subnota (localização, comunicação e satisfação geral), com correlações do mesmo tamanho nos dois mais específicos e menores em satisfação geral. Na decomposição do R^2 da nota global, comodidades fica em primeiro nos dois métodos; satisfação geral e comunicação trocam de posição (correlação de postos 0,80, com apenas quatro aspectos).

4.6 O que é confiável e o que pede cautela

Abas da planilha: `Aspecto_Rotuladas`, `Validacao_Construto`, `LadoALado_validacao_construto`.

Resumindo as evidências, classificamos cada aspecto com um critério descritivo, fixado antes das seções seguintes: **confiável** se a precisão de atribuição na amostra é de ao menos 0,60 e a correlação com a subnota correspondente é de ao menos 0,20 nos dois modelos; **cautela** nos demais casos.

Aspecto	Precisão da atribuição (amostra)	Spearman com a subnota (A)	Spearman com a subnota (B)	Classificação	Critério
Limpeza	67%	0,45	0,42	confiável	precisão ≥ 0,60 e correlação ≥ 0,20 com a subnota nos dois modelos
Localização	74%	0,24	0,24	confiável	precisão ≥ 0,60 e correlação ≥ 0,20 com a subnota nos dois modelos
Check-in	56%	0,42	0,43	cautela	precisão de atribuição < 0,60
Comunicação	44%	0,30	0,30	cautela	precisão de atribuição < 0,60
Custo-benefício	74%	0,24	0,22	confiável	precisão ≥ 0,60 e correlação ≥ 0,20 com a subnota nos dois modelos
Ruído e conforto	44%	—	—	cautela	sem subnota correspondente: não validável
Segurança	48%	—	—	cautela	sem subnota correspondente: não validável
Precisão do anúncio	70%	0,17	0,15	cautela	correlação < 0,20 com a subnota em ao menos um modelo
Comodidades	44%	—	—	cautela	sem subnota correspondente: não validável
Satisfação geral	41%	0,34	0,26	cautela	precisão de atribuição < 0,60

São confiáveis: Limpeza, Localização, Custo-benefício. Pedem cautela: Check-in, Comunicação, Ruído e conforto, Segurança, Precisão do anúncio, Comodidades, Satisfação geral. Duas consequências valem para as seções 5 a 7. Primeiro, o aspecto de maior peso na seção 5, comodidades, pede cautela (atribuição imprecisa e sem subnota para validar); por isso a leitura prática da seção 5 se apoia nos tópicos finos de queixa e elogio, cuja atribuição é melhor (tópicos diretos, 65% de acerto de aspecto), e os pesos por aspecto são apresentados como indicativos. Segundo, nenhum resultado por aspecto deve ser lido sem a classificação ao lado. A concordância entre dois anotadores ainda não foi medida (**pendente**): uma planilha cega de 100 frases e o script de kappa estão prontos.

5. O que o texto revela sobre a nota

Abas da planilha: `Imp_Aspectos`, `Imp_Modelos`, `Imp_Segmentos_Sens`, `Imp_Topicos_Queixas`, `Imp_Topicos_Elogios`, `LadoALado_imp_lmg`, `LadoALado_imp_gbm`, `LadoALado_imp_logit`, `LadoALado_imp_segmentos`, `LadoALado_imp_sensibilidade`.

Estabelecido quais medidas merecem confiança (seção 4.6), esta seção apresenta a contribuição central do estudo: **o que o texto das avaliações revela sobre a nota que o anúncio recebe**. Primeiro, quais aspectos mais se associam à nota global e a cada subnota; depois, quais tópicos finos concentram as queixas e os elogios. Tudo é associação, não causa.

5.1 Importância dos aspectos

Abas da planilha: `Imp_Aspectos`, `Imp_Modelos`, `Imp_Segmentos_Sens`, `LadoALado_imp_lmg`, `LadoALado_imp_gbm`, `LadoALado_imp_logit`, `LadoALado_imp_segmentos`, `LadoALado_imp_sensibilidade`.

A análise usa os 28.889 anúncios com texto, inclusive os de pouco texto (o sentimento não observado de um aspecto é imputado pela média, e isso evita exigir três aspectos por anúncio), e toma como alvo o percentil da nota (a nota é comprimida no topo). A decomposição LMG (média de Shapley) reparte o R^2 da regressão da nota global sobre o sentimento dos dez aspectos; o R^2 total é de 0,320 em A e 0,291 em B. Parcela de cada aspecto:

Aspecto	Parcela do R^2 (A)	Parcela do R^2 (B)	Classificação (seção 4.6)
Comodidades	42,5%	47,8%	cautela
Limpeza	19,6%	18,8%	confiável
Satisfação geral	17,5%	9,9%	cautela
Comunicação	11,3%	12,6%	cautela
Check-in	3,4%	4,9%	cautela
Ruído e conforto	3,1%	3,6%	cautela
Precisão do anúncio	1,7%	1,1%	cautela
Localização	0,6%	0,8%	confiável
Custo-benefício	0,3%	0,4%	confiável
Segurança	0,1%	0,1%	cautela

Comodidades responde por 42,5% do R^2 em A e 47,8% em B, seguida por limpeza (19,6% e 18,8%); satisfação geral e comunicação vêm depois. Localização, custo-benefício e segurança quase não contribuem para a **nota global**, embora localização seja o aspecto que mais explica a sua própria subnota (tabela abaixo): o hóspede avalia o local em separado, e a nota global parece refletir mais o que ele viveu dentro do imóvel. A ordem das parcelas é muito parecida entre os modelos (correlação de postos 0,99); a diferença mais visível é a satisfação geral, que pesa menos em B. Ressalvas da seção 4.6: comodidades e satisfação geral estão na classe "cautela", e a importância relativa de um aspecto mistura efeito e confiabilidade da medida (aspectos pouco citados, como segurança e custo-benefício, são medidos com mais erro e imputados na maioria dos anúncios).

Para cada subnota, o aspecto correspondente está entre os que mais a explicam (modelo A, com a parcela também em B):

Subnota	R^2 total (A)	Aspecto correspondente	Sua parcela (A)	Sua parcela (B)	Aspecto de maior parcela (A)
cleanliness	0,229	Limpeza	33,3%	30,7%	Comodidades
location	0,093	Localização	41,8%	38,3%	Localização
checkin	0,163	Check-in	11,9%	14,5%	Comodidades
communication	0,211	Comunicação	22,1%	24,5%	Comodidades
value	0,239	Custo-benefício	0,7%	0,7%	Comodidades
accuracy	0,258	Precisão do anúncio	2,1%	1,4%	Comodidades

Dois modelos mais flexíveis dão a mesma leitura. Um GBM com valores ausentes tem R^2 fora da amostra de 0,442 em A e 0,416 em B (regressão linear com imputação: 0,388 e 0,363); a queda de R^2 por permutação é maior em Comodidades (0,233), Limpeza (0,078) e Satisfação geral (0,075) no modelo A. Na regressão logística para "nota ≥ 4,9" (que 51% dos anúncios têm; AUC fora da amostra 0,815 em A e 0,802 em B), um desvio-padrão a mais de sentimento multiplica as chances de nota alta por 2,46 em comodidades, 1,91 em limpeza, 1,47 em satisfação geral e 1,37 em comunicação (A); em B, 2,49, 1,65, 1,21 e 1,36.

O resultado é estável. Comodidades é o aspecto de maior parcela em 11 dos 11 segmentos (tipo de acomodação, idioma predominante e os seis maiores bairros) em A e em 11 dos 11 em B, com parcela de 37% a 43% (A) e de 38% a 49% (B); e é o de maior parcela em 5 das 5 sensibilidades (todos os anúncios, só tópicos diretos, até 30 avaliações, ao menos 3 aspectos, sem satisfação geral como preditor) em A e em 5 das 5 em B.

5.2 Queixas e elogios por tópico

Abas da planilha: `Imp_Topicos_Queixas`, `Imp_Topicos_Elogios`, `RSyn_Resumo_AB`.

A leitura prática está nos tópicos finos, cuja atribuição de aspecto é mais precisa (tópicos diretos). Para cada tópico, comparamos o percentil da nota entre anúncios com e sem ao menos uma menção negativa (ou positiva) no tópico, controlando o volume de avaliações e de frases; as 68 queixas e 181 elogios com amostra suficiente foram testados com correção de Benjamini-Hochberg (56 queixas e 123 elogios com q < 0,05 no sentido esperado). Queixas de maior peso (efeito × prevalência), modelo A:

Tópico (palavras de maior peso)	Aspecto (classificação)	Anúncios com menção	Efeito no percentil da nota	q (BH)
banheiro, chuveiro, água, box	Comodidades (cautela)	14%	−20,3 pontos	0,000
condicionado, aire, acondicionado, calor	Comodidades (cautela)	13%	−17,7 pontos	0,000
sujo, limpeza, chão, dirty	Limpeza (confiável)	7%	−26,4 pontos	0,000
infelizmente, leave, disappointed, problemas	Satisfação geral (cautela)	9%	−20,0 pontos	0,000
cozinha, cozinhar, kitchen, cocina	Comodidades (cautela)	7%	−19,1 pontos	0,000
anfitrião, anfitriã, hóspedes, host	Comunicação (cautela)	5%	−22,9 pontos	0,000
barulho, noise, ruido, noisy	Ruído e conforto (cautela)	11%	−9,7 pontos	0,000
cheiro, mofo, forte, olor	Limpeza (confiável)	5%	−21,8 pontos	0,000
cama, bed, camas, casal	Comodidades (cautela)	5%	−17,8 pontos	0,000
dormir, cortina, luz, cortinas	Ruído e conforto (cautela)	5%	−15,7 pontos	0,000
reparos, precisa, manutenção, melhorias	Comodidades (cautela)	3%	−21,5 pontos	0,000
wifi, sinal, senha, único	Comodidades (cautela)	3%	−19,5 pontos	0,000
airbnb, experiência, experience, airbnbs	Satisfação geral (cautela)	3%	−21,4 pontos	0,000

Chamam atenção as queixas de instalações e manutenção (banheiro, ar-condicionado, cozinha, cama, wi-Fi, reparos), de limpeza (sujeira, cheiro) e de resposta do anfitrião, que se associam a quedas de 10 a 26 pontos no percentil da nota entre os anúncios que as recebem. Entre as **15 queixas de maior peso**, 13 coincidem nos dois modelos: a lista é robusta à escolha do modelo (em A e não em B: reparos, precisa, manutenção; repelente, cocina, kitchen; em B e não em A: check, checkout, flexível; reserva, paguei, cheguei). Elogios mais associados a notas altas, modelo A:

Tópico (palavras de maior peso)	Aspecto (classificação)	Anúncios com menção	Efeito no percentil da nota	q (BH)
anfitriã, anfitrião, host, anfitriões	Comunicação (cautela)	84%	+8,5 pontos	0,000
rio, janeiro, río, rock	Satisfação geral (cautela)	56%	+7,5 pontos	0,000
casa, senti, sentimos, sentir	Satisfação geral (cautela)	34%	+10,9 pontos	0,000
voltaremos, voltar, esperamos, iremos	Satisfação geral (cautela)	44%	+8,2 pontos	0,000
agradeço, gracias, agradecer, atenção	Comunicação (cautela)	31%	+5,7 pontos	0,000
limpo, organizado, limpio, clean	Limpeza (confiável)	34%	+4,8 pontos	0,000

A queixa genérica ("decepcionado, problemas") e os elogios genéricos (sentir-se em casa, voltar) pertencem a satisfação geral, aspecto de cautela, e servem sobretudo como termômetro.

5.3 Cuidados de interpretação

Sem rótulo causal: um anúncio com queixa de banheiro tem nota menor, mas isto não quer dizer que consertar o banheiro eleve a nota. O "efeito" é a diferença média, na cidade, entre anúncios com e sem a menção, controlada por volume. A atribuição de aspecto acerta entre 52% e 66% na população (seção 4.1), e a importância por aspecto fica abaixo da dos tópicos, o que reforça a leitura por tópico.

6. Aplicação: diagnóstico por anúncio

Abas da planilha: `Benchmark_Bairro_Tipo`.

A seção 5 diz o que se associa à nota; esta mostra como um anfitrião ou uma empresa gestora usa isso. A ferramenta `diagnostico.py` gera, a pedido, o relatório de **um** anúncio: o sentimento médio em cada aspecto e a posição (percentil) entre anúncios do mesmo bairro e tipo de acomodação (ou do tipo na cidade, quando o bairro tem poucos anúncios); a evidência de cada aspecto (poucas frases, evidência baixa, sem rótulo de força ou atenção); as queixas e os elogios recorrentes do anúncio, com a associação média, na cidade, desses tópicos com o percentil da nota (seção 5.2); e a evolução do sentimento nas avaliações mais recentes. A ferramenta funciona também para anúncios novos, marcando a evidência como baixa em vez de omitir o aspecto.

Para a comparação, a Etapa 17 construiu tabelas de referência: 66 grupos de bairro e tipo de acomodação com ao menos 30 anúncios e 3 grupos por tipo na cidade (aba `Benchmark_Bairro_Tipo`), com mediana e quartis do sentimento por aspecto e da nota. O relatório respeita a classificação da seção 4.6: a nota metodológica que o acompanha informa a precisão da atribuição por aspecto, e os aspectos de cautela não devem orientar decisões isoladamente (os confiáveis são Limpeza, Localização, Custo-benefício). Três

exemplos anonimizados (um anúncio de nota alta, um de nota baixa e um com poucas avaliações) estão em `redacao/exemplos_diagnostico/`: no de nota baixa, o relatório aponta comodidades e satisfação geral muito abaixo dos pares e as queixas de banheiro e cozinha; no de poucas avaliações, a maior parte dos aspectos aparece com evidência baixa. O relatório prioriza onde investigar, e não prevê nota nem prescreve causas.

7. Um índice único acrescenta algo?

Abas da planilha: `RSyn_Resumo_AB`, `Descritivo_Teto`, `Selecao_Teto`, `Analise_A`, `Analise_A_mB`, `Analise_A_Intersecao`, `Comparacoes_Multiplas`, `Analise_B`, `Analise_B_mB`, `Sensibilidade`, `Sensibilidade_mB`, `Limite_30_Avaliacoes`.

Com a seção 5 estabelecida, resta uma pergunta secundária: o que se ganha ao resumir o perfil de aspectos em **um número**, um índice sintético que substitua a nota oficial? É um resultado secundário, e um resultado nulo seria legítimo: a decomposição por aspecto da seção 5 é a contribuição do estudo, e o índice sintético apenas a testa.

7.1 Construção

O índice sintético (R_syn) é a média igual dos sentimentos dos aspectos disponíveis do anúncio, em estrelas de 1 a 5, exigindo ao menos 3 aspectos específicos com evidência (a satisfação geral entra na média, mas não conta para o mínimo). Há 22.564 anúncios com R_syn. A especificação principal **não** aplica shrinkage (encolhimento empírico-bayesiano com m = 23, a mediana de avaliações), por uma razão teórica: o encolhimento puxa os anúncios de poucas avaliações para a média global e, com isso, correlaciona o índice com o volume de avaliações justamente onde a nota é 5,0 (os anúncios de nota 5,0 têm mediana de 9 avaliações, contra 31 nos demais): entre eles, a correlação de postos do índice com o log do volume é 0,50 com shrinkage e −0,04 sem (0,45 e 0,03 em B). Registramos que **essa decisão foi tomada depois de ver o resultado** com shrinkage; por isso as duas versões são reportadas (seção 7.5).

7.2 Compressão da nota oficial e reordenamento

Abas da planilha: `RSyn_Resumo_AB`, `Selecao_Teto`.

A nota oficial concentra 22,8% dos anúncios com R_syn no valor 5,0; o valor mais comum do índice sintético concentra 1,6% em A e 1,9% em B. A correlação de postos entre R_syn e a nota oficial é 0,62 em A e 0,58 em B; 61% (A) e 63% (B) dos anúncios mudam 10 pontos percentuais de posto ou mais entre os dois rankings. Os R_syn de A e de B têm correlação de postos 0,82. Entre os anúncios de nota exatamente 5,0 com R_syn (5.142), o índice espalha os anúncios entre o percentil 27 e o 98 (5º a 95º; B: 22 e 98) e concorda fracamente, mas de forma positiva, com as seis subnotas (correlação de postos de 0,08 a 0,12 em A e de 0,04 a 0,10 em B; as subnotas também são saturadas).

Quem entra no teto. Essa discriminação vale para os anúncios de nota 5,0 **que têm R_syn**: 5.142 dos 9.373 anúncios de nota 5,0 (54,9%). Os que ficam de fora são sobretudo os de pouquíssimas avaliações, que são justamente os mais comprimidos:

Característica (nota 5,0)	Com R_syn	Sem R_syn
Anúncios	5.142	4.231
Avaliações totais (mediana)	9	3
Preço (mediana)	345	331
Casa ou apartamento inteiro	81%	72%
Quarto privado	18%	26%
Português predominante	74%	73%

7.3 Poder explicativo sobre os índices de volume

Abas da planilha: `Analise_A`, `Analise_A_mB`, `Analise_A_Intersecao`, `Comparacoes_Multiplas`, `Descritivo_Teto`.

Os controles são o volume total de avaliações (log), o preço (log), o tipo de acomodação e o bairro; **não** se controla pelas avaliações dos últimos 12 meses (seção 2). A validação é fora da amostra, com 5 dobras repetidas 5 vezes, mesma semente e mesmas dobras em todos os modelos. M0 são os controles; M1 acrescenta a nota oficial; M2 acrescenta o R_syn no lugar da nota; M3 acrescenta os dois. No índice de ocupação, na amostra completa, os controles têm R^2 fora da amostra de 0,475, e a nota oficial o eleva a 0,483. Ganho de R^2 fora da amostra (média entre dobras e intervalo de 2,5% a 97,5% entre dobras):

Desfecho	Escopo	M1 − M0: nota oficial (A)	M2 − M1: R_syn no lugar da nota (A)	M3 − M1: R_syn além da nota (A)	M3 − M1 (B)
Índice de ocupação	amostra completa	+0,0079 [+0,0052; +0,0099]	−0,0050 [−0,0070; −0,0020]	+0,0000 [−0,0005; +0,0002]	+0,0002 [−0,0007; +0,0006]
Índice de ocupação	nota ≥ 4,8	+0,0063 [+0,0038; +0,0091]	−0,0059 [−0,0083; −0,0033]	+0,0000 [−0,0003; +0,0002]	+0,0002 [−0,0005; +0,0006]
Índice de ocupação	nota ≥ 4,9	+0,0033 [+0,0009; +0,0057]	−0,0033 [−0,0055; −0,0010]	−0,0001 [−0,0003; +0,0000]	+0,0000 [−0,0006; +0,0002]
Índice de ocupação	nota = 5,0	+0,0000 [+0,0000; +0,0000]	−0,0002 [−0,0009; +0,0000]	−0,0002 [−0,0009; +0,0000]	−0,0002 [−0,0007; +0,0000]
Índice de receita (log)	amostra completa	+0,0174 [+0,0089; +0,0239]	−0,0132 [−0,0206; −0,0050]	+0,0010 [−0,0013; +0,0025]	+0,0014 [−0,0015; +0,0027]
Índice de receita (log)	nota ≥ 4,8	+0,0039 [−0,0001; +0,0073]	−0,0037 [−0,0080; +0,0009]	−0,0002 [−0,0012; +0,0001]	−0,0002 [−0,0008; +0,0000]
Índice de receita (log)	nota ≥ 4,9	+0,0009 [−0,0015; +0,0028]	−0,0002 [−0,0029; +0,0029]	+0,0004 [−0,0010; +0,0012]	+0,0004 [−0,0016; +0,0015]
Índice de receita (log)	nota = 5,0	+0,0000 [+0,0000; +0,0000]	+0,0019 [−0,0040; +0,0059]	+0,0019 [−0,0040; +0,0059]	+0,0016 [−0,0019; +0,0040]
Avaliações em 12 meses (log)	amostra completa	+0,0163 [+0,0108; +0,0208]	−0,0116 [−0,0157; −0,0067]	+0,0006 [−0,0009; +0,0014]	+0,0012 [−0,0008; +0,0025]
Avaliações em 12 meses (log)	nota ≥ 4,8	+0,0060 [+0,0033; +0,0088]	−0,0055 [−0,0088; −0,0026]	−0,0001 [−0,0005; +0,0001]	+0,0001 [−0,0008; +0,0006]
Avaliações em 12 meses (log)	nota ≥ 4,9	+0,0028 [−0,0008; +0,0059]	−0,0020 [−0,0045; +0,0014]	+0,0003 [−0,0004; +0,0007]	+0,0000 [−0,0006; +0,0002]
Avaliações em 12 meses (log)	nota = 5,0	+0,0000 [+0,0000; +0,0000]	+0,0015 [−0,0020; +0,0041]	+0,0015 [−0,0020; +0,0041]	+0,0005 [−0,0018; +0,0017]

A nota oficial acrescenta um poder explicativo pequeno, mas detectável (nos três desfechos, na amostra completa); o R_syn, no lugar dela, explica menos; e **o R_syn não acrescenta poder explicativo além da nota oficial**: o intervalo de M3 − M1 exclui zero em 0 das 12 comparações em A e em 0 em B. Restritos aos 22.564 anúncios com R_syn nos dois modelos, as diferenças M3 − M1 entre A e B são de no máximo 0,0010 (aba `Analise_A_Intersecao`).

Coeficientes dentro da amostra. Em M3, o coeficiente padronizado de R_syn (erro-padrão robusto HC3) aparece significativo em vários desfechos e escopos; reunimos os 12 de cada modelo em uma família e aplicamos Benjamini-Hochberg:

Desfecho	Escopo	Coef. de R_syn (A)	p (A)	q (A)	Coef. de R_syn (B)	p (B)	q (B)
Índice de ocupação	amostra completa	−0,919	0,0617	0,1058	−1,636	0,0007	0,0027
Índice de ocupação	nota ≥ 4,8	−0,716	0,1255	0,1882	−1,252	0,0055	0,0132
Índice de ocupação	nota ≥ 4,9	−0,236	0,6424	0,6855	−0,654	0,1808	0,2411
Índice de ocupação	nota = 5,0	+0,188	0,6855	0,6855	−0,190	0,6797	0,6797
Índice de receita (log)	amostra completa	−0,129	0,0000	0,0000	−0,143	0,0000	0,0000
Índice de receita (log)	nota ≥ 4,8	−0,016	0,4550	0,5460	−0,011	0,6167	0,6728
Índice de receita (log)	nota ≥ 4,9	+0,058	0,0218	0,0435	+0,063	0,0165	0,0248
Índice de receita (log)	nota = 5,0	+0,141	0,0004	0,0012	+0,120	0,0047	0,0132
Avaliações em 12 meses (log)	amostra completa	−0,037	0,0000	0,0000	−0,052	0,0000	0,0000
Avaliações em 12 meses (log)	nota ≥ 4,8	−0,005	0,4280	0,5460	−0,016	0,0140	0,0241
Avaliações em 12 meses (log)	nota ≥ 4,9	+0,020	0,0056	0,0133	+0,008	0,2866	0,3440
Avaliações em 12 meses (log)	nota = 5,0	+0,040	0,0000	0,0001	+0,026	0,0073	0,0145

Com a correção, 6 de 12 coeficientes têm q < 0,05 em A e 8 em B. Eles **não são robustos**: mudam de sinal conforme o escopo (negativos na amostra completa, positivos em parte dos tetos) e conforme o modelo de sentimento (por exemplo, no índice de ocupação da amostra completa, o coeficiente não é significativo em A e é negativo e significativo em B), e não se confirmam fora da amostra (os ganhos M3 − M1 acima têm intervalos que incluem zero na quase totalidade das comparações). Por isso ficam fora da síntese e das conclusões.

7.4 Monotonicidade e reordenamento

Abas da planilha: `Analise_B`, `Analise_B_mB`.

O R_syn reordena os anúncios em relação à nota oficial (seção 7.2); a pergunta é se essa reordenação se associa ao desfecho. Correlação de postos entre cada medida e o índice de ocupação residualizado nos controles, por faixa da nota oficial:

Faixa da nota oficial	n	ρ de R_syn × desfecho residual (A)	ρ de R_syn × desfecho residual (B)	ρ da nota oficial × desfecho residual	ρ de R_syn × nota oficial (A)	% que muda ≥ 10 pp de posto (A)
TODAS	20.882	0,083	0,071	0,168	0,620	61%
[0; 4.5)	1.285	−0,086	−0,108	−0,176	0,427	30%
[4.5; 4.8)	5.146	−0,045	−0,063	0,047	0,273	56%
[4.8; 4.9)	4.704	−0,036	−0,063	0,018	0,134	73%
[4.9; 5)	5.036	−0,018	−0,004	0,099	0,153	68%
= 5,0	4.711	0,025	0,028	—	—	55%

Para os dois modelos, a associação do R_syn com o desfecho residual é pequena e muda de sinal entre faixas, e na faixa de nota 5,0 é próxima de zero. A regressão isotônica (relação monótona crescente, avaliada fora da amostra) tem R^2 de 0,029 para a nota oficial e 0,006 para o R_syn na amostra completa (B: 0,004), e nos tetos é ≈ 0 para ambos (nota 5,0: −0,003 para o R_syn em A).

7.5 Sensibilidade

Abas da planilha: `Sensibilidade`, `Sensibilidade_mB`, `Limite_30_Avaliacoes`.

Ganho de R^2 do R_syn além da nota oficial no teto (nota = 5,0) e correlação de postos do índice com o desfecho (índice de ocupação) dentro da faixa de nota 5,0, para as seis variantes (shrinkage; com e sem satisfação geral; todos os anúncios ou só os de até 30 avaliações):

Variante	Δ R^2 índice de ocupação (A)	Δ R^2 avaliações 12 m (A) [IC]	ρ bruto (A)	ρ residual (A)	Δ R^2 avaliações 12 m (B)	ρ bruto (B)
Sem shrinkage (principal)	−0,0002	+0,0015 [−0,0020; +0,0041]	−0,01	+0,03	+0,0005	+0,03
Com shrinkage (m = 23)	+0,0001	+0,0016 [−0,0026; +0,0044]	+0,35	+0,02	+0,0002	+0,31
Sem shrinkage, sem satisfação geral	−0,0002	+0,0010 [−0,0011; +0,0032]	−0,02	+0,02	+0,0006	+0,02
Com shrinkage, sem satisfação geral	−0,0001	+0,0011 [−0,0023; +0,0034]	+0,33	+0,01	+0,0004	+0,31
Sem shrinkage, só anúncios com até 30 avaliações	−0,0003	+0,0013 [−0,0037; +0,0046]	+0,02	+0,03	+0,0007	+0,05
Com shrinkage, só anúncios com até 30 avaliações	−0,0003	+0,0014 [−0,0043; +0,0052]	+0,26	+0,04	+0,0008	+0,23

O ρ bruto de +0,35 com shrinkage é um artefato do encolhimento (seção 7.1); sem ele, e com o desfecho residualizado nos controles, o ρ é próximo de zero em todas as variantes. Excluir a satisfação geral quase não muda os resultados. O limite de 30 avaliações por anúncio afeta 32% dos anúncios elegíveis (9.266), mas só 5,2% dos de nota 5,0; a confiabilidade do sentimento médio por anúncio é de 0,50 com 30 avaliações, 0,67 com 60 e 0,80 com 120, e não há deriva temporal relevante (estrelas médias de 4,345 nas 10 avaliações mais recentes e 4,368 nas 20 mais antigas).

7.6 Como ler o resultado

O resultado é nulo e secundário: o índice sintético não acrescenta poder explicativo sobre os índices de volume além da nota oficial, em nenhum dos dois modelos de sentimento. Há duas leituras, que não se excluem. A primeira é que **o sentimento do texto tem pouca razão teórica para prever uma contagem de avaliações**: os desfechos disponíveis são índices de volume (seção 2), e o nulo é em parte consequência do desfecho que a base permite. A segunda é que **o valor do texto está na decomposição por aspecto da seção 5, e não em substituir a nota**: a nota oficial já resume bem a satisfação geral do hóspede, e o texto acrescenta o porquê. Em nenhum ponto este estudo apresenta o R_syn como "rating melhor".

8. Sazonalidade e eventos (análise exploratória)

Abas da planilha: `Sazon_Volume`, `Sazon_NegativaGeral`, `Sazon_NegativaGeral_mB`, `Sazon_Criterio`, `Sazon_Criterio_mB`, `LadoALado_sazon_aspecto`, `LadoALado_sazon_criterio`, `Config`.

Esta seção é **exploratória** e vem depois das demais porque não sustenta nenhuma conclusão das seções 5 a 7; ela mostra uma aplicação do mesmo texto a uma pergunta diferente, a de como o conteúdo das avaliações muda em períodos de grande procura. Três limitações valem para tudo o que segue. A data da avaliação não é a da estadia (as avaliações foram atribuídas a cada evento por uma janela entre o dia seguinte ao início da estadia e 14 dias depois do fim, prazo máximo para avaliar), de modo que há erro de atribuição. Os dados só incluem avaliações de anúncios ainda ativos na coleta, e os anos mais antigos ficam sub-representados. Os eventos têm poucas edições dentro do período (o *Todo Mundo no Rio* tem uma, e o conteúdo do Carnaval vem de duas). O plano e os critérios foram congelados antes dos resultados (histórico de decisões), mas a comparação de conteúdo por aspecto e por tópico envolve muitos testes, corrigidos por Benjamini-Hochberg, e deve ser lida como geração de hipóteses.

8.1 Volume de avaliações

A medida é o volume diário de **avaliações escritas** na janela do evento em relação ao de dias comuns do mesmo ano-mês (GLM de Poisson com efeitos fixos de ano-mês e dia da semana, erro-padrão robusto HAC; 2020 e 2021 excluídos). Ela indica estadias que terminaram no período, e **não** a ocupação dos imóveis. Em todos os eventos o volume é maior do que em dias comuns:

Evento	Defasagem 14 dias [IC 95%]	Defasagem 7 dias [IC 95%]
Rock in Rio	1,73 [1,16; 2,58]	2,42 [2,12; 2,77]
Corpus Christi	1,34 [1,15; 1,56]	1,65 [1,45; 1,89]
Réveillon	1,34 [1,22; 1,46]	1,45 [1,32; 1,59]
Todo Mundo no Rio (2024)	1,31 [1,01; 1,69]	1,66 [1,37; 2,01]
Carnaval	1,26 [1,09; 1,45]	1,51 [1,36; 1,69]
Semana Santa	1,25 [1,13; 1,37]	1,27 [1,16; 1,39]
Feriados curtos	1,24 [1,13; 1,36]	1,26 [1,16; 1,37]

A defasagem de 7 dias dá razões maiores porque considera só os dias logo após o check-out, onde o efeito se concentra; a de 14 dias inclui mais dias comuns. No *Todo Mundo no Rio*, o limite inferior com 14 dias fica praticamente em 1, e a evidência é mais fraca.

8.2 Tom geral das avaliações: não replica entre os modelos

Em uma checagem exploratória (binomial diário, janelas de 14 dias), a proporção de frases negativas no corpus inteiro nas janelas de evento, em relação a dias comuns, é menor em Rock in Rio, Corpus Christi, Todo Mundo no Rio (2024) com o modelo A. Com o modelo B, o resultado não aparece (eventos com q < 0,05: nenhum):

Evento	Razão de chances de frase negativa (A) [IC 95%]	q (A)	Razão de chances (B) [IC 95%]	q (B)
Rock in Rio	0,87 [0,82; 0,92]	0,000	0,97 [0,91; 1,05]	0,506
Corpus Christi	0,91 [0,86; 0,95]	0,000	0,99 [0,95; 1,02]	0,506
Réveillon	1,02 [0,92; 1,14]	0,839	1,01 [0,99; 1,04]	0,506
Todo Mundo no Rio (2024)	0,84 [0,78; 0,91]	0,000	0,98 [0,93; 1,03]	0,506
Carnaval	0,99 [0,89; 1,10]	0,907	0,91 [0,84; 0,99]	0,349
Semana Santa	1,05 [0,98; 1,12]	0,307	1,03 [0,99; 1,08]	0,442
Feriados curtos	1,00 [0,95; 1,05]	0,933	1,03 [0,99; 1,06]	0,389

Portanto, a menor proporção de frases negativas nos eventos de música **depende do modelo de sentimento** e não deve ser tratada como achado; a interpretação que havíamos aventado (público mais jovem e tolerante a ruído) fica sem sustentação empírica neste ponto. O modelo B classifica mais frases como positivas que o A (seção 4.2), e é plausível que a diferença entre janelas dependa do limiar entre neutro e negativo.

8.3 Conteúdo por aspecto

Para cada evento e aspecto, comparou-se a proporção de frases negativas dentro do aspecto com a de dias comuns (razão de chances; janelas de 14 dias; 70 combinações). Com q < 0,05, 20 combinações aparecem em A e 13 em B; **só 5 aparecem nos dois com o mesmo sentido**, 0 com sentidos opostos, 15 apenas em A e 8 apenas em B. As que coincidem:

Evento	Aspecto	Razão de chances (A) [IC]	Razão de chances (B) [IC]
Semana Santa	Limpeza	1,21 [1,06; 1,38]	1,24 [1,09; 1,41]
Semana Santa	Localização	0,81 [0,74; 0,89]	0,83 [0,77; 0,89]
Corpus Christi	Check-in	0,71 [0,62; 0,81]	0,70 [0,60; 0,83]
Corpus Christi	Comunicação	1,18 [1,07; 1,30]	1,18 [1,05; 1,33]
Todo Mundo no Rio (2024)	Custo-benefício	0,22 [0,09; 0,52]	0,23 [0,14; 0,38]

Por exemplo, os aumentos de queixa no Carnaval que aparecem só em A: Localização (razão de chances 1,23 em A e 0,99 em B); Custo-benefício (razão de chances 1,57 em A e 0,78 em B); Precisão do anúncio (razão de chances 1,79 em A e 1,07 em B). O critério de conteúdo definido de antemão (ao menos um aspecto ou tópico com aumento de queixa relevante e significativo) é satisfeito em Carnaval com A e em Réveillon, Todo Mundo no Rio (2024), Semana Santa com B: o conteúdo é **sensível ao modelo**, e só as combinações da tabela acima podem ser tomadas como indicativas.

9. Limitações

Abas da planilha: `Config`, `Estat_Corpus`, `Limite_30_Avaliacoes`, `Avaliacao_Rotuladas_AB`, `Aspecto_Rotuladas`, `Val_Confiab_AUC`, `Checagem_LDA`.

Reunimos aqui o que limita a leitura de todo o texto, na ordem das seções.

- **Recorte do corpus (seção 1).** O sentimento usa as 30 avaliações mais recentes de cada anúncio; 32% dos anúncios elegíveis (9.266) têm mais avaliações que o limite. O truncamento afeta pouco os de nota 5,0 (5,2%), mas reduz a confiabilidade do sentimento médio por anúncio (Spearman-Brown de 0,50 com 30 avaliações). Os dados só têm anúncios ativos na coleta, e as avaliações não indicam a data da estadia.
- **Desfechos (seção 2).** Não há ocupação nem receita observadas; os campos disponíveis são funções do número de avaliações recentes. Nenhum resultado fala de desempenho econômico.
- **Medição do texto (seções 3 e 4).** Os rótulos de referência vêm de um único pesquisador, que também revisou o mapa de tópicos para aspectos; a concordância com um segundo anotador ainda não foi medida (**pendente**: planilha cega de 100 frases e script de kappa prontos). A amostra rotulada tem 297 frases e, ponderada pela população, tamanho efetivo de cerca de 72 frases, de modo que os intervalos são largos e as comparações entre modelos são frágeis (a diferença de kappa B − A é de −0,141, com IC que mal exclui zero). A confiabilidade split-half do sentimento por aspecto é baixa, e as subnotas oficiais usadas como referência são comprimidas. Sete dos dez aspectos pedem cautela (seção 4.6); em especial, comodidades, o aspecto de maior peso, tem atribuição imprecisa e não tem subnota para validar. O mapa do LDA é **provisório** e depende de confirmação do pesquisador; o LDA só checa quatro aspectos.
- **Dois modelos de sentimento (seção 4).** O modelo A é o principal por uma regra fixada antes da execução do B, mas B é melhor na amostra rotulada e A na população; a escolha não é óbvia, e por isso os resultados de B acompanham todos os blocos. Onde os dois divergem (seções 7.3 e 8), as duas leituras são relatadas sem preferência.
- **Importância dos aspectos (seção 5).** A importância relativa de um aspecto mistura efeito e confiabilidade da medida, e as associações com a nota são entre anúncios, não dentro do anúncio; nada disso autoriza falar em causa. Anúncios sem aspectos suficientes têm sentimento imputado.
- **Índice sintético (seção 7).** Só 5.142 dos anúncios de nota 5,0 têm o índice, e os que ficam de fora têm menos avaliações; as conclusões sobre o teto valem para esse subconjunto. A decisão de não aplicar shrinkage foi tomada depois de ver o resultado com shrinkage. Coeficientes dentro da amostra não são robustos e não foram confirmados fora dela.
- **Sazonalidade (seção 8).** Exploratória, com poucas edições por evento e conteúdo sensível ao modelo; o feriado municipal de São Sebastião deve ser conferido em lei municipal.
- **Generalização.** Um só município, uma só plataforma e uma só coleta.

10. Conclusões

Abas da planilha: `Avaliacao_Rotuladas_AB`, `Diferenca_B_menos_A`, `Validacao_Construto`, `Checagem_LDA`, `Imp_Aspectos`, `LadoALado_imp_lmg`, `Imp_Topicos_Queixas`, `RSyn_Resumo_AB`, `Selecao_Teto`, `Analise_A`, `Comparacoes_Multiplas`, `Sazon_Volume`, `Config`.

As conclusões seguem a ordem da linha de raciocínio. Todas são associações, e todas valem com as ressalvas da seção 9.

1. **A medição do texto é utilizável, com restrições.** Em 297 frases rotuladas por um pesquisador, a acurácia populacional do sentimento é de 87% no modelo A e 85% no B, e o kappa ponderado populacional é 0,66 e 0,51. Pela regra fixada antes da execução do B (diferença de kappa B − A de −0,141, IC [−0,272; −0,012]), o modelo principal é A, e B acompanha todos os resultados. Os dois modelos concordam em ordenar frases e anúncios, mas não são intercambiáveis. O sentimento dos aspectos concorda com as subnotas oficiais de forma moderada e positiva; só Limpeza, Localização, Custo-benefício satisfazem o critério de confiança da seção 4.6, e Check-in, Comunicação, Ruído e

conforto, Segurança, Precisão do anúncio, Comodidades, Satisfação geral pedem cautela. Um segundo método de tópicos (LDA, mapa provisório) reproduz o sinal nos aspectos que consegue checar. A concordância entre dois anotadores está **pendente**.

2. **O texto das avaliações revela o que se associa à nota.** Nos dois modelos, comodidades é o aspecto de maior parcela do R^2 da nota global (42% em A e 48% em B), seguida de limpeza (20% e 19%), e isso se mantém em todos os segmentos e sensibilidades. Como comodidades pede cautela, a leitura que mais se sustenta é a dos tópicos finos: 13 das 15 queixas de maior peso são as mesmas nos dois modelos (banheiro e chuveiro, ar-condicionado, sujeira, cozinha, cheiro, cama, wi-Fi, resposta do anfitrião), associadas a quedas de 10 a 26 pontos no percentil da nota.
3. **A decomposição é aplicável ao anúncio.** O diagnóstico por anúncio (seção 6) compara cada aspecto com anúncios do mesmo bairro e tipo, mostra a evidência de cada um e as queixas e elogios recorrentes, e indica onde investigar, sem prever nota nem prescrever causas.
4. **Um índice único não acrescenta poder explicativo.** O índice sintético reordena os anúncios em relação à nota oficial e discrimina os anúncios de nota 5,0 que o têm (5.142 de 9.373), mas não acrescenta poder explicativo sobre os índices de volume além da nota oficial, em nenhum dos dois modelos. O resultado é nulo e secundário, com duas leituras que não se excluem: o sentimento tem pouca razão teórica para prever uma contagem de avaliações, e o valor do texto está na decomposição por aspecto. Os coeficientes dentro da amostra não são robustos e ficam fora desta síntese.

O que o estudo **não** conclui: que o índice sintético seja um "rating melhor", que consertar um problema aponte para aumento de nota, que haja efeito sobre receita ou ocupação, ou que os eventos alterem o tom das avaliações (seção 8, exploratória e sensível ao modelo).