UNIVERSIDADE CATÓLICA DE PETRÓPOLIS
CENTRO DE ENGENHARIA E COMPUTAÇÃO
MESTRADO PROFISSIONAL EM GESTÃO DE SISTEMAS DE ENGENHARIA

Raphael Rodrigues Eiras

# **O QUE AS AVALIAÇÕES REVELAM SOBRE A NOTA**: decomposição por aspecto do sentimento em avaliações de hóspedes do Airbnb no Rio de Janeiro

**PETRÓPOLIS**
**2026**

Raphael Rodrigues Eiras

# **O QUE AS AVALIAÇÕES REVELAM SOBRE A NOTA**: decomposição por aspecto do sentimento em avaliações de hóspedes do Airbnb no Rio de Janeiro

Dissertação apresentada ao Centro de Engenharia e Computação da Universidade Católica de Petrópolis (UCP), como requisito parcial para obtenção do título de Mestre em Gestão de Sistemas de Engenharia.

Orientador: Prof. Dr. Rodolfo Nicolay

**PETRÓPOLIS**

**2026**

# FICHA CATALOGRÁFICA

[Página reservada. A ficha catalográfica é elaborada pela biblioteca da instituição; substituir esta página pela ficha oficial na versão de depósito. Na versão impressa, a ficha costuma figurar no verso da folha de rosto: confirmar no manual do programa.]

Raphael Rodrigues Eiras

# **O QUE AS AVALIAÇÕES REVELAM SOBRE A NOTA**: decomposição por aspecto do sentimento em avaliações de hóspedes do Airbnb no Rio de Janeiro

Dissertação apresentada ao Centro de Engenharia e Computação da Universidade Católica de Petrópolis (UCP), como requisito parcial para obtenção do título de Mestre em Gestão de Sistemas de Engenharia.

________________________________________________

(Prof. Dr. Rodolfo Nicolay – orientador)

Nota: [a definir pela banca]

Aprovado em: [dia] de [mês] de [ano].

**BANCA EXAMINADORA:**

________________________________________________

([Nome completo, titulação e instituição a que pertence])

________________________________________________

([Nome completo, titulação e instituição a que pertence])

________________________________________________

([Nome completo, titulação e instituição a que pertence])

# RESUMO

As notas do Airbnb se concentram no topo da escala: no Rio de Janeiro, 32,4% dos anúncios têm nota 5,0. O que o texto das avaliações revela sobre a nota? Este trabalho decompõe a nota por aspecto e por queixa concreta com 995.072 avaliações do Inside Airbnb. O sentimento das sentenças é medido por dois modelos multilíngues, e a escolha do principal segue uma regra fixada antes da execução do segundo. Os aspectos vêm de tópicos obtidos com BERTopic e são validados com sentenças rotuladas, ponderadas pela população, com as subnotas oficiais, com um segundo método de tópicos e com um segundo anotador. Comodidades e limpeza respondem por 42% e 20% da variação explicada da nota global. As queixas de banheiro, ar-condicionado, sujeira e resposta do anfitrião se associam a quedas de 10 a 26 pontos no percentil da nota. Apenas limpeza, localização e custo-benefício atendem ao critério de confiança, e essa classificação é indicativa. Um índice sintético construído do texto não acrescenta poder explicativo à nota oficial. Os resultados são associações. A aplicação é um diagnóstico por anúncio, comparado ao bairro e ao tipo de acomodação.

Palavras-chave: análise de sentimento por aspecto; avaliações online; Airbnb; modelagem de tópicos; diagnóstico de anúncios.

# ABSTRACT

Ratings on Airbnb are concentrated at the top of the scale: in Rio de Janeiro, 32.4% of listings have a 5.0 rating. What does the text of the reviews reveal about the rating? This study decomposes the rating by aspect and by specific complaint using 995,072 reviews from Inside Airbnb. Sentence-level sentiment is measured by two multilingual models, and the choice of the main model follows a rule fixed before the second model was run. Aspects come from topics obtained with BERTopic and are validated with labeled sentences weighted by the population, with the official subscores, with a second topic method and with a second annotator. Amenities and cleanliness account for 42% and 20% of the explained variation of the overall rating. Complaints about the bathroom, air conditioning, dirt and host response are associated with drops of 10 to 26 points in the rating percentile. Only cleanliness, location and value meet the confidence criterion, and this classification is indicative. A synthetic index built from the text adds no explanatory power to the official rating. The results are associations. The application is a listing-level diagnosis compared with the neighborhood and the type of accommodation.

Keywords: aspect-based sentiment analysis; online reviews; Airbnb; topic modeling; listing diagnosis.

# LISTA DE FIGURAS

Figura 1 – Etapas do estudo: da base do Inside Airbnb à validação e às análises.................. 19

Figura 2 – Parcela do $R^2$ da nota global atribuída a cada aspecto nos modelos A e B (decomposição LMG), com a classificação do aspecto........................................................ 33

Figura 3 – Diferença associada no percentil da nota, em pontos de percentil, para as queixas e os elogios das Tabelas 10 e 11, com intervalo de 95%. ....................................................... 37

Figura 4 – Relatório de diagnóstico de um anúncio de nota baixa (exemplo anonimizado; parte superior do relatório). ................................................................................................... 40

Figura 5 – Distribuição da nota oficial e do índice sintético (modelo A) nos 22.564 anúncios com índice. ............................................................................................................................ 44

Figura 6 – Relatório de diagnóstico de um anúncio de nota alta (exemplo anonimizado; parte superior)................................................................................................................................. 61

Figura 7 – Relatório de diagnóstico de um anúncio de nota alta (exemplo anonimizado; parte inferior)................................................................................................................................. 62

Figura 8 – Relatório de diagnóstico de um anúncio de nota baixa (exemplo anonimizado; parte superior)........................................................................................................................ 63

Figura 9 – Relatório de diagnóstico de um anúncio de nota baixa (exemplo anonimizado; parte inferior)......................................................................................................................... 64

Figura 10 – Relatório de diagnóstico de um anúncio com poucas avaliações (exemplo anonimizado; parte superior)................................................................................................ 65

Figura 11 – Relatório de diagnóstico de um anúncio com poucas avaliações (exemplo anonimizado; parte inferior). ................................................................................................ 66

# LISTA DE TABELAS

Tabela 1 – Participação dos aspectos nas sentenças e anúncios com perfil disponível............24
Tabela 2 – Sentimento: desempenho dos modelos A e B nas 297 sentenças rotuladas. ..........26
Tabela 3 – Precisão da atribuição de aspecto, por aspecto previsto (27 sentenças rotuladas em cada).............................................................................................................................27
Tabela 4 – Correlação entre o sentimento do aspecto e a subnota oficial correspondente, no nível do anúncio. ...................................................................................................................28
Tabela 5 – Checagem com LDA: correlação do perfil, validade de construto e parcela do $R^2$ da nota global. ..................................................................................................................30
Tabela 6 – Classificação indicativa dos aspectos: precisão de atribuição com intervalo de Wilson, precisão com os dois anotadores e correlação com a subnota. .................................31
Tabela 7 – Parcela do $R^2$ da nota global atribuída a cada aspecto (decomposição LMG). ......32
Tabela 8 – Decomposição LMG de cada subnota: parcela do aspecto correspondente...........34
Tabela 9 – Parcela do $R^2$ da nota global por subaspecto de comodidades, com a regra de duas sentenças (regra do estudo) e com uma sentença (sensibilidade)...........................................35
Tabela 10 – Queixas de maior peso e associação com o percentil da nota (modelo A)...........36
Tabela 11 – Elogios de maior peso e associação com o percentil da nota (modelo A)............37
Tabela 12 – Anúncios de nota 5,0 com e sem índice sintético (preço por diária em reais). ....44
Tabela 13 – Ganho de $R^2$ fora da amostra: média entre dobras e intervalo entre dobras (versão resumida; as 12 comparações estão no Apêndice D). ..........................................................45
Tabela 14 – Correlação de postos com o índice de ocupação residualizado, por faixa da nota oficial.........................................................................................................................46
Tabela 15 – Sequência datada do registro da regra e da execução do modelo B. ....................60
Tabela 16 – Principais consultas da busca bibliográfica. .......................................................67
Tabela 17 – Ganho de $R^2$ fora da amostra nos 12 escopos: média entre dobras e intervalo entre dobras. ..........................................................................................................................68

# LISTA DE ABREVIATURAS E SIGLAS

| | |
|---|---|
| **ABSA** | Aspect-Based Sentiment Analysis (análise de sentimento por aspecto) |
| **AUC** | Area Under the Curve (área sob a curva ROC) |
| **BERT** | Bidirectional Encoder Representations from Transformers |
| **BERTopic** | modelagem de tópicos baseada em representações do BERT |
| **BH** | correção de Benjamini e Hochberg para comparações múltiplas |
| **CAPES** | Coordenação de Aperfeiçoamento de Pessoal de Nível Superior |
| **CC BY** | licença Creative Commons Atribuição |
| **CPU** | Central Processing Unit (unidade central de processamento) |
| **GBM** | Gradient Boosting Machine (modelo de árvores com gradiente) |
| **GPU** | Graphics Processing Unit (unidade de processamento gráfico) |
| **HC3** | estimador de variância robusta à heterocedasticidade, tipo 3 |
| **HDBSCAN** | Hierarchical Density-Based Spatial Clustering of Applications with Noise |
| **HTML** | HyperText Markup Language |
| **IC** | intervalo de confiança |
| **LDA** | Latent Dirichlet Allocation (alocação latente de Dirichlet) |
| **LGPD** | Lei Geral de Proteção de Dados Pessoais |
| **LLM** | Large Language Model (grande modelo de linguagem) |
| **LMG** | decomposição de Lindeman, Merenda e Gold (média de Shapley do $R^2$) |
| **PLN** | processamento de linguagem natural |
| **PPG** | programa de pós-graduação |
| **UCP** | Universidade Católica de Petrópolis |
| **UMAP** | Uniform Manifold Approximation and Projection |
| **URL** | Uniform Resource Locator (endereço eletrônico) |
| **UTC** | Tempo Universal Coordenado |

# SUMÁRIO

INTRODUÇÃO ........ 11
1 REFERENCIAL TEÓRICO ........ 14
1.1 FORMAÇÃO DA SATISFAÇÃO E TEORIA DOS TRÊS FATORES ........ 14
1.2 AVALIAÇÕES ONLINE: COMPRESSÃO DAS NOTAS E VIESES DE RELATO . 14
1.3 AS AVALIAÇÕES DO AIRBNB E O SEU CONTEÚDO ........ 15
1.4 DETERMINANTES DE PREÇO E DE REPUTAÇÃO ........ 16
1.5 ANÁLISE DE SENTIMENTO POR ASPECTO E MODELOS DE LINGUAGEM ... 16
1.6 MODELAGEM DE TÓPICOS ........ 17
1.7 VALIDAÇÃO, CONCORDÂNCIA E IMPORTÂNCIA RELATIVA ........ 17
1.8 BUSCA BIBLIOGRÁFICA ........ 18
1.9 LACUNA ........ 18
2 DADOS E MÉTODO ........ 19
2.1 BASE E RECORTE ........ 19
2.2 ASPECTOS ÉTICOS, AMBIENTE DE EXECUÇÃO E DISPONIBILIDADE ........ 20
2.3 O QUE A BASE PERMITE MEDIR ........ 21
2.4 MEDIÇÃO DO SENTIMENTO ........ 22
2.5 TÓPICOS E ASPECTOS ........ 23
2.6 PERFIL POR ANÚNCIO ........ 24
2.7 DESENHO ANALÍTICO ........ 24
3 VALIDAÇÃO DA MEDIÇÃO ........ 26
3.1 EVIDÊNCIA DIRETA: FRASES ROTULADAS ........ 26
3.2 CONCORDÂNCIA ENTRE OS DOIS MODELOS ........ 27
3.3 REGRA DE ESCOLHA FIXADA DE ANTEMÃO E MODELO PRINCIPAL ........ 28
3.4 VALIDADE DE CONSTRUTO: CONCORDÂNCIA COM AS SUBNOTAS OFICIAIS ........ 28
3.5 CHECAGEM COM UM SEGUNDO MÉTODO DE TÓPICOS E COM UM SEGUNDO ANOTADOR ........ 29

3.6 CLASSIFICAÇÃO DOS ASPECTOS ........ 30

4 O QUE O TEXTO REVELA SOBRE A NOTA ........ 32

4.1 IMPORTÂNCIA DOS ASPECTOS ........ 32

4.2 QUEIXAS E ELOGIOS POR TÓPICO ........ 36

4.3 CUIDADOS DE INTERPRETAÇÃO ........ 38

5 APLICAÇÃO: DIAGNÓSTICO POR ANÚNCIO ........ 39

5.1 PRODUTO TÉCNICO ........ 40

6 UM ÍNDICE ÚNICO ACRESCENTA ALGO? ........ 43

6.1 CONSTRUÇÃO DO ÍNDICE ........ 43

6.2 COMPRESSÃO DA NOTA OFICIAL E REORDENAMENTO ........ 43

6.3 PODER EXPLICATIVO SOBRE OS ÍNDICES DE VOLUME ........ 44

6.4 MONOTONICIDADE E REORDENAMENTO ........ 46

6.5 SENSIBILIDADE ........ 46

6.6 COMO LER O RESULTADO ........ 47

7 DISCUSSÃO E LIMITAÇÕES ........ 48

7.1 OS RESULTADOS À LUZ DA LITERATURA ........ 48

7.2 IMPLICAÇÕES PARA ANFITRIÕES E EMPRESAS GESTORAS ........ 49

7.3 LIMITAÇÕES ........ 49

CONCLUSÕES ........ 52

REFERÊNCIAS ........ 54

APÊNDICE A – REGISTRO DATADO DA REGRA DE ESCOLHA DO MODELO PRINCIPAL ........ 60

APÊNDICE B – RELATÓRIOS DE DIAGNÓSTICO DOS TRÊS EXEMPLOS ........ 61

APÊNDICE C – ESTRATÉGIAS DE BUSCA BIBLIOGRÁFICA ........ 67

APÊNDICE D – GANHO DE $R^2$ FORA DA AMOSTRA: TABELA COMPLETA ........ 68

# INTRODUÇÃO

A nota média de um anúncio no Airbnb resume a opinião de dezenas ou centenas de hóspedes em um único número entre 1 e 5. Esse número é quase sempre alto. Em uma análise de anúncios da plataforma, Zervas, Proserpio e Byers (2021) encontraram que cerca de 95% dos anúncios exibem média de 4,5 ou 5 estrelas. A literatura sobre avaliações online descreve distribuições concentradas no topo da escala em outros mercados (Filippas; Horton; Golden, 2022; Hu; Zhang; Pavlou, 2009). Os dados deste estudo repetem o padrão: entre os 28.890 anúncios do Rio de Janeiro analisados, 9.373 (32,4%) têm nota exatamente igual a 5,0. Uma nota tão comprimida distingue mal os anúncios entre si e diz pouco sobre o que levou o hóspede a avaliar bem ou mal.

A informação que falta à nota está no texto. Ao escrever, o hóspede menciona a limpeza, a localização, a comunicação com o anfitrião, o estado do banheiro ou o ruído da rua, em linguagem própria, frequentemente em mais de um idioma. Esse conteúdo raramente é examinado de forma sistemática por quem administra o anúncio. Para o anfitrião ou para uma empresa gestora, a pergunta útil vai além da nota: em que aspecto o anúncio se afasta dos pares e que queixas se repetem.

Este trabalho investiga, com avaliações de hóspedes do Airbnb no Rio de Janeiro (Inside Airbnb), o que o texto das avaliações revela sobre a nota. A pergunta central desdobra-se em quatro perguntas específicas. A primeira trata da medição: para quais aspectos é possível medir, de forma confiável, o sentimento do hóspede a partir de milhões de frases em português, inglês e espanhol? A segunda trata da associação com a nota: quais aspectos e quais queixas e elogios concretos mais se associam à nota global e às subnotas oficiais? A terceira trata da aplicação: como transformar esse resultado em um diagnóstico por anúncio, comparado ao bairro e ao tipo de acomodação? A quarta, de caráter secundário, trata do índice único: um índice sintético construído a partir do texto acrescenta poder explicativo à nota oficial?

Comodidades e limpeza concentram a maior parte da variação explicada da nota global (42,5% e 19,6% no modelo principal). As queixas de maior peso, como banheiro, ar-condicionado, sujeira, cozinha, cama e resposta do anfitrião, se associam a quedas de 10 a 26 pontos no percentil da nota nos anúncios que as recebem. Apenas limpeza, localização e custo-benefício atendem ao critério de confiança da medição, e essa classificação é indicativa. Um índice sintético construído do texto não acrescenta poder explicativo à nota oficial.

**Objetivo geral.** Decompor, por aspecto e por tópico, o que o texto das avaliações de hóspedes do Airbnb no Rio de Janeiro revela sobre a nota dos anúncios, com medição validada e limites declarados, e disponibilizar o resultado como instrumento de diagnóstico por anúncio.

**Objetivos específicos.** Os objetivos seguem a ordem das perguntas. O primeiro é medir o sentimento por aspecto a partir das sentenças das avaliações e classificar os aspectos segundo a confiança da medida. O segundo é estimar a associação dos aspectos, das queixas e dos elogios com a nota global e com as subnotas oficiais. O terceiro é construir o diagnóstico por anúncio, comparado ao bairro e ao tipo de acomodação e formalizá-lo como produto técnico. O quarto é testar se um índice sintético construído a partir do texto acrescenta poder explicativo à nota oficial.

**Justificativa.** A nota concentrada no topo da escala orienta pouco quem administra um anúncio. Anfitriões e empresas gestoras precisam saber que queixas se repetem e quanto elas pesam e a plataforma não entrega essa leitura. Do ponto de vista científico, a literatura descreve a compressão das notas e os temas das avaliações, mas a validação explícita da medida por aspecto, com amostra ponderada pela população e mais de um anotador, é rara, sobretudo para avaliações em português. Do ponto de vista técnico, o estudo parte de dados públicos e produz um procedimento reprodutível, cujo resultado final é uma ferramenta de uso prático.

**Aderência à área.** O trabalho se insere no Programa de Mestrado Profissional em Gestão de Sistemas de Engenharia por tratar da gestão da qualidade de serviços e do apoio à decisão. Ele transforma dados não estruturados, as avaliações de hóspedes, em indicadores de qualidade percebida por aspecto, com método de validação e entrega um produto técnico para gestores de hospedagem. A dissertação vincula-se à área de concentração em Sistemas de Engenharia e à linha de pesquisa Modelagem Computacional do programa.

O estudo oferece quatro contribuições. A primeira é a validação da medição em camadas: frases rotuladas por um pesquisador e ponderadas pela população de sentenças, comparação de dois modelos de sentimento com regra de escolha fixada antes da execução do segundo, concordância com as subnotas oficiais, checagem com um segundo método de tópicos e rotulagem independente de 100 frases por um segundo anotador. A segunda é a decomposição da nota por aspecto e por tópico, que permite apontar queixas específicas. A terceira é o diagnóstico por anúncio, formalizado como produto técnico. A quarta é o resultado sobre o índice sintético, apresentado como resultado nulo, com suas duas leituras possíveis. Uma contribuição metodológica adicional resulta da verificação feita na base: os campos de ocupação e receita estimadas do Inside Airbnb são funções exatas do número de avaliações recentes e, por isso, só podem ser tratados como índices de volume de avaliações.

Todas as medidas são associações. O estudo não estima efeitos causais, não observa ocupação nem receita reais e se limita a um município, uma plataforma e uma coleta.

O texto está organizado em Introdução, sete seções numeradas, Conclusões e apêndices. A Seção 1 reúne a literatura e a Seção 2 descreve os dados e o método. A Seção 3 valida a medição, a Seção 4 traz a associação entre texto e nota e a Seção 5 a aplicação. A Seção 6 testa o índice sintético, a Seção 7 discute os resultados e as limitações e as Conclusões encerram o trabalho. Os apêndices reúnem o registro datado da regra de escolha do modelo, os três relatórios de diagnóstico, as estratégias de busca bibliográfica e a tabela completa dos ganhos de $R^2$.

# 1 REFERENCIAL TEÓRICO

## 1.1 FORMAÇÃO DA SATISFAÇÃO E TEORIA DOS TRÊS FATORES

A satisfação de um cliente com um serviço não resulta da soma simétrica do desempenho em cada atributo. A teoria dos três fatores da satisfação do cliente, derivada do modelo de qualidade atrativa e qualidade obrigatória de Kano, distingue os atributos conforme a relação entre o seu desempenho e a satisfação global (Füller; Matzler, 2008; Matzler; Sauerwein, 2002). Os fatores básicos são requisitos esperados: o mau desempenho gera insatisfação, mas o bom desempenho não eleva a satisfação além do esperado. Os fatores de desempenho têm relação aproximadamente proporcional, de modo que cada ganho de desempenho eleva a satisfação e cada perda a reduz. Os fatores de entusiasmo elevam a satisfação quando presentes e não geram insatisfação quando ausentes. Matzler e Sauerwein (2002) propõem identificar o tipo de fator a partir da assimetria entre o efeito do mau e o do bom desempenho do atributo sobre a satisfação geral, na análise de penalidade e recompensa. Füller e Matzler (2008) aplicam a teoria a clientes de turismo, segmentados por estilo de vida e Bi et al. (2020) examinam efeitos assimétricos do desempenho de atributos sobre a satisfação no setor hoteleiro.

A teoria interessa a este estudo como moldura de leitura. Nas avaliações do Airbnb, a nota é a medida de satisfação global e as queixas e os elogios do texto são sinais de mau e de bom desempenho em atributos concretos. Se há atributos que se comportam como fatores básicos, as queixas a eles associadas devem se relacionar a quedas maiores da nota do que os elogios correspondentes a altas. A comparação entre a diferença associada às queixas e a associada aos elogios (Seção 4) será retomada na Seção 7 como leitura descritiva à luz da teoria, sem teste formal de assimetria.

## 1.2 AVALIAÇÕES ONLINE: COMPRESSÃO DAS NOTAS E VIESES DE RELATO

Sistemas de avaliação produzem notas concentradas nos valores mais altos. Hu, Zhang e Pavlou (2009) descrevem a distribuição em forma de J das avaliações de produtos, com muitas notas máximas, algumas mínimas e poucas intermediárias e atribuem o padrão a vieses de quem decide avaliar. Dellarocas e Wood (2008) mostram, com dados do eBay, que a propensão a relatar depende do resultado da transação, o que distorce a distribuição das avaliações públicas em relação à experiência efetivamente vivida. Filippas, Horton e Golden (2022) tratam a inflação de reputação, isto é, a elevação das notas ao longo do tempo, como fator que reduz o conteúdo informativo desses sistemas no longo prazo. O efeito das avaliações sobre as vendas de livros é documentado há tempo (Chevalier; Mayzlin, 2006) e as respostas das empresas às avaliações também alteram o que os clientes escrevem (Proserpio; Zervas, 2017).

Na psicometria, a tendência de um julgamento global contaminar os julgamentos específicos recebe o nome de efeito halo (Thorndike, 1920). A noção importa para este estudo porque as subnotas oficiais do Airbnb (limpeza, localização, check-in e outras) são muito correlacionadas entre si. A correlação entre o sentimento de um aspecto e a sua subnota precisa, por isso, ser lida à luz desse efeito.

## 1.3 AS AVALIAÇÕES DO AIRBNB E O SEU CONTEÚDO

No Airbnb, Zervas, Proserpio e Byers (2021) reportam que a grande maioria dos anúncios tem média de 4,5 ou 5 estrelas, valores mais altos que os de hotéis e pousadas listados no TripAdvisor. O sistema é bilateral, pois anfitrião e hóspede avaliam um ao outro. Fradkin, Grewal e Holtz (2021) realizaram um experimento na plataforma em que o feedback ficava oculto até que as duas partes avaliassem e observaram menos retaliação e reciprocidade nas avaliações e, em consequência, notas mais baixas. Bridges e Vásquez (2016) analisam a linguagem das avaliações e concluem que elas recorrem a um conjunto restrito de recursos linguísticos, o que estabelece uma norma de comentário muito positivo, embora experiências menos favoráveis possam ser sinalizadas por indícios mais sutis. Um trabalho com dados do Brasil e dos Estados Unidos compara o sentimento das avaliações do Airbnb, do Couchsurfing e do Booking.com e encontra avaliações consideravelmente mais positivas nas plataformas de economia compartilhada (Santos et al., 2020).

Diversos estudos aplicam mineração de texto às avaliações do Airbnb. Cheng e Jin (2019) concluem que localização, comodidades e anfitrião são os atributos que mais moldam a experiência do hóspede e que o preço não figura entre os determinantes principais. Luo e Tang (2019) adaptam a análise latente de aspectos e notas para identificar cinco aspectos (comunicação, experiência, localização, produto ou serviço e valor) e mostrar sua contribuição à nota numérica. Sutherland e Kiatkawsin (2020) extraem 43 tópicos de mais de um milhão de avaliações de Nova York com LDA, agrupados em avaliação geral do hóspede, atributos de localização, características dos imóveis, gestão do anúncio e qualidade do serviço do anfitrião. Outros estudos aplicam modelagem de tópicos ao tema. Ding et al. (2020) empregam modelagem estrutural de tópicos para explorar atributos de qualidade percebida do serviço e Ding et al. (2021) combinam tópicos não supervisionados e supervisionados para identificar fontes de satisfação e de insatisfação. Zhang (2019) examina os tópicos das avaliações e o seu impacto no desempenho do anúncio, Cavique et al. (2022) usam mineração de texto para examinar tendências de satisfação do hóspede e Kiatkawsin, Sutherland e Kim (2020) comparam, com LDA, avaliações de Hong Kong e de Singapura. Este trabalho se soma a essa linha ao decompor a nota por aspecto em um mercado da América Latina, em três idiomas e com validação explícita da medida.

## 1.4 DETERMINANTES DE PREÇO E DE REPUTAÇÃO

Outra vertente da literatura procura explicar o preço e a demanda dos anúncios. Estudos de preço com regressão hedônica, quantílica e espacial mostram que localização, tamanho, comodidades e reputação online se associam ao preço (Chica-Olmo; González-Morales; Zafra-Gómez, 2020; Gyódi; Nawaro, 2021; Wang; Nicolau, 2017). Em Nova York, com dados de agosto de 2014 a setembro de 2016, a localização, sobretudo o acesso a empregos por transporte público, tem grande efeito sobre o preço por noite e sobre a receita mensal e a profissionalização do mercado direciona a receita a um grupo menor de anfitriões (Deboosere et al., 2019). Esses trabalhos tomam preço, ocupação ou receita como variáveis de interesse. Neste estudo o objeto é a nota e o texto que a acompanha. As medidas de volume entram como desfecho auxiliar, com a ressalva, estabelecida na Seção 2, de que os campos de ocupação e receita estimadas da base são funções do número de avaliações.

## 1.5 ANÁLISE DE SENTIMENTO POR ASPECTO E MODELOS DE LINGUAGEM

A análise de sentimento por aspecto (*aspect-based sentiment analysis*, ABSA) consiste em identificar os aspectos de uma entidade mencionados no texto e o sentimento expresso sobre cada um (Liu, 2012). As tarefas compartilhadas do SemEval consolidaram a formulação e os conjuntos de dados da área (Pontiki et al., 2014; Pontiki et al., 2016) e levantamentos recentes organizam os métodos e os desafios (Schouten; Frasincar, 2016; Zhang et al., 2023). Os modelos atuais de processamento de linguagem natural (PLN) derivam do BERT (Devlin et al., 2019). Para corpora multilíngues como o desta pesquisa, empregam-se modelos multilíngues como o XLM-T, treinado em mensagens de uma rede social em vários idiomas (Barbieri; Espinosa Anke; Camacho-Collados, 2022). Para o português, existem modelos específicos, como o BERTimbau (Souza, 2020) e trabalhos de mineração de opinião sobre avaliações em português (Freitas; Vieira, 2013). Estudos de 2020 em diante aplicam a análise por aspecto à hospedagem e ao turismo. Vassilikopoulou, Kamenidou e Priporas (2022) analisam avaliações negativas do Airbnb por aspecto. Suryabrata, Warnars e Muyeba (2026) comparam modelos de transformadores multilíngues em avaliações de hotéis de Jacarta. Trabalhos recentes avaliam grandes modelos de linguagem (LLM) na mesma tarefa, em avaliações de turismo (Xu et al., 2026) e de hotéis de Chipre (Giritli; Erensel; Öztüren, 2026). Os LLM ampliam o repertório de métodos, mas exigem custo de inferência e controle de versão que um corpus de 1,5 milhão de sentenças torna relevantes. Este estudo usa classificadores de sentimento de porte menor, executáveis em processador comum e dedica a validação a medir o que eles acertam. A busca bibliográfica que sustenta esta revisão é descrita no fim da seção.

## 1.6 MODELAGEM DE TÓPICOS

O LDA (Blei; Ng; Jordan, 2003) é o método clássico de modelagem de tópicos probabilística. O BERTopic (Grootendorst, 2022) agrupa representações vetoriais de sentenças (Reimers; Gurevych, 2019; Reimers; Gurevych, 2020), após redução de dimensão por UMAP (McInnes; Healy; Melville, 2018) e agrupamento por densidade (McInnes; Healy; Astels, 2017) e descreve cada grupo por termos de maior peso. O BERTopic já foi aplicado a avaliações do Airbnb e de hotéis em estudo sobre satisfação e confiança nas transações (Rey-Moreno; Sánchez-Franco; Rey-Tienda, 2023). A coerência $C_v$ (Röder; Both; Hinneburg, 2015) é a medida usual para comparar a qualidade interpretável dos tópicos e neste estudo é empregada apenas de forma descritiva.

## 1.7 VALIDAÇÃO, CONCORDÂNCIA E IMPORTÂNCIA RELATIVA

A concordância entre avaliadores é medida pelo coeficiente kappa (Cohen, 1960), em sua versão ponderada quando as categorias são ordenadas (Cohen, 1968) e sua interpretação segue faixas convencionais (Landis; Koch, 1977), com as ressalvas discutidas em McHugh (2012). Quando a amostra rotulada é estratificada e se deseja estimar a medida na população, cada observação recebe o peso do seu estrato e o tamanho efetivo da amostra ponderada, descrito por Kish (1992), indica a precisão efetiva. A incerteza é estimada por *bootstrap* (Efron, 1979). A confiabilidade de uma medida obtida de duas metades dos dados é ajustada pela fórmula de Spearman-Brown (Brown, 1910; Spearman, 1910). A importância relativa de preditores correlacionados é decomposta pelo método LMG, equivalente à média de Shapley do $R^2$ (Grömping, 2006; Grömping, 2007; Lindeman; Merenda; Gold, 1980). A correção de

Benjamini e Hochberg (BH) (Benjamini; Hochberg, 1995) controla a taxa de falsas descobertas em comparações múltiplas e o encolhimento bayesiano empírico (Efron; Morris, 1975) fundamenta a opção de ponderar a média de anúncios com poucas avaliações em direção à média global.

## 1.8 BUSCA BIBLIOGRÁFICA

A revisão de literatura foi apoiada em busca bibliográfica estruturada nas bases Scopus, Web of Science e Google Acadêmico, realizada entre maio e outubro de 2026. Foram combinados termos em português e inglês relacionados ao Airbnb, às avaliações de hóspedes, à análise de sentimento por aspecto e à modelagem de tópicos. Para investigar a produção sobre o recorte geográfico, realizaram-se consultas específicas com “Airbnb” e “Rio de Janeiro”, posteriormente combinadas com termos de análise textual. Outras consultas trataram da compressão das notas, da validação da análise por aspecto, da modelagem de tópicos e da teoria dos três fatores. Foram considerados artigos, dissertações e teses, sem restrição de período de publicação, selecionando-se trabalhos pertinentes às perguntas da pesquisa e aos métodos empregados. Excluíram-se duplicatas e estudos sem relação direta com o escopo. A busca foi complementada pelo exame das referências e das citações dos trabalhos selecionados. O Apêndice C lista as principais consultas.

## 1.9 LACUNA

A literatura revisada documenta a compressão das notas, descreve os temas das avaliações do Airbnb e aplica modelos de linguagem à análise por aspecto. Nas bases, datas e estratégias de busca descritas, não foram identificados estudos que reunissem os quatro elementos seguintes, que este trabalho reúne. O primeiro é a validação explícita da medida por aspecto, com amostra ponderada pela população e com mais de um anotador. O segundo é a comparação entre dois modelos de sentimento com regra de escolha fixada de antemão. O terceiro é a decomposição da nota global por aspecto e por tópico em um corpus multilíngue de um mercado brasileiro. O quarto é uma pergunta: um índice sintético construído a partir do texto acrescenta poder explicativo à nota oficial?

Nas consultas específicas com “Airbnb” e “Rio de Janeiro”, não foram identificados estudos de análise de sentimento por aspecto sobre avaliações de hospedagem da cidade. A afirmação vale para as bases, datas e estratégias descritas e não exclui a existência de estudos fora delas.

# 2 DADOS E MÉTODO

Este capítulo apresenta a base, delimita o que ela permite medir e descreve como o texto das avaliações é convertido em medidas por aspecto. A validação dessas medidas é tratada na Seção 3. As análises que as utilizam estão nas Seções 4 a 6. A Figura 1 resume as etapas do estudo.

Figura 1 – Etapas do estudo: da base do Inside Airbnb à validação e às análises.

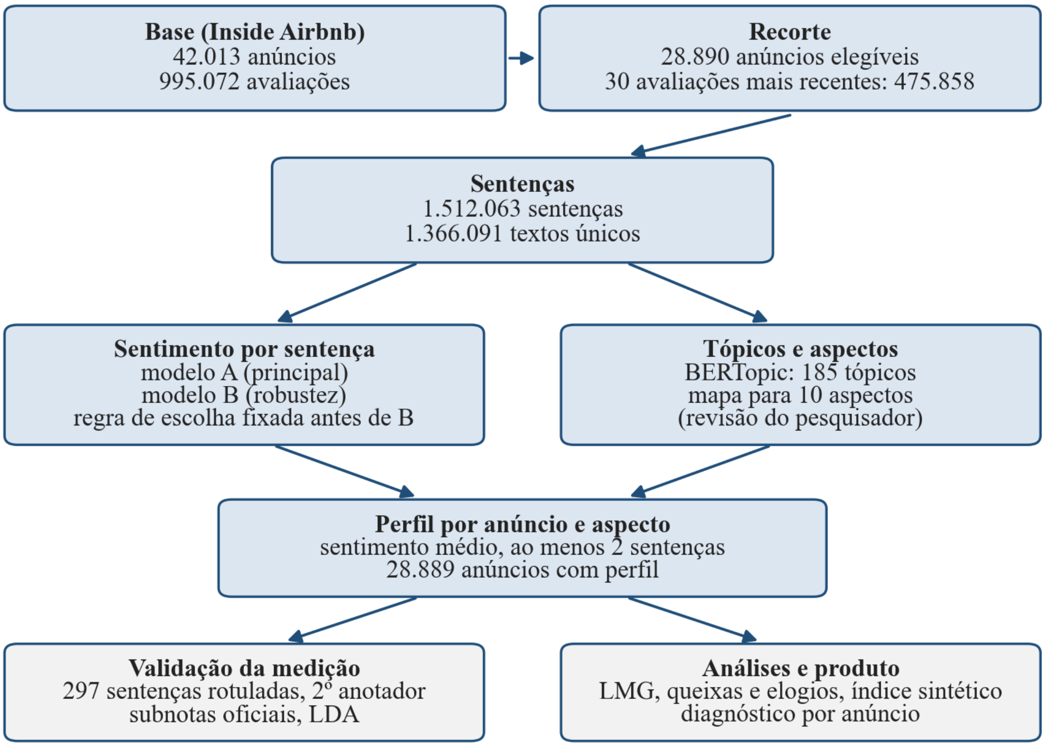
Base (Inside Airbnb)
42.013 anúncios
995.072 avaliações
Recorte
28.890 anúncios elegíveis
30 avaliações mais recentes: 475.858
Sentenças
1.512.063 sentenças
1.366.091 textos únicos
Sentimento por sentença
modelo A (principal)
modelo B (robustez)
regra de escolha fixada antes de B
Tópicos e aspectos
BERTopic: 185 tópicos
mapa para 10 aspectos
(revisão do pesquisador)
Perfil por anúncio e aspecto
sentimento médio, ao menos 2 sentenças
28.889 anúncios com perfil
Validação da medição
297 sentenças rotuladas, 2º anotador
subnotas oficiais, LDA
Análises e produto
LMG, queixas e elogios, índice sintético
diagnóstico por anúncio

Fonte: Elaborada pelo autor.

## 2.1 BASE E RECORTE

A base provém do projeto Inside Airbnb (Inside Airbnb, 2026) e reúne 42.013 anúncios do Rio de Janeiro e 995.072 avaliações textuais. Entre os anúncios, 33.140 possuem nota global e as seis subnotas oficiais (limpeza, localização, check-in, comunicação, custo-benefício e precisão do anúncio). Foram considerados elegíveis os que têm nota maior que zero e ao menos duas avaliações, o que resulta em 28.890 anúncios.

O custo computacional da inferência levou a um recorte: o sentimento foi calculado sobre as 30 avaliações mais recentes de cada anúncio. O recorte contém 475.858 avaliações, depois da remoção de uma avaliação automática e de 311 duplicatas. O limite atinge 32% dos anúncios elegíveis (9.266 anúncios têm mais avaliações do que o teto). As avaliações foram divididas em sentenças, o que produziu 1.512.063 unidades, das quais 1.366.091 são textos únicos, com média de 3,18 sentenças por avaliação e 12,4 *tokens* por sentença. O idioma foi detectado por avaliação: português (66,2%), inglês (15,5%), espanhol (14,2%), francês (2,4%), alemão (1,1%) e italiano (0,3%). O corpus não foi separado por idioma. Os dois modelos de sentimento adotados são multilíngues.

A nota oficial é fortemente comprimida no topo da escala. Entre os 28.890 anúncios elegíveis, 9.373 (32,4%) têm nota exatamente igual a 5,0.

## 2.2 ASPECTOS ÉTICOS, AMBIENTE DE EXECUÇÃO E DISPONIBILIDADE

Os dados são públicos. O Inside Airbnb os disponibiliza em seu sítio sob a licença Creative Commons Atribuição 4.0 Internacional (CC BY 4.0), conforme consulta feita em 15 de outubro de 2026 e a fonte é citada nas referências. A coleta usada é a de 19 a 21 de março de 2025 e as avaliações vão de junho de 2010 a março de 2025.

As avaliações são textos livres escritos por pessoas e podem conter nomes e outras informações pessoais. O tratamento seguiu a Lei Geral de Proteção de Dados Pessoais (LGPD, Lei n. 13.709, de 2018) com as seguintes medidas. Os dados foram usados apenas para a finalidade acadêmica deste estudo. O nome e o identificador do avaliador não entram nas análises (o identificador serve apenas para remover avaliações duplicadas). O primeiro nome do anfitrião é mascarado no texto antes da análise. Os resultados são apresentados de forma agregada, por aspecto, tópico e grupo de anúncios. Os relatórios de diagnóstico de exemplo são anonimizados: o identificador do anúncio é substituído por um código, o bairro é omitido e não há trechos de avaliações. As bases brutas e os dicionários de dados não são publicados no repositório, que contém apenas as 297 sentenças rotuladas e as 100 do segundo anotador usadas na validação, já com o primeiro nome do anfitrião mascarado. Esses textos são avaliações públicas, sob a licença CC BY 4.0 do Inside Airbnb. Como a pesquisa usa apenas informações de acesso público e de domínio público, ela não é registrada nem avaliada pelo sistema CEP/CONEP, conforme o art. 1º, parágrafo único, incisos II e III, da Resolução CNS n. 510, de 7 de abril de 2016.

A execução foi feita em um computador portátil com processador Intel Core i7-8565U (4 núcleos e 8 *threads*), cerca de 20 GB de memória e sistema Windows 10, sem GPU. As versões foram extraídas do ambiente virtual usado: Python 3.11.0, PyTorch 2.14.1 (CPU), Transformers 5.18.0, Sentence-Transformers 6.1.0, BERTopic 0.17.4, UMAP 0.5.12, HDBSCAN 0.8.44, Gensim 4.4.0, scikit-learn 1.9.1, statsmodels 0.15.0, pandas 3.0.6, NumPy

2.4.6 e SciPy 1.17.1. Os modelos foram obtidos do repositório Hugging Face e as revisões registradas no *cache* local são `f2f1202b` (modelo A), `8f6f4e3a` (modelo B) e `e8f8c211` (modelo de *embeddings*). A inferência de sentimento sobre os 1.366.091 textos únicos levou 633,6 minutos no modelo A e 757,1 minutos no modelo B e o ajuste do BERTopic levou 23,8 minutos. A semente aleatória é 42 em todas as etapas.

O código, a configuração e as tabelas de resultados agregados estão no repositório público do projeto (`https://github.com/reirasdev/airbnb-reviews-topic-modelling-code`), licenciado sob a GNU General Public License v3.0 (GPLv3).

## 2.3 O QUE A BASE PERMITE MEDIR

Os dados não trazem ocupação nem receita observadas. Os campos `estimated_occupancy_l365d` e `estimated_revenue_l365d` são estimativas calculadas pelo Inside Airbnb e, como a verificação deste estudo mostrou, correspondem a funções exatas de variáveis do próprio anúncio. A ocupação estimada é dada por $\min(255,\ R_{12} \times 2 \times \max(3,\ N_{\min}))$, em que $R_{12}$ é o número de avaliações nos últimos 12 meses e $N_{\min}$ é a estadia mínima. A fórmula reproduz o campo em 100,0% dos 42.013 anúncios. A receita estimada é igual ao preço multiplicado pela ocupação estimada em 100,0% dos 38.356 anúncios com preço informado. A ocupação é zero nos 12.979 anúncios sem avaliação nos últimos 12 meses (100,0% dos casos). A construção segue o modelo descrito pelo Inside Airbnb, que converte avaliações em reservas com taxa de avaliação de 50% e estadia média de três noites (Inside Airbnb, 2026). Na faixa de nota 5,0, a correlação de postos entre a ocupação estimada e o número de avaliações dos últimos 12 meses é 0,97.

Por esse motivo, os dois campos são tratados como índices de volume recente de avaliações. Os termos ocupação e receita só aparecem acompanhados dessa qualificação. Há uma consequência de desenho. Controlar uma regressão pelo número de avaliações dos últimos 12 meses equivale a controlar o próprio desfecho e por isso esse controle não é utilizado. O objeto central do estudo são a nota global, as subnotas e o texto das avaliações. O volume de avaliações entra como desfecho auxiliar em três formas: o índice de ocupação, o índice de receita (em logaritmo) e o número de avaliações dos últimos 12 meses (em logaritmo), este último sem construção algébrica.

## 2.4 MEDIÇÃO DO SENTIMENTO

O sentimento de cada sentença é medido por dois modelos, porque a escolha de um único modelo poderia alterar as conclusões. O modelo A (`cardiffnlp/twitter-xlm-roberta-base-sentiment`) é um classificador multilíngue treinado em mensagens de uma rede social (Barbieri; Espinosa Anke; Camacho-Collados, 2022; Cardiff NLP, 2023), com três classes: negativo, neutro e positivo. Sua saída foi convertida em estrelas esperadas pela expressão $1 \cdot P(\text{neg}) + 3 \cdot P(\text{neu}) + 5 \cdot P(\text{pos})$. O modelo B (`nlptown/bert-base-multilingual-uncased-sentiment`) é um modelo multilíngue da família BERT (Devlin et al., 2019) ajustado a avaliações de produtos (NLP Town, 2025), com cinco classes que correspondem a 1 a 5 estrelas. As estrelas esperadas são $\Sigma_k\, k \cdot P(k)$.

A polaridade discreta de A é a mais provável entre as três classes. Em B, a polaridade é negativa quando a classe mais provável tem 1 ou 2 estrelas, neutra quando tem 3 e positiva quando tem 4 ou 5. Os modelos foram aplicados às mesmas 1.512.063 sentenças (1.366.091 textos únicos), com a biblioteca Transformers (Wolf et al., 2020). As estrelas médias por texto único são 4,19 em A e 4,06 em B. A proporção de sentenças com quatro estrelas ou mais é 75,1% e 70,0%. As polaridades (negativa, neutra e positiva) distribuem-se em 6,8%, 14,3% e 78,9% em A e em 10,4%, 8,1% e 81,5% em B. Nos dois casos a maior parte das sentenças é positiva, o que reproduz no texto o viés de positividade das avaliações online (Bridges; Vásquez, 2016; Zervas; Proserpio; Byers, 2021).

As análises seguintes usam a ordenação do sentimento e não o seu nível absoluto. Importa, portanto, que as estrelas esperadas ordenem as sentenças como um leitor humano. A correlação de postos entre o rótulo manual (−1, 0, +1) e as estrelas esperadas é 0,64 em A e 0,63 em B.

Antes de executar o modelo B sobre o corpus, fixou-se a regra de escolha do modelo principal. O modelo B seria adotado como principal se o intervalo de 95% da diferença B menos A no kappa ponderado linear populacional, estimado por *bootstrap* estratificado (Efron, 1979), excluísse zero a favor de B. Caso contrário, o principal seria A. O registro datado da regra, anterior à execução de B, está no Apêndice A. O outro modelo é reportado em todos os resultados como análise de robustez. O kappa populacional é calculado sobre sentenças rotuladas manualmente e ponderadas pelo tamanho dos estratos de origem, como detalhado na Seção 3.

## 2.5 TÓPICOS E ASPECTOS

As sentenças foram agrupadas pelo BERTopic (Grootendorst, 2022), que combina *embeddings* de sentenças, redução de dimensão e agrupamento por densidade. Foram usados os *embeddings* multilíngues `paraphrase-multilingual-MiniLM-L12-v2` (Reimers; Gurevych, 2020), a redução por UMAP (McInnes; Healy; Melville, 2018) e o agrupamento por HDBSCAN (McInnes; Healy; Astels, 2017). O ajuste foi feito em uma amostra de 200.000 sentenças. O modelo foi aplicado às demais. Resultaram 185 tópicos. Na amostra de ajuste, 29,8% das sentenças foram classificadas como ruído; depois da reatribuição ao centroide mais próximo, o ruído caiu a 1,0% dos textos. Distinguem-se, assim, as sentenças com tópico direto (atribuídas pelo próprio BERTopic) e as reatribuídas, cuja atribuição é menos precisa (Seção 3). A coerência $C_V$ (Röder; Both; Hinneburg, 2015) média dos tópicos é 0,388.

Como método de checagem, ajustou-se também um modelo LDA (Blei; Ng; Jordan, 2003) com $K = 10$, valor que maximiza o $C_V$ em uma grade de 5 a 40 tópicos e produz $C_V$ médio de 0,625. Os valores de $C_V$ descrevem cada método e não os colocam em disputa. O LDA cumpre apenas o papel de verificar se os resultados por aspecto dependem do método de tópicos (Seção 3).

Cada tópico do BERTopic foi associado a um de dez aspectos: limpeza, localização, check-in, comunicação, custo-benefício, ruído e conforto, segurança, precisão do anúncio, comodidades e satisfação geral (este último reúne elogios e queixas genéricos). O código sugeriu o aspecto pela similaridade do tópico com termos iniciais multilíngues. A decisão final foi tomada por um pesquisador, tópico a tópico. Dos 185 tópicos, 105 mantiveram a sugestão automática e 80 foram alterados na revisão tópico a tópico, porque a sugestão automática colocava cerca de 46% dos tópicos em localização e tratava elogio genérico como aspecto. Em uma etapa seguinte, o pesquisador havia usado custo-benefício como depósito de elogios e queixas genéricos (51 tópicos, 15,7% das sentenças, dos quais apenas um tratava de preço). A revisão conjunta reclassificou 66 tópicos e criou o aspecto satisfação geral, que concentra 53 tópicos no mapa final e deixou custo-benefício com 1,1% das sentenças mapeadas. Os 66 tópicos reclassificados estão entre os 80 alterados. Cada sentença herda o aspecto do tópico a que pertence.

## 2.6 PERFIL POR ANÚNCIO

Para cada anúncio e cada aspecto, o perfil é a média do sentimento das sentenças do aspecto, calculada quando há ao menos duas sentenças. Ao todo, 28.889 anúncios têm perfil. A Tabela 1 mostra a participação de cada aspecto no corpus e o número de anúncios para os quais o perfil está disponível.

Tabela 1 – Participação dos aspectos nas sentenças e anúncios com perfil disponível.

| **Aspecto** | **Sentenças do corpus** | **Anúncios com o aspecto** |
|---|---:|---:|
| Satisfação geral | 27,1% | 26.378 |
| Comunicação | 19,2% | 25.418 |
| Localização | 18,3% | 24.101 |
| Comodidades | 13,0% | 22.272 |
| Limpeza | 7,6% | 19.095 |
| Precisão do anúncio | 5,2% | 16.638 |
| Ruído e conforto | 2,5% | 9.550 |
| Check-in | 2,3% | 8.919 |
| Segurança | 1,3% | 5.072 |
| Custo-benefício | 1,0% | 3.552 |
| Fora do perfil (`geral`) | 2,5% | – |

Fonte: Elaborada pelo autor.

## 2.7 DESENHO ANALÍTICO

Todas as análises estimam associações e não efeitos causais. O alvo principal é o percentil da nota global, escolhido porque a distribuição da nota se concentra no topo. O percentil é o posto da nota dividido pelo número de anúncios e os empates recebem o posto médio. Como 9.373 anúncios (32,4%) têm nota 5,0, todos eles compartilham o mesmo percentil, o de posto médio do grupo, igual a 83,8. A nota tem 143 valores distintos, de modo que há muitos empates em outros valores também e a escala de percentil herda essa limitação. A importância dos aspectos é decomposta pelo método LMG, equivalente à média de Shapley do $R^2$ sobre todas as ordens de entrada dos preditores (Grömping, 2006; Lindeman; Merenda; Gold, 1980). A decomposição é complementada por um modelo de árvores com gradiente (GBM), que aceita valores ausentes, com importância por permutação fora da amostra, por uma regressão logística para a nota igual ou superior a 4,9 e por coeficientes padronizados com erro padrão robusto HC3. Como verificação de sensibilidade, a decomposição é repetida com os tópicos diretos, com os anúncios de até 30 avaliações, com ao menos três aspectos observados e sem a satisfação geral entre os preditores e por segmento (tipo de acomodação, idioma predominante e os maiores bairros).

A análise decompõe o conteúdo da nota e não prevê a nota por um fator independente do texto. O texto e a nota vêm dos mesmos hóspedes: quem escreve a avaliação é quem atribui as estrelas e um sentimento alto em limpeza e uma nota alta têm origem comum na experiência vivida. Por isso a relação entre o sentimento por aspecto e a nota é uma associação entre duas expressões da mesma experiência e a interpretação como causa ou como previsão não se aplica. Há ainda um descompasso de período. O sentimento usa as 30 avaliações mais recentes do anúncio, enquanto a nota oficial resume as avaliações acumuladas e pode incluir hóspedes que não escreveram texto. Nos anúncios com até 30 avaliações os dois cobrem as mesmas estadias e a sensibilidade restrita a esse grupo (Seção 4) permite verificar se o descompasso altera a leitura.

A leitura por tópico compara o percentil da nota entre anúncios com e sem ao menos uma sentença negativa (ou positiva) no tópico, com controle do volume de avaliações e do número de sentenças. A menção negativa é lida da polaridade prevista pelo modelo, que tem erro. Na amostra rotulada, 62% das sentenças que o modelo A prevê como negativas são negativas segundo o pesquisador (52 de 84), de modo que uma única sentença negativa pode ser ruído de classificação. Por isso a análise é repetida exigindo ao menos duas sentenças negativas no tópico (Seção 4). Os testes de tópicos usam a correção de Benjamini e Hochberg (Benjamini; Hochberg, 1995) para comparações múltiplas.

O índice sintético é a média simples do sentimento dos aspectos disponíveis do anúncio, em estrelas de 1 a 5, com exigência de ao menos três aspectos específicos com evidência; a satisfação geral entra na média, mas não conta para o mínimo. Seu poder explicativo sobre os índices de volume é avaliado por modelos aninhados, com controles de volume total de avaliações (em logaritmo), preço (em logaritmo), tipo de acomodação e bairro. A validação é feita por validação cruzada com cinco dobras repetidas cinco vezes, com a mesma semente e as mesmas dobras em todos os modelos (Pedregosa et al., 2011).

Todos os números apresentados nos resultados foram extraídos de uma planilha única gerada pelo *pipeline* de análise, com carimbo de data e hora e conferidos um a um contra o texto.

# 3 VALIDAÇÃO DA MEDIÇÃO

Antes de usar o sentimento por aspecto para dizer algo sobre a nota, é preciso saber o quanto essa medida merece confiança. Esta seção reúne cinco tipos de evidência, da mais direta à mais indireta: frases rotuladas por um pesquisador, concordância entre os dois modelos, uma regra fixada de antemão para escolher o modelo principal, concordância com as subnotas oficiais e uma checagem com um segundo método de tópicos e com um segundo anotador. A seção termina com uma classificação dos aspectos, que as Seções 4 a 6 respeitam.

## 3.1 EVIDÊNCIA DIRETA: FRASES ROTULADAS

Um pesquisador rotulou, sem ver as classificações automáticas, 297 sentenças, indicando o sentimento (negativo, neutro ou positivo) e o aspecto principal. A amostra foi estratificada pelo aspecto e pela polaridade previstos pelo modelo A, com cerca de um terço de sentenças de cada polaridade por aspecto. Por isso a amostra é rica em sentenças difíceis: no corpus, 78,9% das sentenças são positivas segundo A. Cada métrica é lida de duas formas, na amostra e ponderada pela população, em que cada sentença pesa o tamanho do seu estrato original (aspecto e polaridade previstos por A). Os pesos são os mesmos para A e B. O tamanho efetivo da amostra ponderada é de apenas 72 sentenças. Os intervalos de confiança são, em consequência, largos.

A Tabela 2 apresenta as métricas de sentimento. Na amostra, o modelo B tem acurácia maior (63,3% contra 58,9%). Ponderando pela população, o modelo A é superior, com acurácia de 87,2% contra 84,9%, kappa de Cohen de 0,55 contra 0,43 e kappa ponderado linear de 0,66 contra 0,51 (estimativas populacionais).

Tabela 2 – Sentimento: desempenho dos modelos A e B nas 297 sentenças rotuladas.

| **Medida** | **A** | **B** |
|---|---:|---:|
| Acurácia na amostra | 58,9% | 63,3% |
| $F_1$ macro na amostra | 0,57 | 0,52 |
| Kappa de Cohen na amostra | 0,39 | 0,38 |
| Kappa ponderado linear na amostra | 0,48 | 0,50 |
| Correlação de postos, rótulo humano × estrelas esperadas | 0,64 | 0,63 |
| Acurácia (estimativa populacional) | 87,2% | 84,9% |
| Kappa de Cohen (estimativa populacional) | 0,55 | 0,43 |
| Kappa ponderado linear (estimativa populacional) | 0,66 | 0,51 |

Fonte: Elaborada pelo autor.

A discordância entre a amostra e a população tem explicação. A amostra foi construída a partir das previsões de A e concentra as sentenças em que A erra, sobretudo as que A chama de neutras. Nos dois modelos o erro mais comum é classificar como neutras sentenças que o pesquisador considera positivas: quando A prevê positivo, acerta em 94,9% dos casos, mas quando prevê neutro acerta em apenas 26,1%. O modelo B classifica mais sentenças como positivas (151 contra 98 das 297) e acerta menos nas previstas como neutras (16,9%) e negativas (51,7%, contra 61,9% de A). Por idioma, o português, que responde por 66% das avaliações, é o de menor acerto na amostra para o modelo A (51,8%, contra 61,4% de B); ponderada pela população, a acurácia em português é de 85,0% em A e de 82,7% em B.

Quanto ao aspecto, a atribuição não depende do modelo de sentimento. Acerta 54,5% na amostra (kappa 0,50). Ponderando apenas pela participação de cada aspecto no corpus, a estimativa é de 52%. Com os estratos de aspecto e polaridade, é de 66% (IC 95% por *bootstrap* de 57% a 75%), uma estimativa instável por causa de células com poucas sentenças e pesos muito desiguais. Na população, a acurácia de aspecto situa-se, portanto, entre 52% e 66%. O acerto é parecido nas três polaridades previstas (54%, 53% e 57%), porém muito diferente conforme o tópico: 65% nas sentenças de tópico direto (186) e 38% nas de tópico reatribuído por similaridade (111). A Tabela 3 mostra a precisão por aspecto, com 27 sentenças rotuladas em cada um. Com tão poucas sentenças, os intervalos de Wilson de 95% são largos (de cerca de 0,17 de meia-largura, apresentados na Tabela 6).

Tabela 3 – Precisão da atribuição de aspecto, por aspecto previsto (27 sentenças rotuladas em cada).

| **Aspecto previsto** | **Precisão** |
|---|---:|
| Custo-benefício | 74% |
| Localização | 74% |
| Precisão do anúncio | 70% |
| Limpeza | 67% |
| Check-in | 56% |
| Segurança | 48% |
| Comodidades | 44% |
| Comunicação | 44% |
| Ruído e conforto | 44% |
| Satisfação geral | 41% |
| Fora do perfil (`geral`) | 37% |

Fonte: Elaborada pelo autor.

## 3.2 CONCORDÂNCIA ENTRE OS DOIS MODELOS

Com a evidência direta limitada a 297 sentenças, o corpus inteiro permite comparar os modelos entre si. Nas 1.512.063 sentenças, a correlação de postos das estrelas esperadas de A e B é 0,61 (Pearson 0,66) e o kappa ponderado linear das polaridades é 0,45. Por idioma, o kappa é 0,40 em português, 0,54 em inglês e 0,54 em espanhol. No nível de anúncio e aspecto, a concordância é maior (correlação de postos de 0,69 e kappa de 0,55), porque a média de várias sentenças reduz o ruído. Ela varia de 0,46 (precisão do anúncio) a 0,86 (comodidades). Os dois modelos ordenam sentenças e anúncios de modo semelhante, mas não são intercambiáveis: das 1.192.861 sentenças que A classifica como positivas, B concorda em 1.087.384. Das 215.635 que A classifica como neutras, B chama 128.723 de positivas.

## 3.3 REGRA DE ESCOLHA FIXADA DE ANTEMÃO E MODELO PRINCIPAL

A regra de escolha foi registrada antes da execução do modelo B (Seção 2). A diferença B menos A no kappa ponderado linear populacional é de −0,141 (IC 95% de −0,272 a −0,012). O intervalo exclui zero, mas a favor de A e por isso o modelo principal é A. Na acurácia populacional a diferença é de −0,023 (IC de −0,078 a 0,021). Apenas em português, no kappa ponderado linear, a diferença é de −0,169 (IC de −0,323 a 0,011), intervalo que inclui zero. A escolha não é óbvia, porque B é melhor na amostra e A na população. A regra foi fixada de antemão justamente para não escolher o resultado mais conveniente. Daqui em diante o modelo principal é A. Os resultados de B acompanham cada análise como verificação de robustez.

## 3.4 VALIDADE DE CONSTRUTO: CONCORDÂNCIA COM AS SUBNOTAS OFICIAIS

A evidência indireta mais importante é a concordância com as subnotas dadas pelos próprios hóspedes. Para cada aspecto com subnota correspondente, correlacionou-se, no nível do anúncio, o sentimento do aspecto com a subnota e a satisfação geral com a nota global. Não há limiar de aprovação e interessam a força e o sinal da correlação. A Tabela 4 apresenta os resultados.

Tabela 4 – Correlação entre o sentimento do aspecto e a subnota oficial correspondente, no nível do anúncio.

| **Aspecto** | **Subnota** | ***n*** | **Spearman (A)** | **Pearson (A)** | **Spearman (B)** | **Pearson (B)** |
|---|---|---:|---:|---:|---:|---:|
| Limpeza | `cleanliness` | 19.095 | 0,45 | 0,58 | 0,42 | 0,52 |
| Localização | `location` | 24.101 | 0,24 | 0,31 | 0,24 | 0,27 |
| Check-in | `checkin` | 8.919 | 0,42 | 0,40 | 0,43 | 0,42 |
| Comunicação | `communication` | 25.418 | 0,30 | 0,44 | 0,30 | 0,43 |
| Custo-benefício | `value` | 3.552 | 0,24 | 0,26 | 0,22 | 0,23 |
| Precisão do anúncio | `accuracy` | 16.638 | 0,17 | 0,22 | 0,15 | 0,21 |
| Satisfação geral | nota global | 26.378 | 0,34 | 0,52 | 0,26 | 0,38 |

Fonte: Elaborada pelo autor.

Todos os coeficientes são positivos e significativos nos dois modelos. A concordância é moderada, de 0,17 a 0,45 em A e de 0,15 a 0,43 em B, sem um modelo sistematicamente melhor: B é um pouco maior em check-in e comunicação; A é maior em limpeza, custo-benefício e, sobretudo, satisfação geral. As correlações devem ser lidas à luz de que as subnotas também são comprimidas, com muitos empates em 5,0, o que as atenua. Cinco verificações de robustez complementam o resultado.

Na primeira, por volume de avaliações, a concordância dos anúncios com até 30 avaliações (em que o sentimento usa todas as avaliações) difere da dos anúncios com mais de 30 em no máximo 0,11 (check-in), sem padrão sistemático. A segunda trata da validade convergente e discriminante: a subnota correspondente é a mais correlacionada com o aspecto em 5 de 7 casos em A e em 3 de 7 em B. Nos demais casos fica em segundo ou terceiro lugar, porque as subnotas são muito correlacionadas entre si (efeito halo). Controlando a nota global por correlação parcial, resta informação específica em limpeza (0,17), localização (0,22), check-in (0,23) e comunicação (0,15). Em custo-benefício (0,08) e precisão do anúncio (0,04) resta quase nenhuma. Na terceira, a probabilidade de o sentimento ser maior nos anúncios de subnota 5 do que nos de subnota menor (AUC) vai de 0,57 a 0,69 em A e de 0,55 a 0,67 em B. Na quarta, as correlações são positivas em português, inglês e espanhol (de 0,13 a 0,45 em A) e em casa ou apartamento inteiro e quarto privado (de 0,17 a 0,46), o que sustenta o uso de modelos multilíngues. Na quinta, a confiabilidade das metades do sentimento por aspecto, com correção de Spearman-Brown, é baixa, de 0,10 a 0,40 em A e de 0,06 a 0,40 em B. As correlações corrigidas por essa atenuação (de 0,57 a 0,96 em A) são apenas ilustrativas, porque com confiabilidades tão baixas a correção é instável e corrige só o lado do sentimento.

## 3.5 CHECAGEM COM UM SEGUNDO MÉTODO DE TÓPICOS E COM UM SEGUNDO ANOTADOR

Para saber se os resultados por aspecto dependem do método de tópicos, cada sentença foi atribuída ao tópico dominante de um modelo LDA com 10 tópicos. O mapa dos tópicos do LDA para aspectos seguiu uma regra: o tópico recebe aspecto apenas quando a leitura das palavras de maior peso, o aspecto mais similar aos termos iniciais e uma margem de 0,05 entre o primeiro e o segundo aspecto coincidem; caso contrário, o tópico é considerado misto e fica fora do perfil. O mapa foi confirmado pelo pesquisador. Quatro dos dez tópicos receberam aspecto (comodidades, comunicação, satisfação geral e localização). Além disso, 55% das sentenças caem em tópicos mistos, de modo que o LDA permite checar apenas esses quatro aspectos. Entre as sentenças com aspecto nos dois métodos, 68,8% recebem o mesmo aspecto. A Tabela 5 compara os resultados.

Tabela 5 – Checagem com LDA: correlação do perfil, validade de construto e parcela do $R^2$ da nota global.

| **Aspecto** | **Perfil BERTopic × LDA** | **Subnota (LDA)** | **Subnota (BERTopic)** | **$R^2$ (LDA)** | **$R^2$ (BERTopic)** |
|---|---|---|---|---|---|
| Localização | 0,61 | 0,20 | 0,24 | 1,6% | 0,9% |
| Comunicação | 0,54 | 0,28 | 0,30 | 22,7% | 15,5% |
| Comodidades | 0,67 | – | – | 62,3% | 59,0% |
| Satisfação geral | 0,46 | 0,19 | 0,34 | 13,4% | 24,6% |

Fonte: Elaborada pelo autor.

O sinal da validade de construto se mantém nos três aspectos que têm subnota, com correlações do mesmo tamanho nos dois mais específicos e menores em satisfação geral. Na decomposição do $R^2$ da nota global, comodidades fica em primeiro nos dois métodos; satisfação geral e comunicação trocam de posição (correlação de postos de 0,80, com apenas quatro aspectos).

Um segundo anotador rotulou, sem ver as classificações do primeiro nem as dos modelos, 100 sentenças da amostra. A concordância no sentimento é de 91% (kappa de Cohen de 0,86, IC de 0,76 a 0,94; kappa ponderado linear de 0,88) e, no aspecto, de 67% (kappa de 0,62, IC de 0,51 a 0,73). Os anotadores concordam bem quanto ao sentimento e de forma moderada quanto ao aspecto. A concordância é baixa justamente em satisfação geral (19%, $n$ = 16, em geral confundida com o grupo `geral`) e em limpeza (33%, $n$ = 6, discutida na Seção 3.6) e alta em custo-benefício e precisão do anúncio (100% nos dois). A amostra é pequena e as concordâncias por aspecto se apoiam em 4 a 20 sentenças.

## 3.6 CLASSIFICAÇÃO DOS ASPECTOS

A partir das evidências, cada aspecto foi classificado por um critério descritivo, fixado antes das seções seguintes. O aspecto é considerado confiável quando a precisão de atribuição na amostra é de ao menos 0,60 e a correlação com a subnota correspondente é de ao menos 0,20 nos dois modelos. Nos demais casos pede cautela. Como a precisão de cada aspecto se apoia em 27 sentenças, a Tabela 6 acrescenta o intervalo de Wilson de 95% e a precisão obtida com os dois anotadores nas 100 sentenças em comum (9 por aspecto, 10 em `geral`). Na coluna *ambos*, a sentença conta como acerto quando os dois anotadores atribuem o aspecto do modelo. Na coluna *ao menos um*, quando ao menos um deles o atribui. A classificação resultante é indicativa.

Tabela 6 – Classificação indicativa dos aspectos: precisão de atribuição com intervalo de Wilson, precisão com os dois anotadores e correlação com a subnota.

| **Aspecto** | **Precisão [IC 95%]** | **Ambos (*n*=9)** | **Ao menos um (*n*=9)** | **Spearman (A)** | **Spearman (B)** | **Classificação indicativa** |
|---|---|---|---|---|---|---|
| Limpeza | 67% [48%; 81%] | 2 | 6 | 0,45 | 0,42 | confiável |
| Localização | 74% [55%; 87%] | 7 | 8 | 0,24 | 0,24 | confiável |
| Custo-benefício | 74% [55%; 87%] | 5 | 8 | 0,24 | 0,22 | confiável |
| Check-in | 56% [37%; 72%] | 3 | 4 | 0,42 | 0,43 | cautela |
| Comunicação | 44% [28%; 63%] | 2 | 3 | 0,30 | 0,30 | cautela |
| Precisão do anúncio | 70% [52%; 84%] | 5 | 5 | 0,17 | 0,15 | cautela |
| Satisfação geral | 41% [25%; 59%] | 1 | 4 | 0,34 | 0,26 | cautela |
| Ruído e conforto | 44% [28%; 63%] | 4 | 5 | – | – | cautela (sem subnota) |
| Segurança | 48% [31%; 66%] | 5 | 6 | – | – | cautela (sem subnota) |
| Comodidades | 44% [28%; 63%] | 3 | 6 | – | – | cautela (sem subnota) |

Fonte: Elaborada pelo autor.

Pela regra, são confiáveis limpeza, localização e custo-benefício e os sete restantes pedem cautela. A classificação é indicativa por três razões. A primeira é o tamanho da amostra: os intervalos de Wilson dos três aspectos confiáveis incluem 0,60, o limiar da regra. A segunda é a baixa concordância entre os anotadores em alguns aspectos. A terceira é o tamanho da amostra do segundo anotador, de 9 sentenças por aspecto.

Limpeza ilustra a tensão. Pela regra fixada, é confiável: precisão de 67% e correlação de 0,45 e 0,42 com a subnota nos dois modelos. Entre os dois anotadores, porém, a concordância no aspecto é de 33% (*n* = 6, intervalo de Wilson de 10% a 70%) nas sentenças que o primeiro anotador rotulou como limpeza. Entre as 9 sentenças que o modelo atribui a limpeza, os dois anotadores concordam com o modelo em 2 e ao menos um deles em 6. A regra não foi alterada depois de ver esses números e limpeza continua na classe confiável, mas a leitura dessa classe deve levar em conta que a base de rotulagem do aspecto é de poucas sentenças e que os anotadores divergem entre si.

Duas consequências valem para as seções seguintes. O aspecto de maior peso na Seção 4, comodidades, está entre os que pedem cautela, por ter atribuição imprecisa e nenhuma subnota que o valide. Por isso a leitura prática se apoia nos tópicos finos de queixa e elogio, cuja atribuição é melhor (65% de acerto de aspecto nos tópicos diretos). Os pesos por aspecto são apresentados como indicativos. Além disso, nenhum resultado por aspecto deve ser lido sem a classificação correspondente.

# 4 O QUE O TEXTO REVELA SOBRE A NOTA

Estabelecido quais medidas merecem confiança, esta seção apresenta o resultado central do estudo: o que o texto das avaliações revela sobre a nota que o anúncio recebe. A análise tem duas partes. A primeira mostra quais aspectos mais se associam à nota global e a cada subnota. A segunda identifica os tópicos finos que concentram as queixas e os elogios. Tudo é associação.

## 4.1 IMPORTÂNCIA DOS ASPECTOS

A análise usa os 28.889 anúncios com texto, inclusive os de pouco texto. Quando um aspecto não tem sentenças suficientes, seu sentimento é imputado pela média, o que evita exigir três aspectos por anúncio. O alvo é o percentil da nota, porque a nota é comprimida no topo. A decomposição LMG reparte o $R^2$ da regressão da nota global sobre o sentimento dos dez aspectos. O $R^2$ total é de 0,320 em A e 0,291 em B. A Tabela 7 mostra a parcela de cada aspecto.

Tabela 7 – Parcela do $R^2$ da nota global atribuída a cada aspecto (decomposição LMG).

| **Aspecto** | **Modelo A** | **Modelo B** | **Classificação (Seção 3)** |
|---|---:|---:|---|
| Comodidades | 42,5% | 47,8% | cautela |
| Limpeza | 19,6% | 18,8% | confiável |
| Satisfação geral | 17,5% | 9,9% | cautela |
| Comunicação | 11,3% | 12,6% | cautela |
| Check-in | 3,4% | 4,9% | cautela |
| Ruído e conforto | 3,1% | 3,6% | cautela |
| Precisão do anúncio | 1,7% | 1,1% | cautela |
| Localização | 0,6% | 0,8% | confiável |
| Custo-benefício | 0,3% | 0,4% | confiável |
| Segurança | 0,1% | 0,1% | cautela |

Fonte: Elaborada pelo autor.

A Figura 2 apresenta as mesmas parcelas, com a classificação de cada aspecto.

Figura 2 – Parcela do $R^2$ da nota global atribuída a cada aspecto nos modelos A e B (decomposição LMG), com a classificação do aspecto.

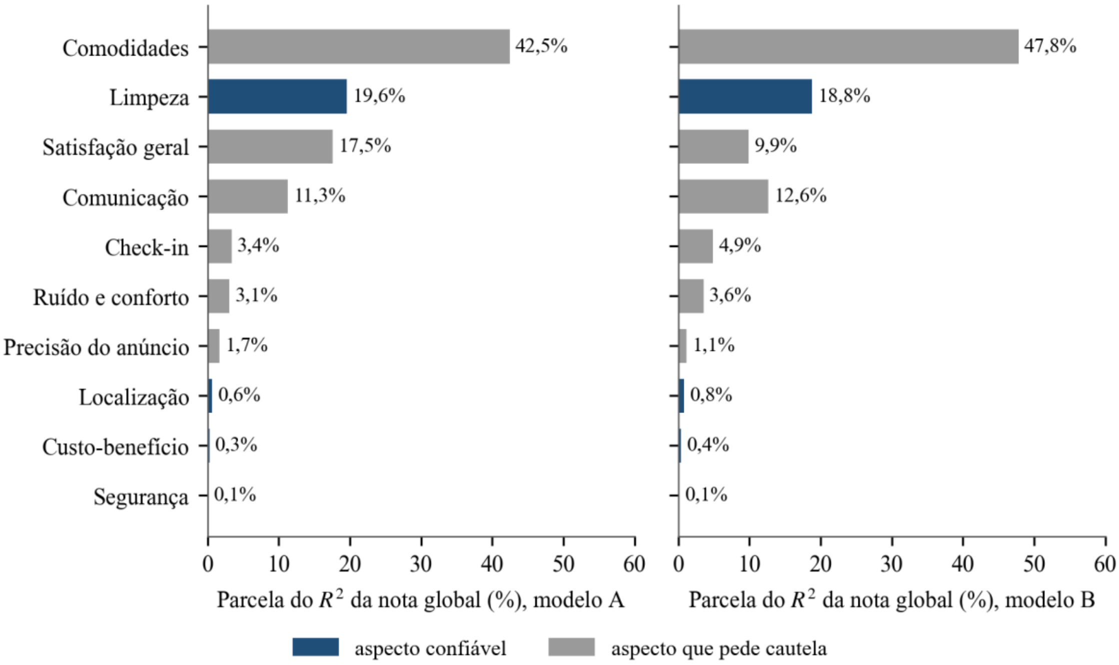

Fonte: Elaborada pelo autor.

Comodidades responde por 42,5% do $R^2$ em A e 47,8% em B, seguida de limpeza (19,6% e 18,8%). Satisfação geral e comunicação vêm depois. Localização, custo-benefício e segurança contribuem pouco para a nota global, embora a localização seja o aspecto que mais explica a sua própria subnota (Tabela 8). Uma hipótese, que os dados não testam, é que o hóspede avalia o local em separado e que a nota global reflete mais o que ele viveu dentro do imóvel. A ordem das parcelas é muito parecida entre os modelos (correlação de postos de 0,99). A diferença mais visível está na satisfação geral, que pesa menos em B. Valem as ressalvas da Seção 3: comodidades e satisfação geral estão na classe de cautela. A importância relativa de um aspecto mistura efeito e confiabilidade da medida, porque aspectos pouco citados, como segurança e custo-benefício, são medidos com mais erro e imputados na maioria dos anúncios.

A Tabela 8 mostra o mesmo exercício para cada subnota. O aspecto correspondente está entre os que mais a explicam; em localização ela é a primeira. Nas demais subnotas, comodidades tem a maior parcela.

Tabela 8 – Decomposição LMG de cada subnota: parcela do aspecto correspondente.

| Subnota | $R^2$ total (A) | Aspecto correspondente | Parcela (A) | Parcela (B) | Maior parcela (A) |
|---|---|---|---|---|---|
| `cleanliness` | 0,229 | Limpeza | 33,3% | 30,7% | Comodidades |
| `location` | 0,093 | Localização | 41,8% | 38,3% | Localização |
| `checkin` | 0,163 | Check-in | 11,9% | 14,5% | Comodidades |
| `communication` | 0,211 | Comunicação | 22,1% | 24,5% | Comodidades |
| `value` | 0,239 | Custo-benefício | 0,7% | 0,7% | Comodidades |
| `accuracy` | 0,258 | Precisão do anúncio | 2,1% | 1,4% | Comodidades |

Fonte: Elaborada pelo autor.

Modelos mais flexíveis dão a mesma leitura. Um modelo de árvores com gradiente (GBM), que aceita valores ausentes, tem $R^2$ fora da amostra de 0,442 em A e 0,416 em B, contra 0,388 e 0,363 de uma regressão linear com imputação. A queda de $R^2$ por permutação é maior em comodidades (0,233), limpeza (0,078) e satisfação geral (0,075) no modelo A. Na regressão logística para nota igual ou superior a 4,9, condição que 51% dos anúncios satisfazem (AUC fora da amostra de 0,815 em A e 0,802 em B), um desvio padrão a mais de sentimento multiplica as chances de nota alta por 2,46 em comodidades, 1,91 em limpeza, 1,47 em satisfação geral e 1,37 em comunicação (modelo A). No modelo B, os valores são 2,49, 1,65, 1,21 e 1,36.

O resultado é estável. Comodidades é o aspecto de maior parcela nos 11 segmentos analisados (tipo de acomodação, idioma predominante e os seis maiores bairros), tanto em A quanto em B, com parcelas de 37% a 43% em A e de 38% a 49% em B. Também ocupa o primeiro lugar nas cinco sensibilidades: todos os anúncios, apenas tópicos diretos, até 30 avaliações, ao menos três aspectos observados e sem a satisfação geral entre os preditores.

Nos 19.623 anúncios com até 30 avaliações, em que o sentimento e a nota cobrem as mesmas estadias (Seção 2), comodidades responde por 41,2% do $R^2$ em A e 46,8% em B e limpeza por 18,5% e 18,2%, valores próximos dos da amostra completa. O descompasso de período entre o texto e a nota não altera, portanto, a leitura.

A imputação pela média pode confundir a ausência de menção com opinião neutra. Na repetição da decomposição com um indicador de ausência para cada aspecto (o sentimento imputado e um indicador de presença, 20 preditores), o $R^2$ total sobe de 0,320 para 0,382 em A (de 0,291 para 0,358 em B), porque estar ou não entre os assuntos citados também informa sobre a nota. A ordem dos aspectos não muda. O sentimento de comodidades fica com 34,3% do $R^2$ em A e 37,3% em B e com 41,8% e 45,6% quando se soma o indicador de ausência do aspecto. O sentimento de limpeza fica com 15,6% e 14,5% e o de satisfação geral com 13,4% e 7,2%. A leitura da Tabela 7 não depende, portanto, da imputação pela média (aba `LMG_ausencia_v2`).

Comodidades é o aspecto de maior peso e também o mais heterogêneo. Para saber de onde vem o seu peso, os 33 tópicos mapeados a comodidades foram agrupados em sete subaspectos (banheiro e chuveiro, climatização, cozinha e utensílios, cama e colchão, internet, manutenção e reparos e demais comodidades), pela palavra de maior peso de cada tópico e a decomposição da nota global foi refeita com esses subaspectos no lugar do aspecto inteiro. A Tabela 9 traz o resultado em duas leituras. Na primeira, vale a regra do estudo: o subaspecto só existe no anúncio com ao menos duas sentenças. Como os subaspectos são mais raros (de 5% a 25% dos anúncios têm dado próprio e 62% em demais comodidades), a maior parte dos valores é imputada, o $R^2$ total cai e os subaspectos somam 25,2% em A e 29,8% em B. Limpeza (25,3% nos dois modelos) e satisfação geral em A (23,5%) passam à frente de qualquer subaspecto. Na segunda, com ao menos uma sentença, o $R^2$ total volta a 0,304 em A e 0,272 em B e a soma dos subaspectos é de 42,1% e 48,3%, praticamente a parcela do aspecto inteiro (42,5% e 47,8%).

Tabela 9 – Parcela do $R^2$ da nota global por subaspecto de comodidades, com a regra de duas sentenças (regra do estudo) e com uma sentença (sensibilidade).

| **Subaspecto** | **Anúncios com dado próprio** | **A (2 sentenças)** | **B (2 sentenças)** | **A (1 sentença)** | **B (1 sentença)** |
|---|---:|---:|---:|---:|---:|
| Banheiro e chuveiro | 25% | 6,1% | 6,8% | 9,9% | 10,5% |
| Climatização | 12% | 1,2% | 1,5% | 3,5% | 4,5% |
| Cozinha e utensílios | 20% | 3,9% | 4,7% | 6,6% | 7,5% |
| Cama e colchão | 10% | 1,7% | 2,0% | 4,6% | 5,6% |
| Internet | 5% | 0,7% | 0,7% | 1,5% | 1,7% |
| Manutenção e reparos | 9% | 3,5% | 4,0% | 7,8% | 8,2% |
| Demais comodidades | 62% | 8,1% | 10,1% | 8,1% | 10,4% |
| Soma dos sete subaspectos | – | 25,2% | 29,8% | 42,1% | 48,3% |
| $R^2$ total | – | 0,266 | 0,231 | 0,304 | 0,272 |

Fonte: Elaborada pelo autor.

A divisão muda a leitura de uma forma específica. O peso de comodidades vem do conjunto das instalações e não de um único componente: com a medida mais completa, banheiro e chuveiro é o maior subaspecto (9,9% em A e 10,5% em B), seguido de demais comodidades e de manutenção e reparos (7,8% e 8,2%), todos abaixo de limpeza (19,0% e 18,2%). Banheiro e chuveiro é também a queixa de maior peso entre os tópicos (Tabela 10). As demais queixas de instalações (ar-condicionado, cozinha, cama, internet e manutenção) têm parcelas menores como subaspectos e as duas leituras, por subaspecto e por tópico, se complementam. O primeiro lugar de comodidades como bloco depende de medi-lo com todas as sentenças; quando o aspecto é fatiado pela regra de duas sentenças, a imputação domina e a posição relativa de limpeza e de satisfação geral sobe. Os resultados dos subaspectos são, portanto, indicativos (abas `Mapa_comodidades_v2` e `LMG_comodidades_v2`).

## 4.2 QUEIXAS E ELOGIOS POR TÓPICO

A leitura prática está nos tópicos finos, cuja atribuição de aspecto é mais precisa. Para cada tópico, comparou-se o percentil da nota entre anúncios com e sem ao menos uma menção negativa (ou positiva) ao tópico, controlando o volume de avaliações e de sentenças. Foram testadas 68 queixas e 181 elogios com amostra suficiente, com correção de Benjamini e Hochberg. No sentido esperado, 56 queixas e 123 elogios têm $q < 0,05$. A Tabela 10 lista as queixas de maior peso, que combina o efeito com a prevalência, no modelo A.

Tabela 10 – Queixas de maior peso e associação com o percentil da nota (modelo A).

| **Tópico (palavras de maior peso)** | **Aspecto (classificação)** | **Anúncios com menção** | **Diferença associada (pontos de percentil da nota)** |
|---|---|---:|---:|
| banheiro, chuveiro, água, box | Comodidades (cautela) | 14% | −20,3 |
| condicionado, aire, acondicionado, calor | Comodidades (cautela) | 13% | −17,7 |
| sujo, limpeza, chão, *dirty* | Limpeza (confiável) | 7% | −26,4 |
| infelizmente, *leave*, *disappointed*, problemas | Satisfação geral (cautela) | 9% | −20,0 |
| cozinha, cozinhar, *kitchen*, *cocina* | Comodidades (cautela) | 7% | −19,1 |
| anfitrião, anfitriã, hóspedes, *host* | Comunicação (cautela) | 5% | −22,9 |
| barulho, *noise*, ruido, *noisy* | Ruído e conforto (cautela) | 11% | −9,7 |
| cheiro, mofo, forte, olor | Limpeza (confiável) | 5% | −21,8 |
| cama, *bed*, camas, casal | Comodidades (cautela) | 5% | −17,8 |
| dormir, cortina, luz, cortinas | Ruído e conforto (cautela) | 5% | −15,7 |
| reparos, precisa, manutenção, melhorias | Comodidades (cautela) | 3% | −21,5 |
| wifi, sinal, senha, único | Comodidades (cautela) | 3% | −19,5 |

Fonte: Elaborada pelo autor.

Destacam-se as queixas de instalações e manutenção (banheiro, ar-condicionado, cozinha, cama, *wi-fi* e reparos), de limpeza (sujeira e cheiro) e de resposta do anfitrião. Elas se associam a quedas de 10 a 26 pontos no percentil da nota nos anúncios que as recebem. Entre as 15 queixas de maior peso, 13 coincidem nos dois modelos, o que torna a lista robusta à escolha do modelo. As divergências são reparos, manutenção e repelente em A e *check-in* flexível e reserva em B. A Tabela 11 traz os elogios mais associados a notas altas no modelo A.

Tabela 11 – Elogios de maior peso e associação com o percentil da nota (modelo A).

| Tópico (palavras de maior peso) | Aspecto (classificação) | Anúncios com menção | Diferença associada (pontos de percentil da nota) |
|---|---|---:|---:|
| anfitriã, anfitrião, *host*, anfitriões | Comunicação (cautela) | 84% | +8,5 |
| rio, janeiro, río, *rock* | Satisfação geral (cautela) | 56% | +7,5 |
| casa, senti, sentimos, sentir | Satisfação geral (cautela) | 34% | +10,9 |
| voltaremos, voltar, esperamos, iremos | Satisfação geral (cautela) | 44% | +8,2 |
| agradeço, *gracias*, agradecer, atenção | Comunicação (cautela) | 31% | +5,7 |
| limpo, organizado, *limpio*, *clean* | Limpeza (confiável) | 34% | +4,8 |

Fonte: Elaborada pelo autor.

A Figura 3 mostra as diferenças associadas das Tabelas 10 e 11, com intervalos de 95% calculados pela mesma especificação (erro padrão robusto HC3).

Figura 3 – Diferença associada no percentil da nota, em pontos de percentil, para as queixas e os elogios das Tabelas 10 e 11, com intervalo de 95%.

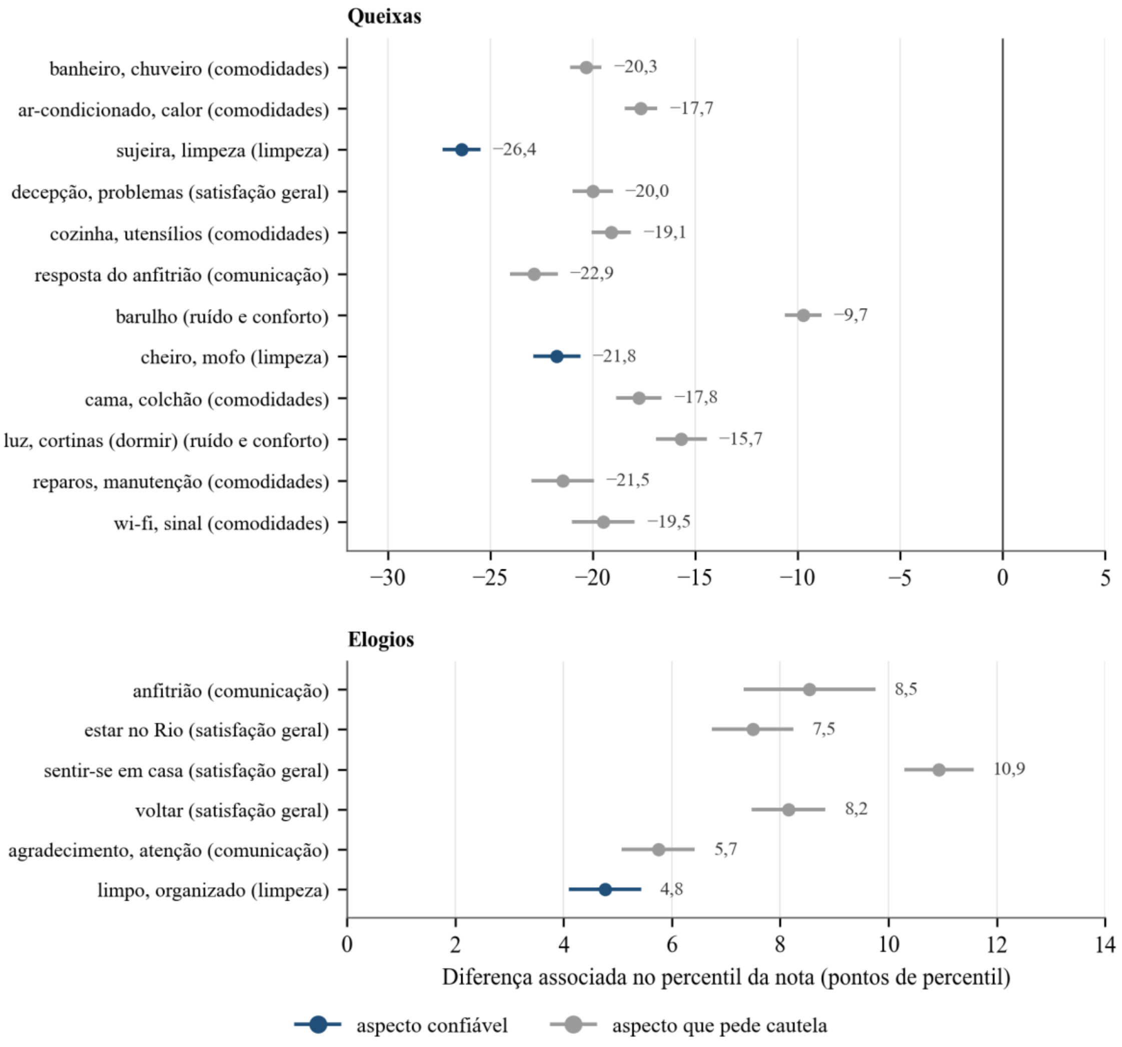

Fonte: Elaborada pelo autor.

Como a menção negativa vem de uma previsão que acerta 62% das vezes (Seção 2), a análise das queixas foi repetida exigindo ao menos duas sentenças negativas no tópico, com a mesma especificação, o mesmo piso de 100 anúncios com a menção e a mesma correção de Benjamini e Hochberg. A exigência reduz os anúncios com a menção (por exemplo, de 3.955 para 1.009 no tópico de banheiro) e, com o piso mantido, os tópicos testados caem de 68 para 13 em A. Das 15 queixas de maior peso em A, 11 seguem testáveis e as 11 mantêm o sinal e $q < 0{,}05$. As quatro restantes (reparos, *wi-fi*, um tópico de experiência geral e fechadura eletrônica) deixam de ser testáveis, com 52 a 86 anúncios com duas menções. Nas 11 testáveis, a diferença associada média passa de −18,9 para −20,9 pontos, com variação de −5,3 a +0,1 ponto por tópico. Em B, 10 das 15 seguem testáveis e a média passa de −20,0 para −23,2. Dez tópicos coincidem nas 15 queixas de maior peso dos dois modelos. Exigir duas menções não enfraquece as associações; elas ficam um pouco maiores, como seria de esperar se uma única sentença negativa isolada contivesse ruído de classificação (aba `Queixas_min2_v2`).

A queixa genérica (decepção e problemas) e os elogios genéricos (sentir-se em casa, voltar) pertencem à satisfação geral, aspecto que pede cautela e funcionam sobretudo como termômetro.

## 4.3 CUIDADOS DE INTERPRETAÇÃO

Os resultados não têm leitura causal. Um anúncio com queixa de banheiro tem nota menor e isso não permite afirmar que consertar o banheiro eleve a nota. A diferença associada apresentada é a diferença média, na cidade, entre anúncios com e sem a menção, controlada por volume. A atribuição de aspecto acerta entre 52% e 66% na população (Seção 3). A importância por aspecto fica abaixo da dos tópicos em confiabilidade, o que reforça a leitura por tópico.

# 5 APLICAÇÃO: DIAGNÓSTICO POR ANÚNCIO

Um anfitrião ou uma empresa gestora pode usar o resultado da Seção 4 por meio de uma ferramenta de diagnóstico, que gera, a pedido, o relatório de um único anúncio com quatro componentes.

O primeiro é o sentimento médio do anúncio em cada aspecto e a sua posição (percentil) entre os anúncios do mesmo bairro e do mesmo tipo de acomodação. Quando o bairro tem poucos anúncios, a comparação passa para o tipo de acomodação na cidade. O segundo componente é a evidência de cada aspecto. Aspectos com poucas sentenças recebem a marca de evidência baixa, sem rótulo de ponto forte ou de ponto de atenção, para que um número sustentado em duas frases não seja lido como diagnóstico. O terceiro componente reúne as queixas e os elogios recorrentes do anúncio, junto com a associação média, na cidade, desses tópicos com o percentil da nota (Seção 4). O quarto mostra a evolução do sentimento nas avaliações mais recentes. A ferramenta funciona também para anúncios novos: em vez de omitir um aspecto sem dados, marca a evidência como baixa.

Para a comparação foram construídas tabelas de referência com 66 grupos de bairro e tipo de acomodação que têm ao menos 30 anúncios e 3 grupos por tipo na cidade. Cada grupo traz a mediana e os quartis do sentimento por aspecto e da nota. O relatório respeita a classificação da Seção 3. Uma nota metodológica acompanha o documento e informa a precisão da atribuição por aspecto. Os aspectos que pedem cautela não devem orientar decisões isoladamente. Os aspectos classificados como confiáveis são limpeza, localização e custo-benefício.

A Figura 4 reproduz o relatório do exemplo de nota baixa e o Apêndice B traz os três relatórios. Foram gerados três exemplos anonimizados: um anúncio de nota alta, um de nota baixa e um com poucas avaliações. No de nota baixa, o relatório aponta comodidades e satisfação geral muito abaixo dos pares e destaca as queixas de banheiro e cozinha. No de poucas avaliações, a maior parte dos aspectos aparece com evidência baixa. O relatório indica onde investigar. Ele não prevê a nota do anúncio e não prescreve causas, porque as associações da Seção 4 são médias da cidade e não efeitos sobre um anúncio específico.

Figura 4 – Relatório de diagnóstico de um anúncio de nota baixa (exemplo anonimizado; parte superior do relatório).

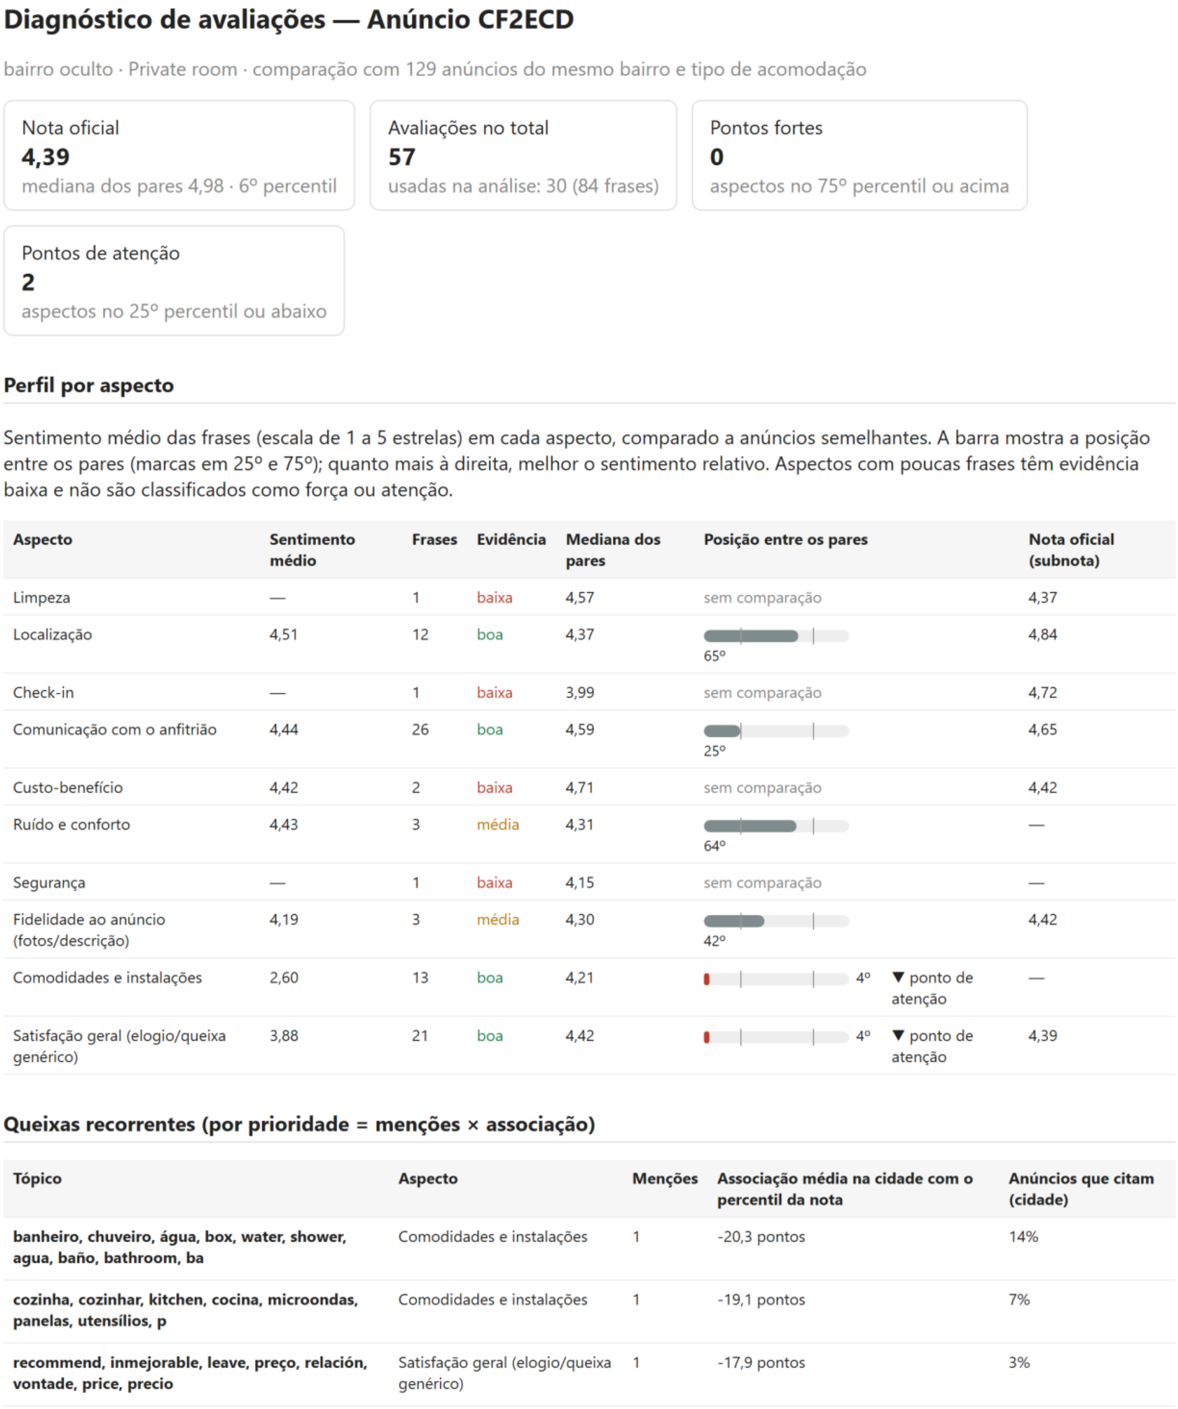

**Diagnóstico de avaliações — Anúncio CF2ECD**

bairro oculto · Private room · comparação com 129 anúncios do mesmo bairro e tipo de acomodação

Nota oficial
**4,39**
mediana dos pares 4,98 · 6º percentil

Avaliações no total
**57**
usadas na análise: 30 (84 frases)

Pontos fortes
**0**
aspectos no 75º percentil ou acima

Pontos de atenção
**2**
aspectos no 25º percentil ou abaixo

**Perfil por aspecto**

Sentimento médio das frases (escala de 1 a 5 estrelas) em cada aspecto, comparado a anúncios semelhantes. A barra mostra a posição entre os pares (marcas em 25º e 75º); quanto mais à direita, melhor o sentimento relativo. Aspectos com poucas frases têm evidência baixa e não são classificados como força ou atenção.

| Aspecto | Sentimento médio | Frases | Evidência | Mediana dos pares | Posição entre os pares | Nota oficial (subnota) |
|---|---|---|---|---|---|---|
| Limpeza | — | 1 | baixa | 4,57 | sem comparação | 4,37 |
| Localização | 4,51 | 12 | boa | 4,37 | 65º | 4,84 |
| Check-in | — | 1 | baixa | 3,99 | sem comparação | 4,72 |
| Comunicação com o anfitrião | 4,44 | 26 | boa | 4,59 | 25º | 4,65 |
| Custo-benefício | 4,42 | 2 | baixa | 4,71 | sem comparação | 4,42 |
| Ruído e conforto | 4,43 | 3 | média | 4,31 | 64º | — |
| Segurança | — | 1 | baixa | 4,15 | sem comparação | — |
| Fidelidade ao anúncio (fotos/descrição) | 4,19 | 3 | média | 4,30 | 42º | 4,42 |
| Comodidades e instalações | 2,60 | 13 | boa | 4,21 | 4º ▼ ponto de atenção | — |
| Satisfação geral (elogio/queixa genérico) | 3,88 | 21 | boa | 4,42 | 4º ▼ ponto de atenção | 4,39 |

**Queixas recorrentes (por prioridade = menções × associação)**

| Tópico | Aspecto | Menções | Associação média na cidade com o percentil da nota | Anúncios que citam (cidade) |
|---|---|---|---|---|
| **banheiro, chuveiro, água, box, water, shower, agua, baño, bathroom, ba** | Comodidades e instalações | 1 | -20,3 pontos | 14% |
| **cozinha, cozinhar, kitchen, cocina, microondas, panelas, utensílios, p** | Comodidades e instalações | 1 | -19,1 pontos | 7% |
| **recommend, inmejorable, leave, preço, relación, vontade, price, precio** | Satisfação geral (elogio/queixa genérico) | 1 | -17,9 pontos | 3% |

Fonte: Elaborada pelo autor.

## 5.1 PRODUTO TÉCNICO

A ferramenta é formalizada como produto técnico desta dissertação. A descrição abaixo segue os itens usuais de um produto técnico.

**Finalidade.** Gerar, a pedido, o relatório de diagnóstico de um único anúncio do Airbnb, que indica em que aspectos o anúncio se afasta dos pares do mesmo bairro e tipo de acomodação e que queixas e elogios se repetem nas suas avaliações.

**Público.** Anfitriões e empresas gestoras de imóveis por temporada.

**Entradas.** O identificador do anúncio e as tabelas produzidas pelo *pipeline* de análise: o perfil por aspecto de cada anúncio, as tabelas de referência por bairro e tipo, as associações dos tópicos com o percentil da nota e a classificação dos aspectos. O *pipeline* é executado antes, sobre os dados do Inside Airbnb.

**Saídas.** Um arquivo HTML autocontido com os quatro componentes descritos acima e uma nota metodológica com a precisão de atribuição por aspecto. Há uma versão anonimizada, sem identificador, sem bairro e sem trechos das avaliações, para uso em publicações.

**Como executar.** Com o *pipeline* já executado, o relatório de um anúncio é gerado com o comando `python diagnostico.py –id <identificador>`. A opção `–anonimizar` gera a versão anonimizada e a opção `–sem-frases` omite as frases de exemplo. A execução usa apenas as tabelas já geradas, em processador comum e sem GPU.

**Repositório e licença.** O código está no repositório público `https://github.com/reirasdev/airbnb-reviews-topic-modelling-code`, licenciado sob a GNU General Public License v3.0 (GPLv3).Os dados de origem estão sob a licença CC BY 4.0 do Inside Airbnb.

**Limites.** O relatório é descritivo. Ele não prevê a nota do anúncio nem prescreve causas, porque as associações são médias da cidade. Os aspectos que pedem cautela não devem orientar decisões isoladamente e aspectos com poucas sentenças recebem a marca de evidência baixa. Os resultados valem para o Rio de Janeiro e para a coleta de março de 2025 e as estimativas de anúncios com poucas avaliações são instáveis.

**Categoria e critérios da CAPES.** Na taxonomia geral de produtos técnicos e tecnológicos da CAPES (CAPES, 2019), a ferramenta se enquadra como software ou aplicativo (programa de computador). Esse enquadramento corresponde à categoria “Software/Aplicativo (Programa de computador)”, que o relatório do grupo de trabalho define como um conjunto de instruções a serem usadas por um computador para obter um determinado resultado, e que consta na Ficha de Avaliação da Área Interdisciplinar (Área 45) para o quadriênio 2025–2028. O produto consiste em um programa que utiliza as tabelas produzidas pelo estudo para gerar relatórios de diagnóstico por anúncio, destinados ao apoio à gestão de hospedagens. A aderência, critério obrigatório, decorre do vínculo com a área de concentração em Sistemas de Engenharia e com a linha de pesquisa Modelagem Computacional. A demanda é espontânea, pois o produto nasceu do problema descrito na Introdução, sem solicitação externa. A replicabilidade é possível, porque o código é aberto e os dados de origem são públicos. A inovação resulta da combinação de métodos já estabelecidos (classificadores de sentimento, modelagem de tópicos e decomposição da importância) em um diagnóstico por anúncio. O impacto é potencial.

**Avaliação de utilidade.** O produto não foi avaliado por anfitriões ou gestoras de imóveis. A avaliação por usuários fica como trabalho futuro.

# 6 UM ÍNDICE ÚNICO ACRESCENTA ALGO?

Com a decomposição da Seção 4 estabelecida, resta uma pergunta secundária: o que se ganha ao resumir o perfil de aspectos em um único número, um índice sintético que substitua a nota oficial? Um resultado nulo seria legítimo, porque a contribuição do estudo está na decomposição por aspecto e o índice apenas a submete a teste.

## 6.1 CONSTRUÇÃO DO ÍNDICE

O índice sintético, representado por $R_{\text{syn}}$, é a média simples do sentimento dos aspectos disponíveis do anúncio, em estrelas de 1 a 5, com exigência de ao menos três aspectos específicos com evidência. A satisfação geral entra na média e não conta para o mínimo. Há 22.564 anúncios com índice.

A especificação principal não aplica encolhimento bayesiano empírico com $m = 23$ (a mediana de avaliações) (Efron; Morris, 1975). A razão é teórica. O encolhimento aproxima da média global os anúncios com poucas avaliações e, com isso, correlaciona o índice com o volume de avaliações justamente onde a nota é 5,0. Os anúncios de nota 5,0 têm mediana de 9 avaliações, contra 31 nos demais. Entre eles, a correlação de postos do índice com o logaritmo do volume é de 0,50 com encolhimento e de −0,04 sem encolhimento (0,45 e 0,03 em B). Registra-se que essa decisão foi tomada depois de ver o resultado com encolhimento. Por isso as duas versões são reportadas (Seção 6.5).

## 6.2 COMPRESSÃO DA NOTA OFICIAL E REORDENAMENTO

A nota oficial concentra 22,8% dos anúncios com índice no valor 5,0. O valor mais frequente do índice sintético concentra 1,6% em A e 1,9% em B. A Figura 5 compara as duas distribuições na mesma amostra de 22.564 anúncios. A correlação de postos entre o índice e a nota oficial é 0,62 em A e 0,58 em B. Além disso, 61% (A) e 63% (B) dos anúncios mudam 10 pontos percentuais de posto ou mais entre os dois rankings. Os índices de A e de B têm correlação de postos de 0,82.

Figura 5 – Distribuição da nota oficial e do índice sintético (modelo A) nos 22.564 anúncios com índice.

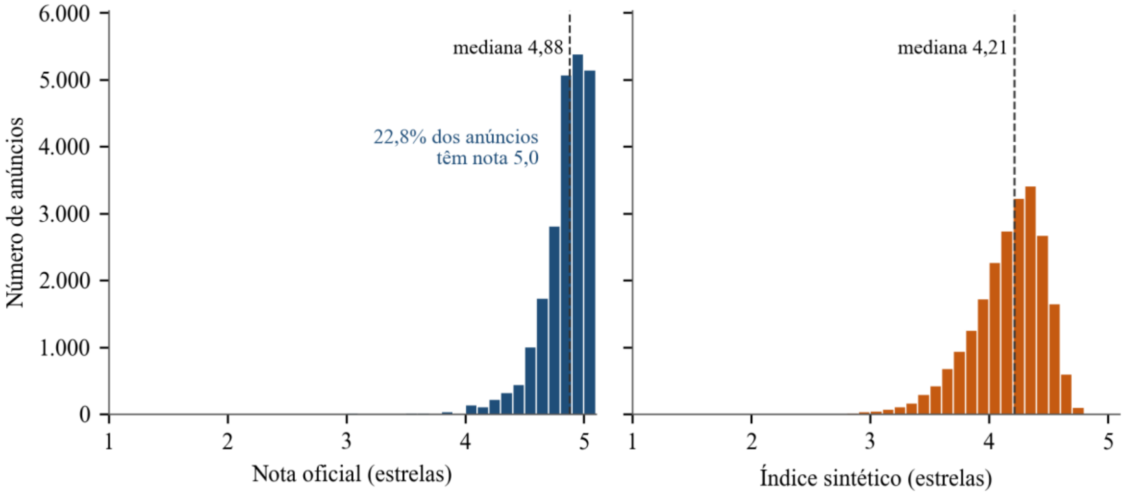

Fonte: Elaborada pelo autor.

Entre os 5.142 anúncios de nota exatamente 5,0 que têm índice, o índice os distribui entre o percentil 27 e o 98 (do 5º ao 95º; em B, de 22 a 98). Esses percentis são calculados sobre a distribuição dos 22.564 anúncios com índice, o que inclui os de nota inferior a 5,0. Ele concorda de forma fraca, mas positiva, com as seis subnotas (correlação de postos de 0,08 a 0,12 em A e de 0,04 a 0,10 em B, já que as subnotas também são saturadas). Essa capacidade de discriminar vale para os anúncios de nota 5,0 que têm índice, ou seja, 5.142 dos 9.373 anúncios de nota 5,0 (54,9%). Os que ficam de fora são sobretudo os de pouquíssimas avaliações, justamente os mais comprimidos (Tabela 12).

Tabela 12 – Anúncios de nota 5,0 com e sem índice sintético (preço por diária em reais).

| **Característica (nota 5,0)** | **Com índice** | **Sem índice** |
|---|---:|---:|
| Anúncios | 5.142 | 4.231 |
| Avaliações totais (mediana) | 9 | 3 |
| Preço por diária (mediana, em R$) | 345 | 331 |
| Casa ou apartamento inteiro | 81% | 72% |
| Quarto privado | 18% | 26% |
| Português predominante | 74% | 73% |

Fonte: Elaborada pelo autor.

## 6.3 PODER EXPLICATIVO SOBRE OS ÍNDICES DE VOLUME

Os controles são o volume total de avaliações (em logaritmo), o preço (em logaritmo), o tipo de acomodação e o bairro. Não se controla pelas avaliações dos últimos 12 meses (Seção 2). A validação é feita fora da amostra, com cinco dobras repetidas cinco vezes, com a mesma semente e as mesmas dobras em todos os modelos. O modelo M0 contém os controles, M1 acrescenta a nota oficial, M2 acrescenta o índice sintético no lugar da nota e

M3 acrescenta os dois. No índice de ocupação, na amostra completa, os controles têm $R^2$ fora da amostra de 0,475 e a nota oficial o eleva a 0,483. A Tabela 13 mostra os ganhos de $R^2$ fora da amostra, com a média entre dobras e o intervalo de 2,5% a 97,5% entre dobras, para a amostra completa e para o teto de nota 5,0. A tabela completa, com os quatro escopos de cada desfecho (12 linhas), está no Apêndice D.

Tabela 13 – Ganho de $R^2$ fora da amostra: média entre dobras e intervalo entre dobras (versão resumida; as 12 comparações estão no Apêndice D).

| **Desfecho** | **Escopo** | **M1 − M0 (A)** | **M2 − M1 (A)** | **M3 − M1 (A)** | **M3 − M1 (B)** |
|---|---|---|---|---|---|
| Índice de ocupação | amostra completa | +0,0079 [+0,0052; +0,0099] | −0,0050 [−0,0070; −0,0020] | +0,0000 [−0,0005; +0,0002] | +0,0002 [−0,0007; +0,0006] |
| Índice de ocupação | nota = 5,0 | +0,0000 | −0,0002 [−0,0009; +0,0000] | −0,0002 [−0,0009; +0,0000] | −0,0002 [−0,0007; +0,0000] |
| Índice de receita (log) | amostra completa | +0,0174 [+0,0089; +0,0239] | −0,0132 [−0,0206; −0,0050] | +0,0010 [−0,0013; +0,0025] | +0,0014 [−0,0015; +0,0027] |
| Índice de receita (log) | nota = 5,0 | +0,0000 | +0,0019 [−0,0040; +0,0059] | +0,0019 [−0,0040; +0,0059] | +0,0016 [−0,0019; +0,0040] |
| Avaliações em 12 meses (log) | amostra completa | +0,0163 [+0,0108; +0,0208] | −0,0116 [−0,0157; −0,0067] | +0,0006 [−0,0009; +0,0014] | +0,0012 [−0,0008; +0,0025] |
| Avaliações em 12 meses (log) | nota = 5,0 | +0,0000 | +0,0015 [−0,0020; +0,0041] | +0,0015 [−0,0020; +0,0041] | +0,0005 [−0,0018; +0,0017] |

Fonte: Elaborada pelo autor.

A nota oficial acrescenta um poder explicativo pequeno, mas detectável nos três desfechos na amostra completa. O índice, no lugar da nota, explica menos. O índice não acrescenta poder explicativo além da nota oficial: nas 12 comparações de M3 com M1 (três desfechos em quatro escopos), o intervalo inclui zero em todas, tanto em A quanto em B. Restritas aos 22.564 anúncios com índice nos dois modelos, as diferenças de M3 − M1 entre A e B são de no máximo 0,0010.

Os coeficientes dentro da amostra mostram outra coisa. Em M3, o coeficiente padronizado do índice (erro padrão robusto HC3) aparece significativo em vários desfechos e escopos. Reunindo os 12 coeficientes de cada modelo em uma família e aplicando a correção de Benjamini e Hochberg, 6 de 12 têm $q < 0,05$ em A e 8 de 12 em B. Esses coeficientes não são robustos. Mudam de sinal conforme o escopo (negativos na amostra completa e positivos em parte dos tetos) e conforme o modelo de sentimento (no índice de ocupação da amostra completa, o coeficiente é não significativo em A, com $q = 0,106$ e negativo e significativo em B, com $q = 0,003$) e não se confirmam fora da amostra, onde os ganhos de M3 − M1 têm intervalos que incluem zero. Por isso ficam fora da síntese e das conclusões.

## 6.4 MONOTONICIDADE E REORDENAMENTO

O índice reordena os anúncios em relação à nota oficial e resta saber se a reordenação se associa ao desfecho. A Tabela 14 mostra a correlação de postos entre cada medida e o índice de ocupação residualizado nos controles, por faixa da nota oficial.

Tabela 14 – Correlação de postos com o índice de ocupação residualizado, por faixa da nota oficial.

| Faixa da nota oficial | $n$ | $\rho$ do índice (A) | $\rho$ do índice (B) | $\rho$ da nota oficial |
|---|---:|---:|---:|---:|
| Todas | 20.882 | 0,083 | 0,071 | 0,168 |
| [0; 4,5) | 1.285 | −0,086 | −0,108 | −0,176 |
| [4,5; 4,8) | 5.146 | −0,045 | −0,063 | 0,047 |
| [4,8; 4,9) | 4.704 | −0,036 | −0,063 | 0,018 |
| [4,9; 5) | 5.036 | −0,018 | −0,004 | 0,099 |
| = 5,0 | 4.711 | 0,025 | 0,028 | – |

Fonte: Elaborada pelo autor.

Nos dois modelos a associação do índice com o desfecho residual é pequena e muda de sinal entre as faixas. Na faixa de nota 5,0 ela é próxima de zero. A regressão isotônica, que impõe relação monótona crescente e é avaliada fora da amostra, tem $R^2$ de 0,029 para a nota oficial e de 0,006 para o índice na amostra completa (0,004 em B). Nos tetos, o $R^2$ é aproximadamente zero para ambos (na nota 5,0, −0,003 para o índice em A).

## 6.5 SENSIBILIDADE

O resultado foi repetido em seis variantes: com e sem encolhimento, com e sem a satisfação geral e com todos os anúncios ou apenas os de até 30 avaliações. O ganho de $R^2$ do índice além da nota oficial no teto (nota 5,0) permanece próximo de zero em todas. O intervalo do ganho no número de avaliações em 12 meses inclui zero em todas (por exemplo, +0,0015, com intervalo de −0,0020 a +0,0041, na especificação principal e +0,0016, com intervalo de −0,0026 a +0,0044, com encolhimento). A correlação de postos do índice com o índice de ocupação bruto, dentro da faixa de nota 5,0, é de −0,01 sem encolhimento e de +0,35 com encolhimento. Esse valor é um artefato do encolhimento (Seção 6.1). Sem ele e com o desfecho residualizado, a correlação é próxima de zero em todas as variantes. Excluir a satisfação geral quase não altera os resultados.

O limite de 30 avaliações por anúncio atinge 32% dos anúncios elegíveis, mas apenas 5,2% dos de nota 5,0. A confiabilidade do sentimento médio por anúncio, com correção de Spearman-Brown, é de 0,50 com 30 avaliações, de 0,67 com 60 e de 0,80 com 120. Não há deriva temporal relevante: as estrelas médias são de 4,345 nas 10 avaliações mais recentes e de 4,368 nas 20 mais antigas.

## 6.6 COMO LER O RESULTADO

O resultado é nulo e secundário: o índice sintético não acrescenta poder explicativo sobre os índices de volume além da nota oficial, nos dois modelos de sentimento. Há duas leituras, que não se excluem. A primeira é que o sentimento do texto tem pouca razão teórica para prever uma contagem de avaliações, porque os desfechos disponíveis são índices de volume (Seção 2). O nulo é, em parte, consequência do desfecho que a base permite. A segunda é que o valor do texto está na decomposição por aspecto da Seção 4. A nota oficial já resume bem a satisfação geral do hóspede. O texto acrescenta o porquê. O índice sintético não é apresentado em nenhum ponto como uma nota melhor.

# 7 DISCUSSÃO E LIMITAÇÕES

## 7.1 OS RESULTADOS À LUZ DA LITERATURA

Os dados reproduzem o padrão de compressão descrito para o Airbnb (Zervas; Proserpio; Byers, 2021): 32,4% dos anúncios elegíveis têm nota exatamente igual a 5,0. A maior parte das sentenças é positiva em ambos os modelos de sentimento (78,9% em A e 81,5% em B). O resultado concorda com a observação de que as avaliações da plataforma adotam uma norma de comentário positivo (Bridges; Vásquez, 2016) e com a comparação, em cidades brasileiras e americanas, que encontra avaliações do Airbnb mais positivas que as de uma plataforma hoteleira (Santos et al., 2020). Dado esse viés, a decisão de trabalhar com a ordenação do sentimento e não com o seu nível e de tomar o percentil da nota como alvo, tem apoio nos próprios dados.

A decomposição da nota coincide, em parte, com os temas que a literatura aponta para a experiência do hóspede. Cheng e Jin (2019) destacam localização, comodidades e anfitrião. Sutherland e Kiatkawsin (2020) agrupam os tópicos em localização, características do imóvel e serviço do anfitrião. Neste estudo, comodidades e limpeza respondem pela maior parte da variação explicada da nota global. As queixas de comunicação com o anfitrião também se associam a notas menores. A localização, por outro lado, quase não contribui para a nota global, embora seja o aspecto que mais explica a sua própria subnota. A diferença em relação aos estudos citados está no desfecho: eles descrevem os temas mais frequentes ou mais valorados nas avaliações. Este trabalho mede a associação de cada aspecto com a nota numérica. Os dois resultados são compatíveis. A localização aparece em muitas avaliações e o hóspede a avalia em separado, de modo que é plausível que a sua variação entre anúncios acrescente pouco à nota global depois de considerados os atributos do imóvel, hipótese que os dados não testam. A análise de Luo e Tang (2019), que relaciona aspectos latentes à nota numérica, é o antecedente mais próximo. Este estudo a estende com validação da medida por aspecto, dois modelos de sentimento e um corpus multilíngue.

A leitura por tópico traz uma assimetria que a teoria dos três fatores (Seção 1.1) ajuda a descrever. As queixas da Tabela 10 se associam a diferenças de 10 a 26 pontos no percentil da nota e os elogios da Tabela 11, a diferenças de 5 a 11 pontos. O contraste é mais nítido em limpeza: a queixa de sujeira tem a maior diferença associada da Tabela 10 (−26,4 pontos) e o elogio de limpeza, a menor da Tabela 11 (+4,8). As queixas de instalações e manutenção (banheiro, ar-condicionado, cozinha, cama, conexão de internet e reparos) e de cheiro estão entre −17,7 e −21,8 pontos. Esse padrão é compatível com atributos que se comportam como fatores básicos: o mau desempenho penaliza a nota mais do que o bom desempenho a recompensa. Limpeza e as instalações do imóvel seriam os candidatos. Os elogios de maior diferença associada são os de satisfação geral (sentir-se em casa, +10,9 pontos) e de comunicação com o anfitrião (+8,5), mais próximos de fatores de desempenho ou de entusiasmo. A leitura é descritiva e tem limites. Os tópicos comparados são diferentes e muito desiguais em prevalência (o elogio ao anfitrião aparece em 84% dos anúncios e a queixa de sujeira em 7%), as menções vêm de previsões com erro e os aspectos de comodidades e de satisfação geral estão na classe de cautela. A assimetria entre queixa e elogio de um mesmo atributo não foi testada formalmente. Esse teste é um dos desdobramentos indicados nas Conclusões.

O resultado nulo do índice sintético tem relação com o efeito halo (Thorndike, 1920). Como as subnotas e a nota global são muito correlacionadas entre si, a nota oficial já captura boa parte do que o sentimento médio dos aspectos poderia acrescentar. O índice reordena os anúncios de nota 5,0 em relação à nota oficial, mas essa reordenação não se associa ao volume de avaliações além do que a nota oficial já explica. Os desfechos disponíveis, que são índices de volume, oferecem um teste pouco favorável ao índice. Essa é a primeira das duas leituras do resultado apresentadas na Seção 6.

## 7.2 IMPLICAÇÕES PARA ANFITRIÕES E EMPRESAS GESTORAS

O resultado mais utilizável está nas queixas por tópico. Entre as 15 queixas de maior peso, 13 se repetem nos dois modelos de sentimento. Entre elas figuram banheiro, ar-condicionado, cozinha, cama, conexão de internet, manutenção, limpeza, cheiro e resposta do anfitrião. As queixas se associam a quedas de 10 a 26 pontos no percentil da nota. O diagnóstico por anúncio permite localizar, entre essas queixas, as que se repetem em um anúncio específico. O instrumento é descritivo. A associação é uma média da cidade. Uma queixa de banheiro em um anúncio não implica que a correção do banheiro eleve a sua nota.

## 7.3 LIMITAÇÕES

O sentimento foi calculado sobre as 30 avaliações mais recentes de cada anúncio. O limite atinge 32% dos anúncios elegíveis (9.266), embora apenas 5,2% dos de nota 5,0 e reduz a confiabilidade do sentimento médio por anúncio, cuja correção de Spearman-Brown é de

0,50 com 30 avaliações. Os dados contêm apenas anúncios ativos na coleta. A data da avaliação não indica a data da estadia.

Não há ocupação nem receita observadas. Os campos disponíveis são funções do número de avaliações recentes. Nenhum resultado diz respeito a desempenho econômico.

Os rótulos de referência vêm de um único pesquisador, que também revisou o mapa dos tópicos para aspectos. Um segundo anotador rotulou 100 sentenças, com concordância alta no sentimento (kappa de 0,86) e moderada no aspecto (kappa de 0,62), de modo que a atribuição de aspecto carrega erro de rotulagem além do erro do modelo. A amostra rotulada tem 297 sentenças e, ponderada pela população, tamanho efetivo de cerca de 72, razão pela qual os intervalos são largos e a comparação entre modelos é frágil: a diferença de kappa entre B e A é de −0,141, com intervalo que mal exclui zero. A confiabilidade das metades do sentimento por aspecto é baixa; as subnotas usadas como referência são comprimidas. Sete dos dez aspectos pedem cautela. A classificação dos aspectos é indicativa: com 27 sentenças rotuladas por aspecto, os intervalos de Wilson são largos e os dos três aspectos confiáveis incluem o limiar de 0,60 e em limpeza os dois anotadores concordam pouco (33%, $n = 6$). Comodidades, o aspecto de maior peso, tem atribuição imprecisa (44%, intervalo de Wilson de 28% a 63%) e não tem subnota que o valide; dividido em subaspectos, o seu peso se reparte sem que um deles domine (Seção 4). O seu conteúdo se sobrepõe em parte ao de outros aspectos. O LDA permite checar apenas quatro aspectos.

Os modelos de sentimento divergem de forma que a escolha não é óbvia. O modelo A é o principal por uma regra fixada antes da execução do B, mas B é melhor na amostra rotulada e A, na população. Por isso os resultados de B acompanham todos os blocos. Onde os dois divergem (por exemplo, nos coeficientes dentro da amostra do índice sintético), as duas leituras são relatadas sem preferência.

A importância relativa de um aspecto mistura efeito e confiabilidade da medida; as associações com a nota são entre anúncios e não dentro de um mesmo anúncio. O texto e a nota vêm dos mesmos hóspedes, de modo que a análise decompõe o conteúdo da nota e não a prevê por um fator independente e o texto cobre as 30 avaliações mais recentes enquanto a nota é acumulada. Anúncios sem aspectos suficientes têm o sentimento imputado. Quanto ao índice sintético, apenas 5.142 dos anúncios de nota 5,0 o possuem. Os que ficam de fora têm menos avaliações, de modo que as conclusões sobre o teto valem para esse subconjunto. A decisão de não aplicar encolhimento foi tomada depois de ver o resultado com encolhimento, o que justifica reportar as duas versões. Os coeficientes dentro da amostra não são robustos e não foram confirmados fora dela.

A análise cobre um município, uma plataforma e uma coleta e os resultados podem não se estender a outros mercados.

# CONCLUSÕES

O texto das avaliações mostra que a nota do Airbnb se associa sobretudo às instalações e à limpeza do imóvel. Comodidades e limpeza respondem pela maior parte da variação explicada da nota global, e as queixas de instalações, de limpeza e de resposta do anfitrião se associam às maiores quedas no percentil da nota. Todos os resultados são associações e valem com as ressalvas da Seção 7.

A medição do texto é utilizável, com restrições. A acurácia populacional do sentimento é de 87% no modelo A e de 85% no B, medida em 297 sentenças rotuladas, e a regra fixada antes da execução do modelo B define A como principal. Os dois modelos ordenam sentenças e anúncios de forma semelhante, mas não são intercambiáveis. Apenas limpeza, localização e custo-benefício atendem ao critério de confiança, e essa classificação é indicativa, porque os intervalos de cada aspecto são largos. Os outros sete aspectos pedem cautela. Um segundo método de tópicos (LDA) reproduz o sinal nos aspectos que consegue checar, e a concordância entre dois anotadores é alta no sentimento e moderada no aspecto.

Nos dois modelos, comodidades é o aspecto de maior parcela do $R^2$ da nota global (42% em A e 48% em B), seguida de limpeza (20% em A e 19% em B). Isso se mantém em todos os segmentos e sensibilidades. Dividido em subaspectos, o peso de comodidades se reparte entre as instalações e banheiro e chuveiro é o maior deles. Como comodidades pede cautela, a leitura mais sustentada é a dos tópicos finos. Treze das 15 queixas de maior peso coincidem nos dois modelos (banheiro e chuveiro, ar-condicionado, sujeira, cozinha, cheiro, cama, *wi-fi* e resposta do anfitrião) e se associam a quedas de 10 a 26 pontos no percentil da nota.

A decomposição é aplicável ao anúncio. O diagnóstico por anúncio compara cada aspecto com os anúncios do mesmo bairro e tipo, mostra a evidência de cada aspecto e as queixas e elogios recorrentes e indica onde investigar, sem prever a nota nem prescrever causas.

Um índice único não acrescenta poder explicativo. O índice sintético reordena os anúncios em relação à nota oficial e discrimina os anúncios de nota 5,0 que o possuem (5.142 de 9.373), mas não acrescenta poder explicativo sobre os índices de volume de avaliações além da nota oficial, em nenhum dos dois modelos. O resultado é nulo e secundário, com duas leituras que não se excluem: o sentimento tem pouca razão teórica para prever uma contagem de avaliações; o valor do texto está na decomposição por aspecto. Os coeficientes do índice dentro da amostra não são robustos e ficam fora desta síntese.

O estudo não conclui que o índice sintético seja uma nota melhor que a oficial, que corrigir um problema apontado em uma queixa eleve a nota, nem que exista efeito sobre receita ou ocupação.

Alguns desdobramentos seguem diretamente das limitações. Desfechos econômicos observados, como calendário de disponibilidade e preços praticados ao longo do tempo, permitiriam testar o índice sintético com um desfecho que não seja índice de volume. Um painel temporal permitiria acompanhar o mesmo anúncio e aproximar-se de um contraste dentro do anúncio. A rotulagem por mais anotadores, em especial dos aspectos que pedem cautela, reduziria o erro de referência da atribuição de aspecto. A replicação em outras cidades testaria a generalidade da decomposição. Um classificador direto de aspecto por sentença, treinado com sentenças rotuladas, dispensaria o mapa de tópicos para aspectos e permitiria comparar a precisão das duas formas de atribuição. Um teste formal da assimetria entre queixa e elogio de um mesmo atributo, no mesmo anúncio ou em um painel, verificaria se limpeza e instalações se comportam como fatores básicos, como a leitura descritiva da Seção 7 sugere.

# REFERÊNCIAS

BARBIERI, Francesco; ESPINOSA ANKE, Luis; CAMACHO-COLLADOS, Jose. XLM-T: Multilingual language models in Twitter for sentiment analysis and beyond. *In*: **CONFERENCE ON LANGUAGE RESOURCES AND EVALUATION, 13., 2022, Marseille**. Proceedings [...]. Marseille: European Language Resources Association, 2022. p. 258-266. Disponível em: https://aclanthology.org/2022.lrec-1.27/. Acesso em: 10 out. 2026.

BENJAMINI, Yoav; HOCHBERG, Yosef. Controlling the False Discovery Rate: A Practical and Powerful Approach to Multiple Testing. **Journal of the Royal Statistical Society: Series B (Methodological)**, v. 57, n. 1, p. 289-300, 1995. DOI: 10.1111/j.2517-6161.1995.tb02031.x.

BI, Jian-Wu *et al.* Exploring asymmetric effects of attribute performance on customer satisfaction in the hotel industry. **Tourism Management**, v. 77, p. 104006, 2020. DOI: 10.1016/j.tourman.2019.104006.

BLEI, David M.; NG, Andrew Y.; JORDAN, Michael I. Latent Dirichlet allocation. **Journal of Machine Learning Research**, v. 3, p. 993-1022, 2003. Disponível em: https://jmlr.org/papers/v3/blei03a.html. Acesso em: 10 out. 2026.

BRIDGES, Judith; VÁSQUEZ, Camilla. If nearly all Airbnb reviews are positive, does that make them meaningless? **Current Issues in Tourism**, 2016. DOI: 10.1080/13683500.2016.1267113.

BROWN, William. Some experimental results in the correlation of mental abilities. **British Journal of Psychology**, v. 3, n. 3, p. 296-322, 1910. DOI: 10.1111/j.2044-8295.1910.tb00207.x.

CAPES. **Produção técnica: relatório de grupo de trabalho**. Brasília: CAPES, 2019.

CARDIFF NLP. **twitter-xlm-roberta-base-sentiment (modelo)**. [S. l.], 2023. Disponível em: https://huggingface.co/cardiffnlp/twitter-xlm-roberta-base-sentiment. Acesso em: 10 out. 2026.

CAVIQUE, Mariana *et al.* Examining Airbnb guest satisfaction tendencies: a text mining approach. **Current Issues in Tourism**, v. 25, n. 22, p. 3607-3622, 2022. DOI: 10.1080/13683500.2022.2115877.

CHENG, Mingming; JIN, Xin. What do Airbnb users care about? An analysis of online review comments. **International Journal of Hospitality Management**, v. 76, p. 58-70, 2019. DOI: 10.1016/j.ijhm.2018.04.004.

CHEVALIER, Judith A.; MAYZLIN, Dina. The Effect of Word of Mouth on Sales: Online Book Reviews. **Journal of Marketing Research**, v. 43, n. 3, p. 345-354, 2006. DOI: 10.1509/jmkr.43.3.345.

CHICA-OLMO, Jorge; GONZÁLEZ-MORALES, Juan Gabriel; ZAFRA-GÓMEZ, José Luis. Effects of location on Airbnb apartment pricing in Málaga. **Tourism Management**, v. 77, p. 103981, 2020. DOI: 10.1016/j.tourman.2019.103981.

COHEN, Jacob. A Coefficient of Agreement for Nominal Scales. **Educational and Psychological Measurement**, v. 20, n. 1, p. 37-46, 1960. DOI: 10.1177/001316446002000104.

COHEN, Jacob. Weighted kappa: Nominal scale agreement provision for scaled disagreement or partial credit. **Psychological Bulletin**, v. 70, n. 4, p. 213-220, 1968. DOI: 10.1037/h0026256.

DEBOOSERE, Robbin *et al.* Location, location and professionalization: a multilevel hedonic analysis of Airbnb listing prices and revenue. **Regional Studies, Regional Science**, v. 6, n. 1, p. 143-156, 2019. DOI: 10.1080/21681376.2019.1592699.

DELLAROCAS, Chrysanthos; WOOD, Charles A. The Sound of Silence in Online Feedback: Estimating Trading Risks in the Presence of Reporting Bias. **Management Science**, v. 54, n. 3, p. 460-476, 2008. DOI: 10.1287/mnsc.1070.0747.

DEVLIN, Jacob *et al.* BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. *In*: **CONFERENCE OF THE NORTH AMERICAN CHAPTER OF THE ASSOCIATION FOR COMPUTATIONAL LINGUISTICS: HUMAN LANGUAGE TECHNOLOGIES, 2019, Minneapolis**. Proceedings [...]. [S. l.]: Association for Computational Linguistics, 2019. p. 4171-4186. DOI: 10.18653/v1/n19-1423.

DING, Kai *et al.* Employing structural topic modelling to explore perceived service quality attributes in Airbnb accommodation. **International Journal of Hospitality Management**, v. 91, p. 102676, 2020. DOI: 10.1016/j.ijhm.2020.102676.

DING, Kai *et al.* Exploring sources of satisfaction and dissatisfaction in Airbnb accommodation using unsupervised and supervised topic modeling. **Frontiers in Psychology**, v. 12, p. 659481, 2021. DOI: 10.3389/fpsyg.2021.659481.

EFRON, Bradley; MORRIS, Carl. Data Analysis Using Stein's Estimator and its Generalizations. **Journal of the American Statistical Association**, v. 70, n. 350, p. 311-319, 1975. DOI: 10.1080/01621459.1975.10479864.

EFRON, Bradley. Bootstrap Methods: Another Look at the Jackknife. **The Annals of Statistics**, v. 7, n. 1, p. 1-26, 1979. DOI: 10.1214/aos/1176344552.

FILIPPAS, Apostolos; HORTON, John J.; GOLDEN, Joseph M. Reputation Inflation. **Marketing Science**, v. 41, n. 4, p. 733-745, 2022. DOI: 10.1287/mksc.2022.1350.

FRADKIN, Andrey; GREWAL, Elena; HOLTZ, David. Reciprocity and Unveiling in Two-Sided Reputation Systems: Evidence from an Experiment on Airbnb. **Marketing Science**, v. 40, n. 6, p. 1013-1029, 2021. DOI: 10.1287/mksc.2021.1311.

FREITAS, Larissa A.; VIEIRA, Renata. Ontology based feature level opinion mining for Portuguese reviews. *In*: **INTERNATIONAL CONFERENCE ON WORLD WIDE WEB, 22., 2013, [S. l.]**. Proceedings [...]. [S. l.]: [s. n.], 2013. p. 367-370. DOI: 10.1145/2487788.2487944.

FÜLLER, Johann; MATZLER, Kurt. Customer delight and market segmentation: an application of the three-factor theory of customer satisfaction on life style groups. **Tourism Management**, v. 29, n. 1, p. 116-126, 2008. DOI: 10.1016/j.tourman.2007.03.021.

GIRITLI, Ayçin; ERENSEL, Salahi; ÖZTÜREN, Ali. Evaluating the performance of large language models in aspect-based sentiment analysis: Cyprus hotel reviews. *In*: **IEEE ANNUAL COMPUTERS, SOFTWARE, AND APPLICATIONS CONFERENCE (COMPSAC), 50., 2026, [S. l.]**. Proceedings [...]. [S. l.]: IEEE, 2026. p. 2296-2301. DOI: 10.1109/compsac69091.2026.00342.

GRÖMPING, Ulrike. Relative Importance for Linear Regression in R : The Package relaimpo. **Journal of Statistical Software**, v. 17, n. 1, p. 1-27, 2006. DOI: 10.18637/jss.v017.i01.

GRÖMPING, Ulrike. Estimators of Relative Importance in Linear Regression Based on Variance Decomposition. **The American Statistician**, v. 61, n. 2, p. 139-147, 2007. DOI: 10.1198/000313007x188252.

GROOTENDORST, Maarten. BERTopic: Neural topic modeling with a class-based TF-IDF procedure. [S. l.]: arXiv, 2022. Disponível em: https://arxiv.org/abs/2203.05794. Acesso em: 10 out. 2026.

GYÓDI, Kristóf; NAWARO, Łukasz. Determinants of Airbnb prices in European cities: A spatial econometrics approach. **Tourism Management**, v. 86, p. 104319, 2021. DOI: 10.1016/j.tourman.2021.104319.

HU, Nan; ZHANG, Jie; PAVLOU, Paul A. Overcoming the J-shaped distribution of product reviews. **Communications of the ACM**, v. 52, n. 10, p. 144-147, 2009. DOI: 10.1145/1562764.1562800.

INSIDE AIRBNB. **Inside Airbnb: Adding data to the debate; data assumptions (San Francisco model)**. [S. l.], 2026. Disponível em: https://insideairbnb.com/data-assumptions/. Acesso em: 10 out. 2026.

KIATKAWSIN, Kiattipoom; SUTHERLAND, Ian; KIM, Jin-Young. A comparative automated text analysis of Airbnb reviews in Hong Kong and Singapore using latent Dirichlet allocation. **Sustainability**, v. 12, n. 16, p. 6673, 2020. DOI: 10.3390/su12166673.

KISH, Leslie. Weighting for unequal Pi. **Journal of Official Statistics**, v. 8, n. 2, p. 183-200, 1992.

LANDIS, J. Richard; KOCH, Gary G. The Measurement of Observer Agreement for Categorical Data. **Biometrics**, v. 33, n. 1, p. 159-174, 1977. DOI: 10.2307/2529310.

LINDEMAN, Richard H.; MERENDA, Peter F.; GOLD, Ruth Z. **Introduction to Bivariate and Multivariate Analysis**. Glenview, IL: Scott, Foresman, 1980.

LIU, Bing. **Sentiment Analysis and Opinion Mining**. [S. l.]: Morgan & Claypool, 2012. (Synthesis Lectures on Human Language Technologies) DOI: 10.1007/978-3-031-02145-9.

LUO, Yi; TANG, Rebecca (Liang). Understanding hidden dimensions in textual reviews on Airbnb: An application of modified latent aspect rating analysis (LARA). **International Journal of Hospitality Management**, v. 80, p. 144-154, 2019. DOI: 10.1016/j.ijhm.2019.02.008.

MATZLER, Kurt; SAUERWEIN, Elmar. The factor structure of customer satisfaction: an empirical test of the importance grid and the penalty-reward-contrast analysis. **International Journal of Service Industry Management**, v. 13, n. 4, p. 314-332, 2002. DOI: 10.1108/09564230210445078.

MCHUGH, Mary L. Interrater reliability: the kappa statistic. **Biochemia Medica**, v. 22, n. 3, p. 276-282, 2012. DOI: 10.11613/bm.2012.031.

MCINNES, Leland; HEALY, John; ASTELS, Steve. hdbscan: Hierarchical density based clustering. **Journal of Open Source Software**, v. 2, n. 11, p. 205, 2017. DOI: 10.21105/joss.00205.

MCINNES, Leland; HEALY, John; MELVILLE, James. UMAP: Uniform manifold approximation and projection for dimension reduction. [S. l.]: arXiv, 2018. Disponível em: https://arxiv.org/abs/1802.03426. Acesso em: 10 out. 2026.

NLP TOWN. **bert-base-multilingual-uncased-sentiment (modelo)**. [S. l.], 2025. Disponível em: https://huggingface.co/nlptown/bert-base-multilingual-uncased-sentiment. Acesso em: 10 out. 2026.

PEDREGOSA, Fabian *et al.* Scikit-learn: Machine learning in Python. **Journal of Machine Learning Research**, v. 12, p. 2825-2830, 2011. Disponível em: https://jmlr.org/papers/v12/pedregosa11a.html. Acesso em: 10 out. 2026.

PONTIKI, Maria *et al.* SemEval-2014 Task 4: Aspect Based Sentiment Analysis. *In*: **INTERNATIONAL WORKSHOP ON SEMANTIC EVALUATION, 8., 2014, Dublin**. Proceedings [...]. [S. l.]: [s. n.], 2014. p. 27-35. DOI: 10.3115/v1/s14-2004.

PONTIKI, Maria *et al.* SemEval-2016 Task 5: Aspect Based Sentiment Analysis. *In*: **INTERNATIONAL WORKSHOP ON SEMANTIC EVALUATION, 10., 2016, San Diego**. Proceedings [...]. [S. l.]: Association for Computational Linguistics, 2016. p. 19-30. DOI: 10.18653/v1/s16-1002.

PROSERPIO, Davide; ZERVAS, Georgios. Online Reputation Management: Estimating the Impact of Management Responses on Consumer Reviews. **Marketing Science**, v. 36, n. 5, p. 645-665, 2017. DOI: 10.1287/mksc.2017.1043.

REIMERS, Nils; GUREVYCH, Iryna. Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks. *In*: **CONFERENCE ON EMPIRICAL METHODS IN NATURAL LANGUAGE PROCESSING AND INTERNATIONAL JOINT CONFERENCE ON NATURAL LANGUAGE PROCESSING, 9., 2019, Hong Kong**. Proceedings [...]. [S. l.]: Association for Computational Linguistics, 2019. p. 3982-3992. DOI: 10.18653/v1/d19-1410.

REIMERS, Nils; GUREVYCH, Iryna. Making monolingual sentence embeddings multilingual using knowledge distillation. *In*: **CONFERENCE ON EMPIRICAL METHODS IN NATURAL LANGUAGE PROCESSING, 2020, [S. l.]**. Proceedings [...]. [S. l.]: Association for Computational Linguistics, 2020. p. 4512-4525. DOI: 10.18653/v1/2020.emnlp-main.365.

REY-MORENO, Manuel; SÁNCHEZ-FRANCO, Manuel J.; REY-TIENDA, María de la Sierra. Examining transaction-specific satisfaction and trust in Airbnb and hotels: an application of BERTopic and zero-shot text classification. **Tourism & Management Studies**, v. 19, n. 2, p. 21-37, 2023. DOI: 10.18089/tms.2023.190202.

RÖDER, Michael; BOTH, Andreas; HINNEBURG, Alexander. Exploring the Space of Topic Coherence Measures. *In*: **ACM INTERNATIONAL CONFERENCE ON WEB SEARCH AND DATA MINING, 8., 2015, Shanghai**. Proceedings [...]. [S. l.]: [s. n.], 2015. p. 399-408. DOI: 10.1145/2684822.2685324.

SANTOS, Gustavo *et al.* Neutrality may matter: Sentiment analysis in reviews of Airbnb, Booking, and Couchsurfing in Brazil and USA. [S. l.]: arXiv, 2020. Disponível em: https://arxiv.org/abs/2005.06591. Acesso em: 10 out. 2026.

SCHOUTEN, Kim; FRASINCAR, Flavius. Survey on Aspect-Level Sentiment Analysis. **IEEE Transactions on Knowledge and Data Engineering**, v. 28, n. 3, p. 813-830, 2016. DOI: 10.1109/tkde.2015.2485209.

SOUZA, Fábio Capuano de. **BERTimbau: pretrained BERT models for Brazilian Portuguese**. 2020. Dissertação (Mestrado) – Faculdade de Engenharia Elétrica e de Computação, Universidade Estadual de Campinas, Campinas, 2020. DOI: 10.47749/t/unicamp.2020.1161906.

SPEARMAN, Charles. Correlation calculated from faulty data. **British Journal of Psychology**, v. 3, n. 3, p. 271-295, 1910. DOI: 10.1111/j.2044-8295.1910.tb00206.x.

SURYABRATA, Arghanta Wijna; WARNARS, Harco Leslie Hendric Spits; MUYEBA, Maybin K. Aspect-based sentiment analysis of multilingual hotel reviews in Jakarta using multilingual transformer models: a comparative study of multilingual BERT and cross-lingual RoBERTa. **Ingénierie des Systèmes d'Information**, v. 31, n. 1, 2026. DOI: 10.18280/isi.310112.

SUTHERLAND, Ian; KIATKAWSIN, Kiattipoom. Determinants of Guest Experience in Airbnb: A Topic Modeling Approach Using LDA. **Sustainability**, v. 12, n. 8, p. 3402, 2020. DOI: 10.3390/su12083402.

THORNDIKE, Edward L. A constant error in psychological ratings. **Journal of Applied Psychology**, v. 4, n. 1, p. 25-29, 1920. DOI: 10.1037/h0071663.

VASSILIKOPOULOU, Aikaterini; KAMENIDOU, Irene; PRIPORAS, Constantinos-Vasilios. Negative Airbnb reviews: an aspect-based sentiment analysis approach. **EuroMed Journal of Business**, v. 19, n. 2, p. 191-207, 2022. DOI: 10.1108/emjb-03-2022-0052.

WANG, Dan; NICOLAU, Juan L. Price determinants of sharing economy based accommodation rental: A study of listings from 33 cities on Airbnb.com. **International Journal of Hospitality Management**, v. 62, p. 120-131, 2017. DOI: 10.1016/j.ijhm.2016.12.007.

WOLF, Thomas *et al.* Transformers: State-of-the-Art Natural Language Processing. *In*: **CONFERENCE ON EMPIRICAL METHODS IN NATURAL LANGUAGE PROCESSING: SYSTEM DEMONSTRATIONS, 2020, [S. l.]**. Proceedings [...]. [S. l.]: Association for Computational Linguistics, 2020. p. 38-45. DOI: 10.18653/v1/2020.emnlp-demos.6.

XU, Chun *et al.* Enhancing aspect-based sentiment analysis in tourism using large language models and positional information. **Tsinghua Science and Technology**, v. 31, n. 2, p. 1012-1030, 2026. DOI: 10.26599/tst.2024.9010138.

ZERVAS, Georgios; PROSERPIO, Davide; BYERS, John W. A first look at online reputation on Airbnb, where every stay is above average. **Marketing Letters**, v. 32, n. 1, p. 1-16, 2021. DOI: 10.1007/s11002-020-09546-4.

ZHANG, Jurui. Listening to the consumer: exploring review topics on Airbnb and their impact on listing performance. **Journal of Marketing Theory and Practice**, v. 27, n. 4, p. 371-389, 2019. DOI: 10.1080/10696679.2019.1644953.

ZHANG, Wenxuan *et al.* A Survey on Aspect-Based Sentiment Analysis: Tasks, Methods, and Challenges. **IEEE Transactions on Knowledge and Data Engineering**, v. 35, n. 11, p. 11019-11038, 2023. DOI: 10.1109/tkde.2022.3230975.

# APÊNDICE A – REGISTRO DATADO DA REGRA DE ESCOLHA DO MODELO PRINCIPAL

Este apêndice documenta que a regra de escolha do modelo principal foi fixada antes da execução do modelo B sobre o corpus. O registro está no histórico de decisões do projeto (seção 30 do arquivo `historico/HISTORICO_DECISOES.md`) e no repositório de versões, cujos *commits* têm data e hora.

A regra, como registrada antes da execução, é a seguinte. O modelo principal é B se o intervalo de confiança de 95% (*bootstrap* estratificado) da diferença B menos A no kappa ponderado linear populacional de sentimento, calculado nas frases rotuladas com os pesos de população dos estratos originais (aspecto e polaridade previstos por A), exclui zero a favor de B, isto é, tem limite inferior maior que zero. Caso contrário, o modelo principal continua sendo A. O outro modelo é sempre reportado integralmente como robustez.

A Tabela 15 lista os eventos, com data e hora no fuso de Brasília (UTC−3).

Tabela 15 – Sequência datada do registro da regra e da execução do modelo B.

| **Evento** | **Data e hora** | **Registro** |
|---|---|---|
| Regra registrada no histórico de decisões (seção 30) e no repositório | 09/10/2026, 20:22:25 | *commit* `c6e72df984e8` |
| Início da inferência do modelo B no corpus | 09/10/2026, 20:39:12 | registro de execução da inferência de B |
| Código de inferência do modelo B no repositório | 09/10/2026, 20:40:50 | *commit* `6a82cbe861b3` |
| Fim da inferência do modelo B (757,1 minutos) | 10/10/2026, 09:16:20 | registro de execução da inferência de B |
| Avaliação de A e B nas frases rotuladas, aplicação da regra e resultados | 10/10/2026, 09:31:11 | *commit* `ae38e3e16343` |

Fonte: Elaborada pelo autor.

O *commit* da regra (hash completo `c6e72df984e856dce62c7e3a9719a4ddc47e7a7c`) é anterior em 17 minutos ao início da inferência de B e em 18 minutos e 25 segundos ao *commit* do código que a executa. O resultado da regra é a diferença de −0,141 (IC 95% de −0,272 a −0,012), que exclui zero a favor de A. O modelo principal é, portanto, A.

# APÊNDICE B – RELATÓRIOS DE DIAGNÓSTICO DOS TRÊS EXEMPLOS

As figuras a seguir reproduzem os três relatórios de diagnóstico gerados pela ferramenta (Seção 5) na versão anonimizada, com o identificador do anúncio substituído por um código, o bairro omitido e sem trechos de avaliações. Cada relatório é dividido em duas partes para caber na página. O primeiro exemplo é um anúncio de nota alta, o segundo de nota baixa e o terceiro, com poucas avaliações.

Figura 6 – Relatório de diagnóstico de um anúncio de nota alta (exemplo anonimizado; parte superior).

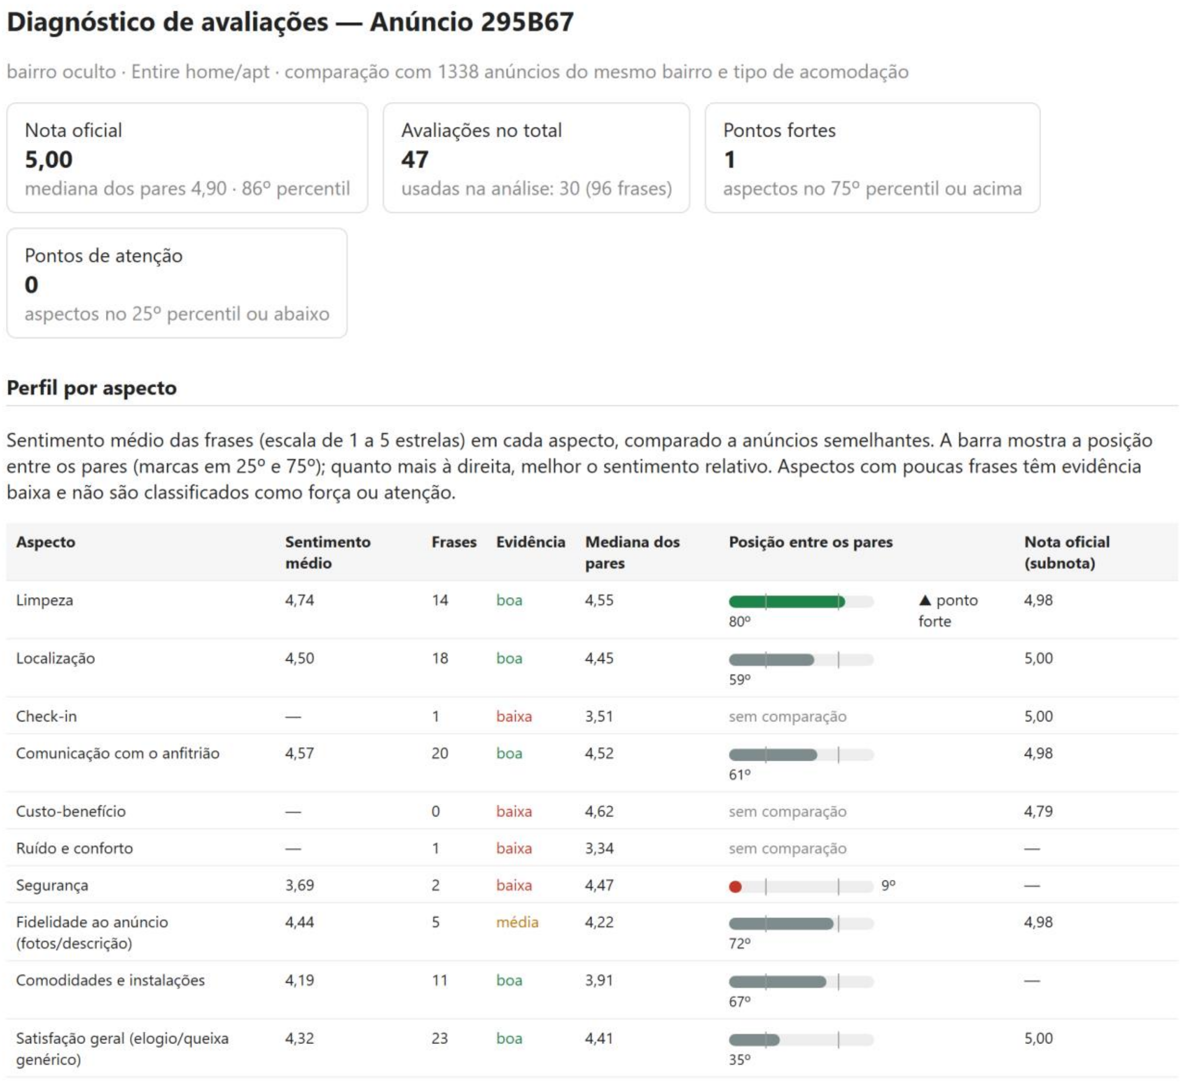

**Diagnóstico de avaliações — Anúncio 295B67**

bairro oculto · Entire home/apt · comparação com 1338 anúncios do mesmo bairro e tipo de acomodação

Nota oficial
**5,00**
mediana dos pares 4,90 · 86º percentil

Avaliações no total
**47**
usadas na análise: 30 (96 frases)

Pontos fortes
**1**
aspectos no 75º percentil ou acima

Pontos de atenção
**0**
aspectos no 25º percentil ou abaixo

**Perfil por aspecto**

Sentimento médio das frases (escala de 1 a 5 estrelas) em cada aspecto, comparado a anúncios semelhantes. A barra mostra a posição entre os pares (marcas em 25º e 75º); quanto mais à direita, melhor o sentimento relativo. Aspectos com poucas frases têm evidência baixa e não são classificados como força ou atenção.

| Aspecto | Sentimento médio | Frases | Evidência | Mediana dos pares | Posição entre os pares | Nota oficial (subnota) |
|---|---|---|---|---|---|---|
| Limpeza | 4,74 | 14 | boa | 4,55 | 80º ▲ ponto forte | 4,98 |
| Localização | 4,50 | 18 | boa | 4,45 | 59º | 5,00 |
| Check-in | — | 1 | baixa | 3,51 | sem comparação | 5,00 |
| Comunicação com o anfitrião | 4,57 | 20 | boa | 4,52 | 61º | 4,98 |
| Custo-benefício | — | 0 | baixa | 4,62 | sem comparação | 4,79 |
| Ruído e conforto | — | 1 | baixa | 3,34 | sem comparação | — |
| Segurança | 3,69 | 2 | baixa | 4,47 | 9º | — |
| Fidelidade ao anúncio (fotos/descrição) | 4,44 | 5 | média | 4,22 | 72º | 4,98 |
| Comodidades e instalações | 4,19 | 11 | boa | 3,91 | 67º | — |
| Satisfação geral (elogio/queixa genérico) | 4,32 | 23 | boa | 4,41 | 35º | 5,00 |

Fonte: Elaborada pelo autor.

Figura 7 – Relatório de diagnóstico de um anúncio de nota alta (exemplo anonimizado; parte inferior).

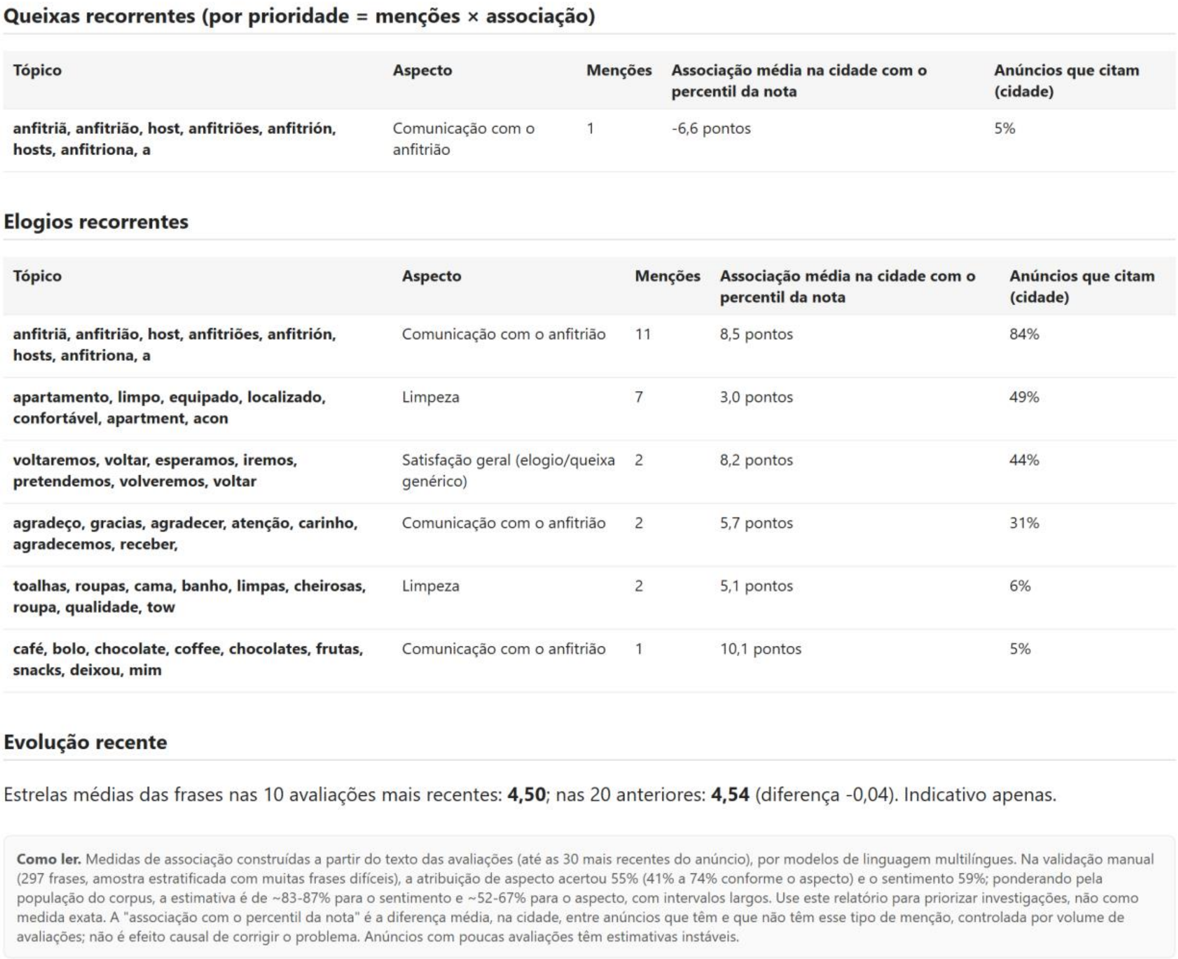

### Queixas recorrentes (por prioridade = menções × associação)

| Tópico | Aspecto | Menções | Associação média na cidade com o percentil da nota | Anúncios que citam (cidade) |
|---|---|---|---|---|
| **anfitriã, anfitrião, host, anfitriões, anfitrión, hosts, anfitriona, a** | Comunicação com o anfitrião | 1 | -6,6 pontos | 5% |

### Elogios recorrentes

| Tópico | Aspecto | Menções | Associação média na cidade com o percentil da nota | Anúncios que citam (cidade) |
|---|---|---|---|---|
| **anfitriã, anfitrião, host, anfitriões, anfitrión, hosts, anfitriona, a** | Comunicação com o anfitrião | 11 | 8,5 pontos | 84% |
| **apartamento, limpo, equipado, localizado, confortável, apartment, acon** | Limpeza | 7 | 3,0 pontos | 49% |
| **voltaremos, voltar, esperamos, iremos, pretendemos, volveremos, voltar** | Satisfação geral (elogio/queixa genérico) | 2 | 8,2 pontos | 44% |
| **agradeço, gracias, agradecer, atenção, carinho, agradecemos, receber,** | Comunicação com o anfitrião | 2 | 5,7 pontos | 31% |
| **toalhas, roupas, cama, banho, limpas, cheirosas, roupa, qualidade, tow** | Limpeza | 2 | 5,1 pontos | 6% |
| **café, bolo, chocolate, coffee, chocolates, frutas, snacks, deixou, mim** | Comunicação com o anfitrião | 1 | 10,1 pontos | 5% |

### Evolução recente

Estrelas médias das frases nas 10 avaliações mais recentes: **4,50**; nas 20 anteriores: **4,54** (diferença -0,04). Indicativo apenas.

**Como ler.** Medidas de associação construídas a partir do texto das avaliações (até as 30 mais recentes do anúncio), por modelos de linguagem multilíngues. Na validação manual (297 frases, amostra estratificada com muitas frases difíceis), a atribuição de aspecto acertou 55% (41% a 74% conforme o aspecto) e o sentimento 59%; ponderando pela população do corpus, a estimativa é de ~83-87% para o sentimento e ~52-67% para o aspecto, com intervalos largos. Use este relatório para priorizar investigações, não como medida exata. A "associação com o percentil da nota" é a diferença média, na cidade, entre anúncios que têm e que não têm esse tipo de menção, controlada por volume de avaliações; não é efeito causal de corrigir o problema. Anúncios com poucas avaliações têm estimativas instáveis.

Fonte: Elaborada pelo autor.

Figura 8 – Relatório de diagnóstico de um anúncio de nota baixa (exemplo anonimizado; parte superior).

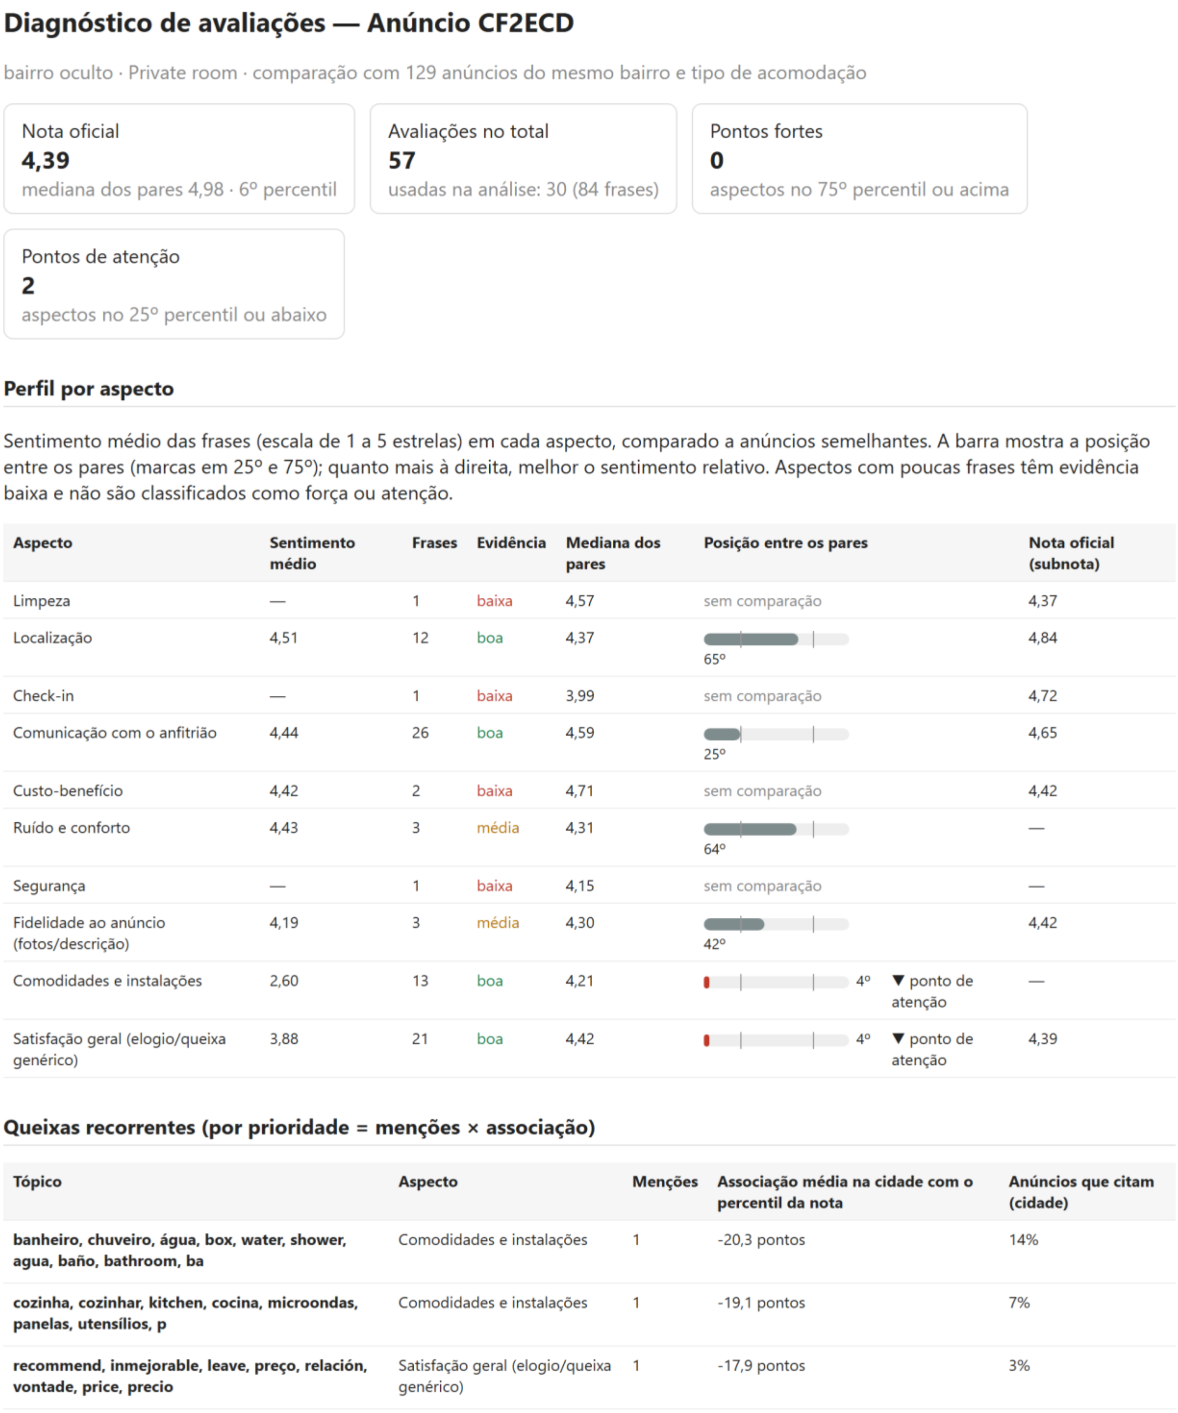

## Diagnóstico de avaliações — Anúncio CF2ECD

bairro oculto · Private room · comparação com 129 anúncios do mesmo bairro e tipo de acomodação

Nota oficial
**4,39**
mediana dos pares 4,98 · 6º percentil

Avaliações no total
**57**
usadas na análise: 30 (84 frases)

Pontos fortes
**0**
aspectos no 75º percentil ou acima

Pontos de atenção
**2**
aspectos no 25º percentil ou abaixo

### Perfil por aspecto

Sentimento médio das frases (escala de 1 a 5 estrelas) em cada aspecto, comparado a anúncios semelhantes. A barra mostra a posição entre os pares (marcas em 25º e 75º); quanto mais à direita, melhor o sentimento relativo. Aspectos com poucas frases têm evidência baixa e não são classificados como força ou atenção.

| Aspecto | Sentimento médio | Frases | Evidência | Mediana dos pares | Posição entre os pares | Nota oficial (subnota) |
|---|---|---|---|---|---|---|
| Limpeza | — | 1 | baixa | 4,57 | sem comparação | 4,37 |
| Localização | 4,51 | 12 | boa | 4,37 | 65º | 4,84 |
| Check-in | — | 1 | baixa | 3,99 | sem comparação | 4,72 |
| Comunicação com o anfitrião | 4,44 | 26 | boa | 4,59 | 25º | 4,65 |
| Custo-benefício | 4,42 | 2 | baixa | 4,71 | sem comparação | 4,42 |
| Ruído e conforto | 4,43 | 3 | média | 4,31 | 64º | — |
| Segurança | — | 1 | baixa | 4,15 | sem comparação | — |
| Fidelidade ao anúncio (fotos/descrição) | 4,19 | 3 | média | 4,30 | 42º | 4,42 |
| Comodidades e instalações | 2,60 | 13 | boa | 4,21 | 4º ▼ ponto de atenção | — |
| Satisfação geral (elogio/queixa genérico) | 3,88 | 21 | boa | 4,42 | 4º ▼ ponto de atenção | 4,39 |

### Queixas recorrentes (por prioridade = menções × associação)

| Tópico | Aspecto | Menções | Associação média na cidade com o percentil da nota | Anúncios que citam (cidade) |
|---|---|---|---|---|
| **banheiro, chuveiro, água, box, water, shower, agua, baño, bathroom, ba** | Comodidades e instalações | 1 | -20,3 pontos | 14% |
| **cozinha, cozinhar, kitchen, cocina, microondas, panelas, utensílios, p** | Comodidades e instalações | 1 | -19,1 pontos | 7% |
| **recommend, inmejorable, leave, preço, relación, vontade, price, precio** | Satisfação geral (elogio/queixa genérico) | 1 | -17,9 pontos | 3% |

Fonte: Elaborada pelo autor.

Figura 9 – Relatório de diagnóstico de um anúncio de nota baixa (exemplo anonimizado; parte inferior).

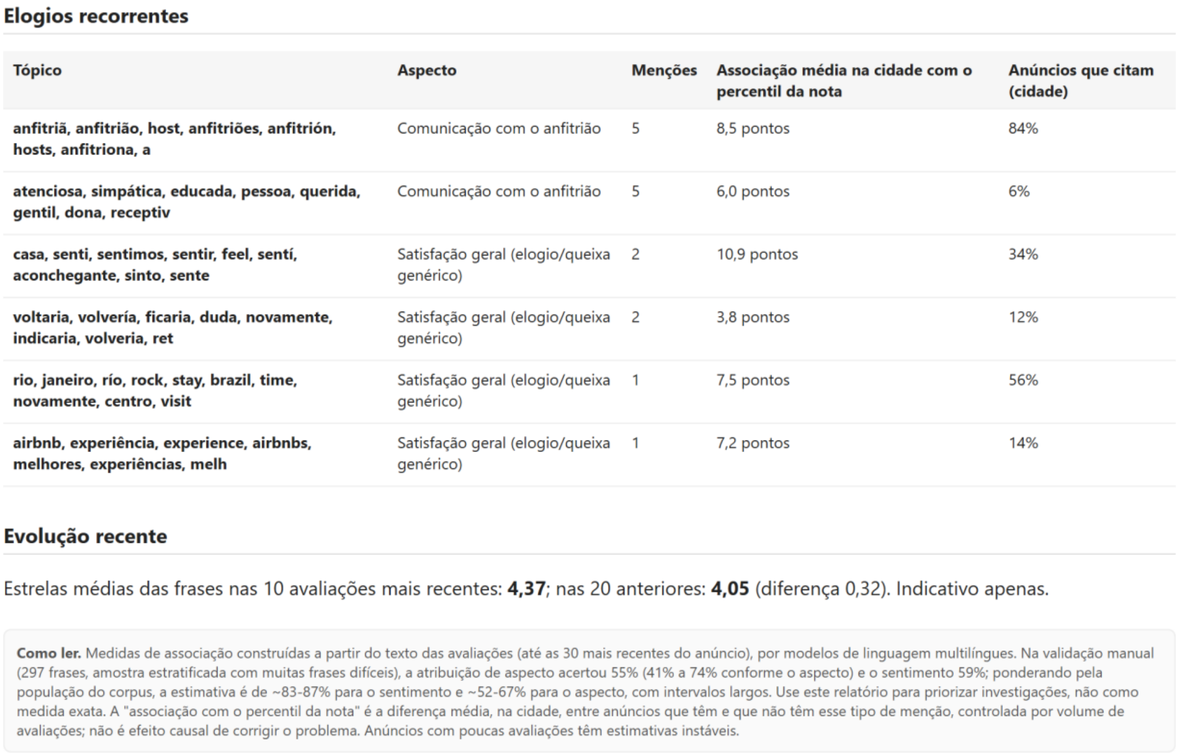

## Elogios recorrentes

| Tópico | Aspecto | Menções | Associação média na cidade com o percentil da nota | Anúncios que citam (cidade) |
|---|---|---|---|---|
| **anfitriã, anfitrião, host, anfitriões, anfitrión, hosts, anfitriona, a** | Comunicação com o anfitrião | 5 | 8,5 pontos | 84% |
| **atenciosa, simpática, educada, pessoa, querida, gentil, dona, receptiv** | Comunicação com o anfitrião | 5 | 6,0 pontos | 6% |
| **casa, senti, sentimos, sentir, feel, sentí, aconchegante, sinto, sente** | Satisfação geral (elogio/queixa genérico) | 2 | 10,9 pontos | 34% |
| **voltaria, volvería, ficaria, duda, novamente, indicaria, volveria, ret** | Satisfação geral (elogio/queixa genérico) | 2 | 3,8 pontos | 12% |
| **rio, janeiro, río, rock, stay, brazil, time, novamente, centro, visit** | Satisfação geral (elogio/queixa genérico) | 1 | 7,5 pontos | 56% |
| **airbnb, experiência, experience, airbnbs, melhores, experiências, melh** | Satisfação geral (elogio/queixa genérico) | 1 | 7,2 pontos | 14% |

## Evolução recente

Estrelas médias das frases nas 10 avaliações mais recentes: **4,37**; nas 20 anteriores: **4,05** (diferença 0,32). Indicativo apenas.

**Como ler.** Medidas de associação construídas a partir do texto das avaliações (até as 30 mais recentes do anúncio), por modelos de linguagem multilíngues. Na validação manual (297 frases, amostra estratificada com muitas frases difíceis), a atribuição de aspecto acertou 55% (41% a 74% conforme o aspecto) e o sentimento 59%; ponderando pela população do corpus, a estimativa é de ~83-87% para o sentimento e ~52-67% para o aspecto, com intervalos largos. Use este relatório para priorizar investigações, não como medida exata. A "associação com o percentil da nota" é a diferença média, na cidade, entre anúncios que têm e que não têm esse tipo de menção, controlada por volume de avaliações; não é efeito causal de corrigir o problema. Anúncios com poucas avaliações têm estimativas instáveis.

Fonte: Elaborada pelo autor.

Figura 10 – Relatório de diagnóstico de um anúncio com poucas avaliações (exemplo anonimizado; parte superior).

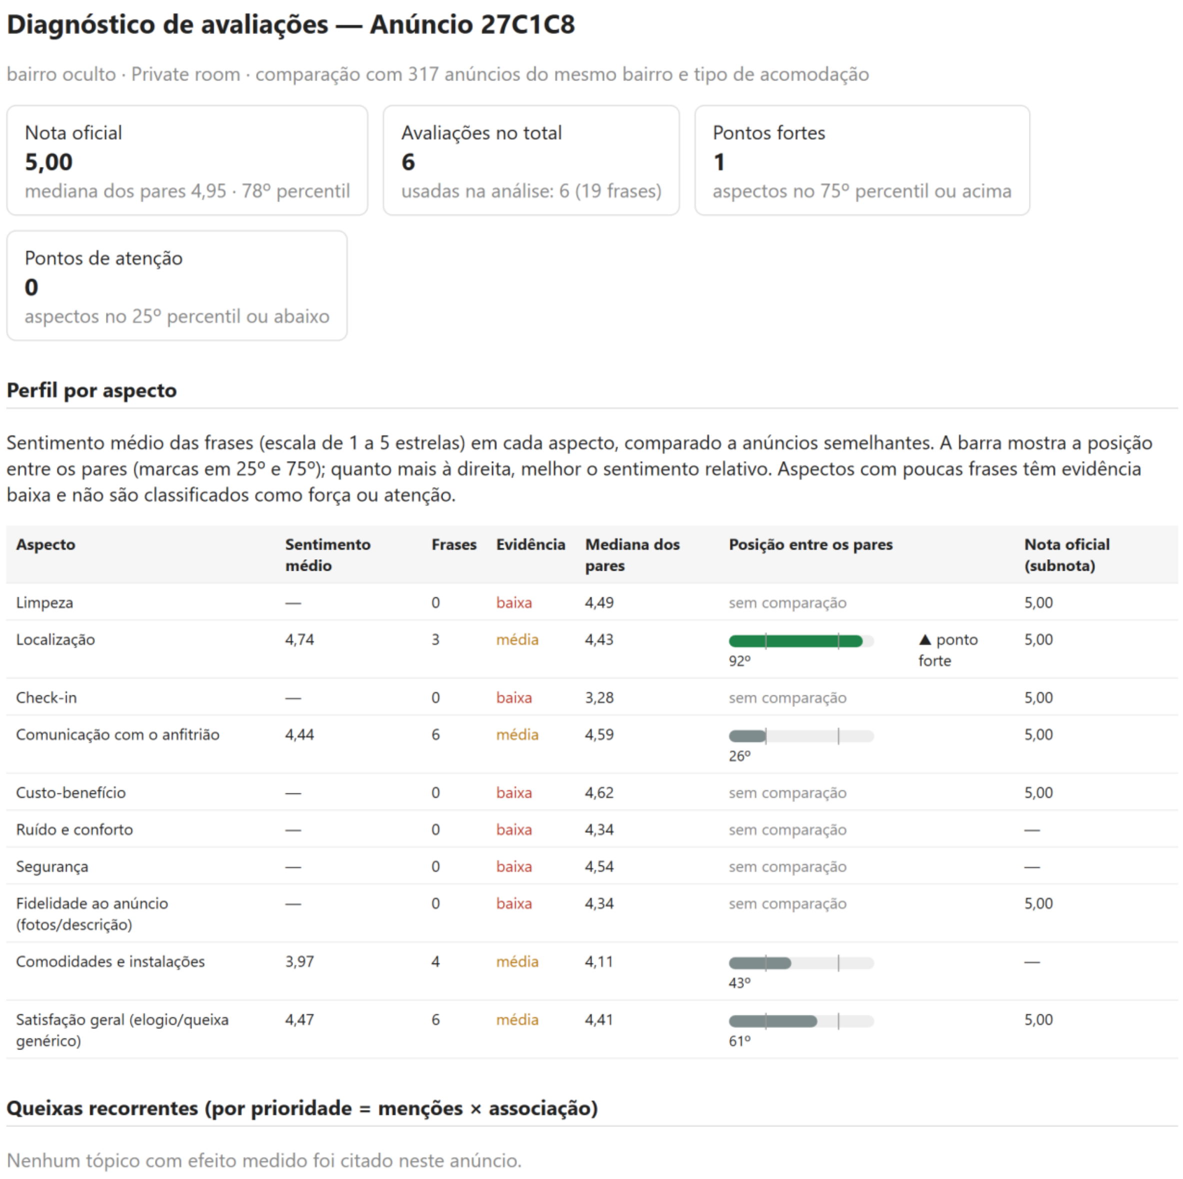

## Diagnóstico de avaliações — Anúncio 27C1C8

bairro oculto · Private room · comparação com 317 anúncios do mesmo bairro e tipo de acomodação

Nota oficial
**5,00**
mediana dos pares 4,95 · 78º percentil

Avaliações no total
**6**
usadas na análise: 6 (19 frases)

Pontos fortes
**1**
aspectos no 75º percentil ou acima

Pontos de atenção
**0**
aspectos no 25º percentil ou abaixo

### Perfil por aspecto

Sentimento médio das frases (escala de 1 a 5 estrelas) em cada aspecto, comparado a anúncios semelhantes. A barra mostra a posição entre os pares (marcas em 25º e 75º); quanto mais à direita, melhor o sentimento relativo. Aspectos com poucas frases têm evidência baixa e não são classificados como força ou atenção.

| Aspecto | Sentimento médio | Frases | Evidência | Mediana dos pares | Posição entre os pares | | Nota oficial (subnota) |
|---|---|---|---|---|---|---|---|
| Limpeza | — | 0 | baixa | 4,49 | sem comparação | | 5,00 |
| Localização | 4,74 | 3 | média | 4,43 | 92º | ▲ ponto forte | 5,00 |
| Check-in | — | 0 | baixa | 3,28 | sem comparação | | 5,00 |
| Comunicação com o anfitrião | 4,44 | 6 | média | 4,59 | 26º | | 5,00 |
| Custo-benefício | — | 0 | baixa | 4,62 | sem comparação | | 5,00 |
| Ruído e conforto | — | 0 | baixa | 4,34 | sem comparação | | — |
| Segurança | — | 0 | baixa | 4,54 | sem comparação | | — |
| Fidelidade ao anúncio (fotos/descrição) | — | 0 | baixa | 4,34 | sem comparação | | 5,00 |
| Comodidades e instalações | 3,97 | 4 | média | 4,11 | 43º | | — |
| Satisfação geral (elogio/queixa genérico) | 4,47 | 6 | média | 4,41 | 61º | | 5,00 |

### Queixas recorrentes (por prioridade = menções × associação)

Nenhum tópico com efeito medido foi citado neste anúncio.

Fonte: Elaborada pelo autor.

Figura 11 – Relatório de diagnóstico de um anúncio com poucas avaliações (exemplo anonimizado; parte inferior).

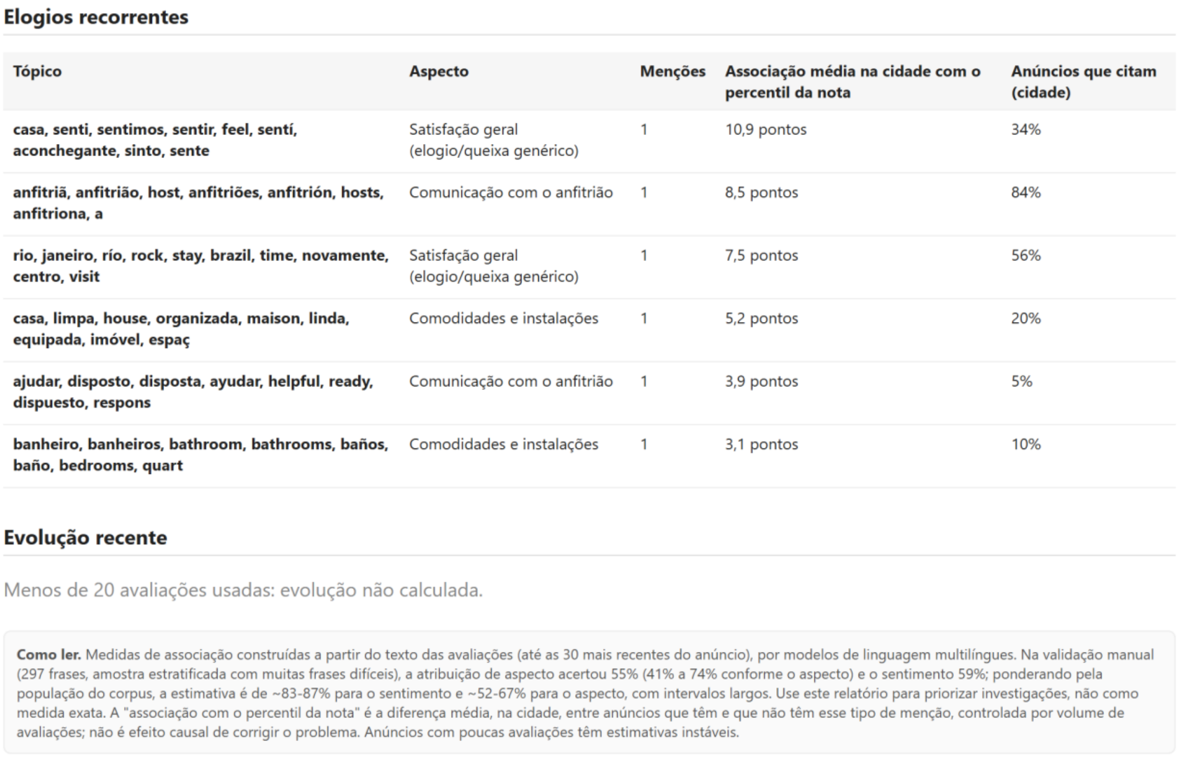

### Elogios recorrentes

| Tópico | Aspecto | Menções | Associação média na cidade com o percentil da nota | Anúncios que citam (cidade) |
|---|---|---|---|---|
| **casa, senti, sentimos, sentir, feel, sentí, aconchegante, sinto, sente** | Satisfação geral (elogio/queixa genérico) | 1 | 10,9 pontos | 34% |
| **anfitriã, anfitrião, host, anfitriões, anfitrión, hosts, anfitriona, a** | Comunicação com o anfitrião | 1 | 8,5 pontos | 84% |
| **rio, janeiro, río, rock, stay, brazil, time, novamente, centro, visit** | Satisfação geral (elogio/queixa genérico) | 1 | 7,5 pontos | 56% |
| **casa, limpa, house, organizada, maison, linda, equipada, imóvel, espaç** | Comodidades e instalações | 1 | 5,2 pontos | 20% |
| **ajudar, disposto, disposta, ayudar, helpful, ready, dispuesto, respons** | Comunicação com o anfitrião | 1 | 3,9 pontos | 5% |
| **banheiro, banheiros, bathroom, bathrooms, baños, baño, bedrooms, quart** | Comodidades e instalações | 1 | 3,1 pontos | 10% |

### Evolução recente

Menos de 20 avaliações usadas: evolução não calculada.

**Como ler.** Medidas de associação construídas a partir do texto das avaliações (até as 30 mais recentes do anúncio), por modelos de linguagem multilíngues. Na validação manual (297 frases, amostra estratificada com muitas frases difíceis), a atribuição de aspecto acertou 55% (41% a 74% conforme o aspecto) e o sentimento 59%; ponderando pela população do corpus, a estimativa é de ~83-87% para o sentimento e ~52-67% para o aspecto, com intervalos largos. Use este relatório para priorizar investigações, não como medida exata. A "associação com o percentil da nota" é a diferença média, na cidade, entre anúncios que têm e que não têm esse tipo de menção, controlada por volume de avaliações; não é efeito causal de corrigir o problema. Anúncios com poucas avaliações têm estimativas instáveis.

Fonte: Elaborada pelo autor.

# APÊNDICE C – ESTRATÉGIAS DE BUSCA BIBLIOGRÁFICA

A Tabela 16 lista as principais consultas da busca descrita na Seção 1. Todas foram executadas nas bases Scopus, Web of Science e Google Acadêmico, entre maio e outubro de 2026, com termos em inglês e, quando indicado, em português. Outras consultas exploratórias, redundantes com estas, não são listadas.

Tabela 16 – Principais consultas da busca bibliográfica.

| **Nº** | **Consulta** | **Tema** |
|---|---|---|
| 1 | Airbnb AND (“aspect-based sentiment analysis” OR “aspect-level sentiment analysis”) | análise por aspecto no Airbnb |
| 2 | Airbnb AND (“guest reviews” OR “online reviews”) AND (“guest satisfaction” OR “customer satisfaction” OR “service quality”) | satisfação do hóspede |
| 3 | Airbnb AND (“textual reviews” OR “review text” OR “review comments”) AND (ratings OR scores) AND (aspects OR attributes OR sentiment) | relação entre texto e nota |
| 4 | Airbnb AND “Rio de Janeiro” | recorte geográfico |
| 5 | Airbnb AND “Rio de Janeiro” AND (“sentiment analysis” OR “text mining” OR “topic modeling” OR reviews) | recorte geográfico e análise textual |
| 6 | Airbnb AND “Rio de Janeiro” AND (“análise de sentimento” OR “mineração de texto” OR avaliações OR comentários) | recorte geográfico, em português |
| 7 | Airbnb AND (“rating inflation” OR “reputation inflation” OR “ceiling effect” OR “positivity bias”) | compressão das notas no Airbnb |
| 8 | “online reviews” AND (“rating compression” OR “J-shaped distribution” OR “reporting bias”) | compressão das notas e vieses de relato |
| 9 | (“aspect-based sentiment analysis” OR “aspect-level sentiment analysis”) AND (hospitality OR tourism OR hotels) AND (validation OR annotation OR multilingual) | análise por aspecto em hospedagem e turismo |
| 10 | “aspect-based sentiment analysis” AND (“inter-annotator agreement” OR “construct validity” OR “domain adaptation”) | validação da análise por aspecto |
| 11 | (BERTopic OR “latent Dirichlet allocation”) AND (Airbnb OR hospitality OR “hotel reviews”) | modelagem de tópicos em avaliações |
| 12 | “multilingual sentiment analysis” AND (Portuguese OR “Brazilian Portuguese” OR hospitality) | sentimento multilíngue e em português |
| 13 | (Airbnb OR hospitality OR hotels) AND (“three-factor theory” OR Kano OR “penalty-reward contrast analysis” OR “asymmetric effects”) | teoria dos três fatores |

Fonte: Elaborada pelo autor.

# APÊNDICE D – GANHO DE $R^2$ FORA DA AMOSTRA: TABELA COMPLETA

A Tabela 17 traz as 12 comparações (três desfechos em quatro escopos) cuja versão resumida está na Seção 6. Cada célula mostra a média entre dobras e, entre colchetes, o intervalo de 2,5% a 97,5% entre dobras. As comparações são M1 − M0 (nota oficial além dos controles), M2 − M1 (índice no lugar da nota) e M3 − M1 (índice além da nota), esta última nos dois modelos de sentimento. Nos escopos de teto, o escopo é o conjunto de anúncios com nota oficial igual ou superior ao valor indicado.

Tabela 17 – Ganho de $R^2$ fora da amostra nos 12 escopos: média entre dobras e intervalo entre dobras.

| **Desfecho** | **Escopo** | ***n*** | **M1 − M0 (A)** | **M2 − M1 (A)** | **M3 − M1 (A)** | **M3 − M1 (B)** |
|---|---|---|---|---|---|---|
| Índice de ocupação | amostra completa | 20.882 | +0,0079 [+0,0052; +0,0099] | −0,0050 [−0,0070; −0,0020] | +0,0000 [−0,0005; +0,0002] | +0,0002 [−0,0007; +0,0006] |
| Índice de ocupação | nota ≥ 4,8 | 14.451 | +0,0063 [+0,0038; +0,0091] | −0,0059 [−0,0083; −0,0033] | +0,0000 [−0,0003; +0,0002] | +0,0002 [−0,0005; +0,0006] |
| Índice de ocupação | nota ≥ 4,9 | 9.747 | +0,0033 [+0,0009; +0,0057] | −0,0033 [−0,0055; −0,0010] | −0,0001 [−0,0003; +0,0000] | +0,0000 [−0,0006; +0,0002] |
| Índice de ocupação | nota = 5,0 | 4.711 | +0,0000 | −0,0002 [−0,0009; +0,0000] | −0,0002 [−0,0009; +0,0000] | −0,0002 [−0,0007; +0,0000] |
| Índice de receita (log) | amostra completa | 20.882 | +0,0174 [+0,0089; +0,0239] | −0,0132 [−0,0206; −0,0050] | +0,0010 [−0,0013; +0,0025] | +0,0014 [−0,0015; +0,0027] |
| Índice de receita (log) | nota ≥ 4,8 | 14.451 | +0,0039 [−0,0001; +0,0073] | −0,0037 [−0,0080; +0,0009] | −0,0002 [−0,0012; +0,0001] | −0,0002 [−0,0008; +0,0000] |
| Índice de receita (log) | nota ≥ 4,9 | 9.747 | +0,0009 [−0,0015; +0,0028] | −0,0002 [−0,0029; +0,0029] | +0,0004 [−0,0010; +0,0012] | +0,0004 [−0,0016; +0,0015] |
| Índice de receita (log) | nota = 5,0 | 4.711 | +0,0000 | +0,0019 [−0,0040; +0,0059] | +0,0019 [−0,0040; +0,0059] | +0,0016 [−0,0019; +0,0040] |
| Avaliações em 12 meses (log) | amostra completa | 20.882 | +0,0163 [+0,0108; +0,0208] | −0,0116 [−0,0157; −0,0067] | +0,0006 [−0,0009; +0,0014] | +0,0012 [−0,0008; +0,0025] |
| Avaliações em 12 meses (log) | nota ≥ 4,8 | 14.451 | +0,0060 [+0,0033; +0,0088] | −0,0055 [−0,0088; −0,0026] | −0,0001 [−0,0005; +0,0001] | +0,0001 [−0,0008; +0,0006] |
| Avaliações em 12 meses (log) | nota ≥ 4,9 | 9.747 | +0,0028 [−0,0008; +0,0059] | −0,0020 [−0,0045; +0,0014] | +0,0003 [−0,0004; +0,0007] | +0,0000 [−0,0006; +0,0002] |
| Avaliações em 12 meses (log) | nota = 5,0 | 4.711 | +0,0000 | +0,0015 [−0,0020; +0,0041] | +0,0015 [−0,0020; +0,0041] | +0,0005 [−0,0018; +0,0017] |

Fonte: Elaborada pelo autor.